

華中科技大學

本科生毕业设计

基于大语言模型的课程知识命名实体识别 与关系抽取

院 系 计算机科学与技术学院

专业班级 计科 7 班

姓 名 瞿明睿

学 号 U202215561


指导教师 姚德中

2026 年 6 月

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包括任何其他个人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

作者签名：



2026 年 6 月

学位论文版权使用授权书


本学位论文作者完全了解学校有关保障、使用学位论文的规定，同意学校保留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权省级优秀学士论文评选机构将本学位论文的全部或部分内 容编入有关数据进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于 1、保 密 ☐，在 年解密后适用本授权书

2、不保密 ☒。

(请在以上相应方框内打“√”)

作者签名：



2026 年 6 月

导师签名：

2026 年 6 月

摘要

课程知识的系统化组织对计算机网络领域的教学与研究很有价值。人工构建知识图谱效率低、成本高，难以规模化。本文设计并实现了一个面向计算机网络课程材料的自动化知识图谱构建系统，以大语言模型（Large Language Model, LLM）为核心完成知识抽取。

系统通过七阶段流水线将非结构化 PDF 文档转换为结构化知识图谱。文档预处理阶段使用多模态视觉语言模型完成 OCR（Optical Character Recognition），将教材、讲义、试卷等 PDF 材料转为结构化 Markdown 文本。长文档处理采用标题层级感知的递归分块算法，结合令牌预算控制，实现语义连贯的文本切分。知识抽取分两阶段：先用提示工程（Prompt Engineering）从中文课程文本中识别协议、概念、机制、指标四类实体，再抽取包含、依赖、对比、应用四类语义关系，通过证据验证门控机制保证三元组可溯源。实体歧义通过基于稠密向量嵌入（Dense Embedding）的实体规范化方法处理，利用 FAISS（Facebook AI Similarity Search）索引加速相似度检索，结合 Union-Find 并查集算法完成实体同一性判定与归并。知识融合后，数据导入 Neo4j 图数据库，通过基于 Next.js 的前端界面展示交互式知识图谱，支持关系导航与查询。

实验使用 205 份计算机网络课程材料构建知识图谱，涵盖教材、课件、习题集和 RFC 文档，共 274 个输出目录。处理后生成 16,438 个文本块，总计约 1,040 万词元，平均块长 632.6 词元。最终知识图谱包含 23,600 个实体（概念 16,719 个、机制 3,063 个、协议 2,189 个、指标 1,629 个）和 44,526 条关系三元组，高频实体包括 TCP（2,657 次）、UDP（1,411 次）、IP（1,020 次）、HTTP（932 次）等。实验表明，系统能处理大规模课程材料，提取的知识结构清晰、覆盖面广，为计算机网络课程教学提供了可计算的知识基础。

关键词：大语言模型；命名实体识别；关系抽取；知识图谱；课程知识；提示工程；实体规范化

Abstract

Structuring course knowledge can support teaching and research in computer networking. However, course documents contain specialized terms and complex relations, while manual knowledge graph construction is costly and hard to scale. This work studies how to build knowledge graphs automatically from unstructured course materials with large language models (LLMs).

A seven-stage pipeline was built that converts PDFs into Markdown, text chunks, raw triples, a merged knowledge graph, Neo4j storage, and a Next.js visualization frontend. Multimodal vision-language models perform OCR (Optical Character Recognition) and produce structured Markdown. A recursive header-aware chunking algorithm keeps document hierarchy within token limits. Chinese prompts extract four entity types (protocol, concept, mechanism, metric) and four relation types (contains, depends_on, compared_with, applied_to) in zero-shot and few-shot modes. An evidence verification gate checks that each triple is supported by source text. Entity canonicalization combines FAISS (Facebook AI Similarity Search) similarity search with the Union-Find disjoint-set algorithm to merge duplicate entities.

The pipeline processed 205 computer networking course documents and generated 16,438 text chunks (~ 10.4 million tokens). The final graph contains 23,600 entities and 44,526 relational triples across the predefined entity and relation categories. Frequent entities such as TCP, UDP, IP, and HTTP show that the graph captures core networking concepts. The result provides a structured knowledge graph for networking education.

Keywords: Large Language Models, Named Entity Recognition, Relation Extraction, Knowledge Graph, Course Knowledge, Prompt Engineering, Entity Canonicalization

目 录

摘 要	I
Abstract	II
1 绪 论	1
1.1 课题背景目的与意义	1
1.2 国内外研究现状	4
1.3 论文的主要内容与结构	8
2 相关技术基础	10
2.1 大语言模型基础	10
2.2 基于大模型的命名实体识别	13
2.3 基于大模型的关系抽取	15
2.4 知识图谱构建技术	17
2.5 教育领域知识图谱	19
2.6 本章小结	20
3 课程知识抽取系统设计	21
3.1 总体架构设计	21
3.2 文档预处理设计	22
3.3 文本分块设计	23
3.4 实体识别设计	26
3.5 关系抽取设计	27
3.6 知识融合设计	29
3.7 图存储与可视化设计	32
3.8 本章小结	33
4 系统实现	34
4.1 文档渲染与 OCR 实现	34
4.2 文本分块实现	34
4.3 知识抽取实现	35

4.4	知识融合实现	36
4.5	Neo4j 图数据库导入与前端可视化实现	37
4.6	本章小结	37
5	实验与结果分析	38
5.1	实验环境与配置	38
5.2	课程语料构建结果	39
5.3	实体抽取评估	41
5.4	关系抽取评估	42
5.5	金标数据核查与零样本/少样本对比	44
5.6	原始抽取层面的零样本与少样本对比	45
5.7	知识图谱质量分析	48
5.8	案例分析	49
5.9	本章小结	50
6	总结与展望	51
	参考文献	53
	致谢	57

1 绪 论

绪论章从课题背景讲起，梳理教育领域知识抽取面临的问题，综述国内外基于大语言模型的命名实体识别、关系抽取与知识图谱构建研究，并交代论文的主要内容和组织结构。

知识图谱是一种语义网络知识表示形式，通过结构化方式描述现实世界中的实体及其相互关系，是人工智能领域的基础信息组织形式。在教育信息化中，如何系统组织课程知识并实现智能化应用，直接影响教学质量和学习效率。传统知识图谱的构建依赖大量人工标注，面对专业领域的命名实体识别与关系抽取任务时，标注成本高、领域适应性差、知识更新滞后等问题突出。近年来，以 GPT、DeepSeek 等为代表的大语言模型（Large Language Model, LLM）在自然语言理解与生成方面进步明显，为知识抽取提供了新思路。得益于大模型在零样本和少样本场景下的学习能力，即使标注数据十分有限，也能完成较高质量的信息抽取，这为教育领域知识图谱的自动化构建创造了条件。

1.1 课题背景、目的与意义

1.1.1 研究背景与趋势

命名实体识别（Named Entity Recognition, NER）和关系抽取（Relation Extraction, RE）是信息抽取的两个核心任务，目标是从非结构化文本中自动识别预定义类型的实体并抽取实体间的语义关系。这两项技术在知识图谱构建、智能问答、文本挖掘中应用广泛^[1-2]。随着深度学习的发展^[3]，基于神经网络的方法在标准数据集上表现良好，但这类方法通常依赖大量高质量的标注数据进行监督学习，遇到领域迁移和新实体类型时，泛化能力不足。

教育领域中，课程知识的组织专业性强，结构紧密。以计算机网络课程为例，其中涉及大量协议实体（如 TCP、UDP、IP）、概念实体（如拥塞控制、流量整形）、机制实体（如三次握手、滑动窗口）以及性能指标实体（如吞吐量、时延）。这些实体之间存在复杂的依赖和应用关系，是课程知识体系的核心。教育领域的知识抽取面临独特的挑战：专业术语存在歧义、知识表达方式多样、对证

据可追溯性有要求，传统的有监督学习方法难以直接适应。

大语言模型的兴起为解决上述难题提供了新思路。近年的综述研究表明，大语言模型已从预训练语言模型发展为覆盖训练优化、能力评测和行业应用的通用技术体系^[4]。通过提示工程（Prompt Engineering）和上下文学习（In-Context Learning），大语言模型可以在仅给定少量示例甚至无示例的情况下完成特定任务^[5]，这对标注数据稀缺的教育领域尤其重要。大模型较强的语义理解能力使其能捕捉文本中隐含的语义关系，涌现能力则有助于识别传统方法难以发现的隐性知识关联，而预训练阶段积累的知识表示也使其能更好地理解领域专业知识。

当前，教育数字化转型是教育领域的主流趋势。智能教学系统、个性化学习推荐、自动答疑等应用对高质量的课程知识库需求迫切。传统的课程知识组织方式主要依靠人工整理，效率低且难以保证一致性。利用大语言模型进行自动化知识抽取，为大规模课程知识库的构建提供了可行的路径。

1.1.2 面临的问题和挑战

尽管大语言模型在通用自然语言处理任务上表现优异，但在面向课程知识的信息抽取任务中，仍然面临以下挑战：

一是领域适应性不足。通用大语言模型知识面广，但对特定领域的专业术语和知识体系理解有限。课程知识涉及大量领域特定的概念和关系类型，需要针对教育场景进行专门的模型适配和提示设计。不同学科的知识表达方式不同，如何设计通用的领域适配框架仍是一个需要解决的问题。计算机网络这类课程专业性较强，涉及大量协议规范和技术细节，需要模型具备较强的领域理解能力。例如，同一术语在不同上下文中可能指代不同的概念，模型需要结合上下文才能准确理解。

二是输出结构化困难。大语言模型的输出本质上是自由文本，而知识图谱构建需要严格结构化的三元组数据。如何设计有效的提示策略和输出约束机制，确保模型生成的表示符合规范，是实际应用中的关键问题。在处理复杂的嵌套实体和多关系场景时，结构化的准确性直接影响后续知识融合的效果。输出中的格式错误、实体边界识别偏差、关系类型混淆等问题都会降低最终知识图谱的质量。如何设计可解析的输出格式，并处理模型偶尔产生的格式偏离，也需要

在工程实现中解决。

三是知识准确性难以验证。大语言模型存在幻觉（Hallucination）现象，可能生成表面合理但实际错误的信息。在教育场景中，知识准确性尤其重要，需要建立证据验证机制，确保抽取结果的可信度和可追溯性。如何量化模型输出的置信度，在置信度偏低时触发人工审核，也是实际部署中需要权衡的问题。对于关键的专业知识点，抽取错误可能对学习者产生误导，因此需要质量控制。将抽取的知识与原文片段关联建立证据溯源，有助于提升可信度。

四是规模化处理复杂。课程材料通常以 PDF、PPT 等多种形式存在，包含大量图文混排内容。如何构建端到端的自动化处理流水线，将原始文档高效转换为结构化知识，是工程实现层面的主要挑战。大规模文档处理时的计算效率和成本控制也是实际应用中需要考量的因素。对于包含复杂排版、数学公式和图表说明的技术文档，准确提取其中的知识内容存在较大技术难度。如何设计可扩展的架构以支持持续的知识更新和增量处理，也是长期运营中的问题。

1.1.3 课题目的与意义

本文研究利用大语言模型进行课程知识的命名实体识别与关系抽取，构建面向计算机网络课程的知识图谱自动化构建系统。具体包含以下目标：

探索适用于教育领域的大模型提示策略。通过设计任务特定的提示模板，结合零样本和少样本学习方式，提升大模型在课程知识抽取任务上的表现。针对不同的实体类型和关系类型，设计差异化的提示策略，利用大模型的上下文学习能力。通过实验对比，确定提示设计原则和参数配置。研究不同提示元素（如任务描述、示例、输出格式说明）对抽取性能的影响，为提示工程提供实践参考。

建立知识抽取的质量保障机制。引入证据验证和一致性检查机制，降低大模型生成错误知识的风险，保障知识图谱的准确性。设计自动化的质量评估指标，对抽取结果进行实时监控和反馈。建立人机协作的审核流程，兼顾效率与质量。开发冲突检测算法，识别并解决知识抽取中的逻辑矛盾和不一致问题。

设计知识图谱构建流水线。将文档解析、文本预处理、实体识别、关系抽取、知识融合等环节整合为统一流程，形成可复用的教育知识图谱构建方案。设计模块化架构，支持灵活的配置和扩展，以适应不同学科的知识抽取需求。实现

从原始 PDF 到可视化知识图谱的端到端自动化。提供清晰的配置接口和监控界面，降低系统的使用门槛。

本文在理论和应用两个层面均具有价值。理论上，探索大模型在专业领域知识抽取中的应用模式，为领域自适应的信息抽取方法研究提供参考。研究成果有助于理解大语言模型在特定领域的表现特征，为提示工程和领域适配方法的发展提供实证依据。通过实验设计和结果分析，探讨大模型在教育知识抽取任务中的能力边界和优化方向，为少样本和零样本场景下的信息抽取方法研究提供参考。

应用上，研究成果可直接用于课程资源的智能化管理和个性化学习推荐。构建的知识图谱可应用于智能问答、学习路径推荐、知识点关联分析等教育场景，改善教学效果和学习体验。教师可借助知识图谱快速定位课程重点，设计更有针对性的教学内容；学生可通过知识图谱建立不同知识点之间的关联，形成完整的知识体系。研究成果还可推广至其他专业领域的知识图谱构建。

1.2 国内外研究现状

1.2.1 基于大模型的命名实体识别

近年来，利用大语言模型进行命名实体识别的方法发展迅速，研究者围绕提示设计、输出约束、数据增强等方向做了大量工作。

GPT-NER^[6] 提出了一种基于特殊标记的提示转换方法，引入 @@## 等标记符号，将 NER 任务转化为大模型易于理解的文本生成任务，并配合自验证机制提高识别准确率。该方法解决了大模型在结构化预测任务上的格式遵循问题，使模型输出可直接解析为结构化标注。实验表明，该方法在多个标准数据集上取得了与监督学习方法相当甚至更优的成绩。研究还探索了不同标记符设计对模型性能的影响，发现特定的分隔符组合能提升实体边界识别的准确性。通过自一致性检查，降低了格式错误的发生率。

SLIMER^[7] 针对少样本 NER 场景，提出了基于实体类型定义和标注指南的提示设计框架。该方法为每种实体类型提供详细的定义描述和标注规范，引导大模型更好地理解任务要求，在跨领域 NER 任务上效果好。研究还发现，为实

体类型添加具体示例和边界案例，能提升模型的识别准确率。通过负例说明，帮助模型理解哪些文本片段不应被识别为特定类型的实体，降低了误识别率。该方法的核心思路是利用人类标注知识指导模型学习，即使没有大量标注数据也能取得较好效果。

CodeIE^[8] 探索了将 Python 代码作为提示的新范式，利用代码的结构化特性引导大模型生成结构化的 NER 输出。研究表明，相比自然语言提示，代码风格的提示在结构化预测任务上具有明显优势，因为代码的语法约束能更好地引导模型生成符合格式要求的输出。该方法在零样本和少样本设置下均表现出较好的泛化能力，能够适应新的实体类型而不需要重新训练模型。代码表示还方便集成复杂的约束规则和验证逻辑，提升了抽取质量。

LLM-DA^[9] 聚焦数据增强方向，提出了基于大模型的上下文级和实体级数据增强方法。通过在上下文层面进行语义变换、在实体层面进行同义词替换和边界扰动，扩充了训练数据的多样性。该方法对缓解少样本场景下的数据稀缺问题有重要参考意义，能提升模型的鲁棒性和泛化能力。研究还提出了基于大模型的数据质量评估方法，自动筛选高质量的增强样本。通过迭代增强策略逐步扩充训练数据集，在保持数据质量的同时扩大数据规模。

1.2.2 基于大模型的关系抽取

在关系抽取领域，大语言模型同样展现了潜力，研究者在示例选择、推理机制、任务分解等方面做了大量工作。

GPT-RE^[10] 提出了一种任务感知的示例检索策略，根据输入文本与候选示例的语义相似度动态选择上下文示例，提升了少样本关系抽取的性能。该方法通过引入实体感知的示例编码机制，使模型能更好地理解与当前任务相关的上下文信息，从而在复杂的关系分类任务中取得更好效果。实验结果表明，合理的示例选择策略对最终性能的影响甚至超过了模型规模的选择。研究还探索了动态示例库更新机制，使系统能够随着运行不断积累高质量的示例。

Revisiting-RE^[11] 分析了链式思维（Chain-of-Thought, CoT）推理在关系抽取任务中的作用，发现显式引导大模型进行逐步推理能提高复杂关系的识别准确率，在涉及多跳推理的场景中尤为明显。研究还探讨了不同推理路径设计对最

终性能的影响,可供提示工程设计参考。研究发现,关系特定的推理模板比通用模板能取得更好的效果,将复杂的关系判断分解为多个简单的推理步骤,可降低模型的判断难度。

AutoRE^[12]提出了一种基于关系-头实体-事实(Relation-Head-Fact)分解的抽取范式,将复杂的关系抽取任务分解为多个子任务,降低了模型的生成难度。该方法结合了基于人类反馈的强化学习(Reinforcement Learning from Human Feedback, RLHF)训练范式,使模型输出更契合知识图谱的结构要求。实验结果表明,分解策略能减少关系抽取中的错误传播,提升端到端的抽取质量。该方法的优势在于模块化设计,每个子任务可独立优化和评估。

1.2.3 统一信息抽取与知识图谱构建

统一信息抽取框架旨在通过单一模型同时完成实体识别、关系抽取等多项任务,以提升系统的效率和一致性。

InstructUIE^[13]提出了基于指令微调的多任务信息抽取框架,通过设计统一的指令格式将不同类型的信息抽取任务转化为一致的文本到文本生成问题,实现了跨任务的知识迁移。该方法在多个信息抽取任务上取得了有竞争力的性能,显示了统一框架在多任务上的优势。研究还发布了大规模的多任务指令数据集,为后续研究提供了数据基础。通过统一编码,模型能够学习不同任务之间的共享知识,提升泛化能力。

GoLLIE^[14]延续了代码作为提示的思路,将标注指南编码为Python类型定义和约束条件,利用大模型的代码理解能力进行结构化信息抽取。该方法在零样本场景下表现出较好的泛化能力,能够适应新的实体类型和关系类型而不需要重新训练。代码形式的约束条件使模型能更准确地理解抽取任务的边界和要求,同时方便集成复杂的业务规则。该方法的优势在于可解释性强,便于调试和验证。

OneKE^[15]提出了一种多智能体协作的知识抽取架构,通过调度多个专门化的抽取智能体分别负责实体识别、关系分类、属性抽取等子任务,再由融合模块整合各智能体的输出,提升了抽取质量。该架构的优势在于能发挥不同智能体的专长,通过协作机制取得比单一模型更好的抽取效果。系统还引入了置信度

加权机制，在融合过程中优先采纳高置信度的预测结果。智能体之间的通信协议设计是该系统的主要创新。

在教育领域知识图谱构建方面，Educational-KG-Pipeline^[16] 提出了一套面向教育资源的五阶段知识图谱构建流水线，涵盖数据采集、预处理、知识抽取、知识融合和图谱存储等环节，为教育领域的知识图谱构建提供了参考方案。Graphusion^[17] 则专注于零样本知识图谱构建，提出了基于多源知识融合的图谱扩展方法，能够在无标注数据的情况下实现知识图谱的自动构建和扩展。

1.2.4 教育领域知识图谱

教育领域知识图谱研究近年来进展较快，研究者探索了多种构建和应用方法。

LLM-Curriculum-KG^[18] 探索了人机协作的课程知识建模方法，将大模型的自动抽取能力与领域专家的知识校验相结合，实现了课程知识体系的构建。该方法采用人在回路（Human-in-the-Loop）模式，在保证知识准确性的同时提升了构建效率。研究还提出了面向课程知识的专门化实体类型体系和关系模式，为教育领域的知识表示提供了参考。实验结果表明，人机协作模式相比纯自动或纯人工的方式，在效率和质量间取得了平衡。

LLMs-KG-Survey^[5] 对基于大语言模型的知识图谱技术进行了综述，分析了提示工程、指令微调、检索增强生成等技术在知识抽取、知识补全、知识推理等任务中的应用，梳理了当前研究的主要挑战和发展方向。综述强调领域适应性和知识质量控制在实践中的重要性，还建立了一套评估框架，用于比较不同方法在知识准确性、覆盖率和一致性等方面的表现。

综上，基于大语言模型的信息抽取技术发展迅速，但在面向教育领域的课程知识抽取方面，仍有研究空白。如何设计适合教育场景的领域特定提示策略、如何建立有效的知识质量保障机制、如何构建端到端的自动化处理流水线，是本文关注的问题。处理教育领域特有的复杂知识结构和多源异构数据，也需要探索可行的技术方案。本文将针对上述问题展开研究，力求提出有效的解决方案。

1.3 论文的主要内容与结构

1.3.1 论文主要内容

本文围绕基于大语言模型的课程知识命名实体识别与关系抽取展开研究，构建了面向计算机网络课程的知识图谱自动化构建系统。主要研究内容包括：

(1) 多源课程语料库构建

构建了包含 205 份 PDF 文档的多源课程语料库，涵盖教材、课件、实验指导、RFC 文档等多种类型。设计了标准化的文档预处理流程，实现从 PDF 到结构化文本的自动转换，最终生成 16,438 个文本块，总计约 1,040 万词元 (tokens)，为后续的知识抽取提供了数据基础。针对不同来源的文档特性，设计了差异化的解析策略，保障文本提取的完整性和准确性。对于包含复杂排版的技术文档，采用了专门的处理方法以保留知识结构信息。建立了文档元数据管理系统，记录每份文档的来源、类型和处理状态。

(2) 基于大模型的命名实体识别

针对课程知识的特性，定义了协议、概念、机制、性能指标四类实体类型。设计了零样本和少样本两种提示策略，通过任务特定的提示模板引导大模型识别文本中的命名实体。实验表明，该方法在没有大规模标注数据的情况下依然能达到较高的识别准确率。针对不同实体类型的特点，设计了差异化的提示模板和示例选择策略，提升了识别效果。引入了实体链接机制，将识别出的实体与标准化术语库关联，解决了实体歧义和同义词问题。

(3) 基于大模型的关系抽取

定义了包含、依赖、对比、应用于四类关系类型。提出了“提议-审核”两阶段抽取策略，第一阶段由大模型生成候选关系三元组，第二阶段通过证据验证机制确保抽取结果的准确性和可追溯性。引入了关系约束规则，对不符合逻辑的关系进行过滤，降低了错误率。设计了关系置信度评估机制，为后续的知识融合提供质量依据。对于复杂的多跳关系，设计了迭代抽取策略，逐步构建关系链。建立了关系类型层次结构，支持细粒度的关系分类。

(4) 知识抽取流水线设计

设计了涵盖文档解析、图像转换、文本识别、文本分块、知识抽取、知识融

合、图谱导入七个环节的自动化处理流水线。各模块之间通过标准化接口进行数据交换，支持灵活的配置和扩展。实现了基于配置文件的流水线编排，用户可根据需求自定义处理流程和参数设置。流水线支持断点续处理和增量更新，提高了大规模数据处理的效率。提供了详细的日志记录和进度监控功能，便于跟踪处理状态。设计了错误处理机制，对处理失败的文档自动记录并重试。

(5) 应用验证与系统实现

在计算机网络课程数据上进行了应用验证，最终构建的知识图谱包含 23,600 个实体和 44,526 个关系三元组。其中，高频实体包括 TCP 协议 (2,657 次)、UDP 协议 (1,411 次)、IP 协议 (1,020 次) 等，准确反映了课程知识的核心内容。开发了基于 Web 的可视化界面，支持知识图谱的交互式浏览和查询，验证了系统的可用性。通过多个典型应用场景的测试，验证了知识图谱在教学辅助和学习推荐中的应用。实现了与现有教学平台的集成，支持知识的动态更新和同步。

1.3.2 论文结构

上述研究内容按照“技术基础、系统设计、系统实现、实验评估”的逻辑展开，从相关技术分析出发，经方案设计与代码实现，最终通过实验验证系统的有效性。

2 相关技术基础

本章梳理课程知识命名实体识别与关系抽取的技术基础。2.1 节介绍大语言模型的核心架构与关键技术，为后续模型选型与提示工程设计提供基础；2.2 节和 2.3 节分别综述基于大模型的命名实体识别和关系抽取方法，覆盖零样本、少样本、代码提示等范式；2.4 节讨论知识图谱构建技术栈，包括流水线框架与实体规范化；2.5 节分析教育领域知识图谱的代表性方案及其局限。

2.1 大语言模型基础

大语言模型（Large Language Models, LLMs）在超大规模文本语料上进行自监督预训练，具备语言理解与生成能力。这类模型有两个关键特性：涌现能力与上下文学习能力。本节从架构原理、预训练范式和多模态扩展三个层面展开。

2.1.1 Transformer 架构

Transformer^[19] 用自注意力取代了循环结构，通过全并行计算绕过了 RNN 的串行瓶颈。其核心贡献有三点：自注意力机制（Self-Attention）、多头注意力（Multi-Head Attention）与位置编码（Positional Encoding）。

自注意力机制通过计算序列里头每个位置跟其他所有位置之间的注意力权重，让模型能够捕捉长距离的依赖关系。给定输入序列 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]$ ，自注意力的计算过程可以形式化为：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2-1)$$

其中 Q 、 K 、 V 分别代表查询（Query）、键（Key）和值（Value）矩阵， d_k 为键向量的维度。缩放因子 $\sqrt{d_k}$ 的用处在于缓解点积运算带来的梯度消失问题。自注意力机制可直接建模序列中任意两个位置之间的关系，不受距离限制，解决了 RNN 处理长序列时的梯度消失问题。

多头注意力机制将输入投影到多个子空间并行计算注意力，使模型从不同表示子空间中联合关注不同位置的信息。设有 h 个注意力头，那么多头注意力

的输出就是：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2-2)$$

其中每个 $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$, W 为可学习的投影矩阵。多头机制让模型在不同子空间中关注不同类型的信息，如语法结构与语义关系，提升了模型的表达能力。不同注意力头确实学到了不同的语言特征：有的关注句法依赖，有的关注语义关联。

由于 Transformer 不含循环或卷积结构，引入位置编码以注入序列的顺序信息。原始 Transformer 采用正弦余弦函数来编码绝对位置：

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}}) \quad (2-3)$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}}) \quad (2-4)$$

后来的工作表明，可学习的绝对位置编码和相对位置编码在特定任务上表现更好。RoPE (Rotary Position Embedding) 和 ALiBi (Attention with Linear Biases) 等相对位置编码方案在处理长序列时外推能力更强，可以支撑更长的上下文窗口。

2.1.2 预训练语言模型与上下文学习

在 Transformer 架构基础上，预训练语言模型形成了编码器和解码器两条主要技术路线。BERT 采用双向 Transformer 编码器和掩码语言模型任务进行预训练，使模型能够同时利用左右上下文信息，推动了自然语言理解任务的发展^[20]。GPT (Generative Pre-trained Transformer) 系列模型则采用自回归语言建模范式进行预训练。这种范式通过最大化序列的似然概率来学习语言表示，也就是：

$$\mathcal{L} = \sum_{i=1}^n \log P(x_i | x_1, \dots, x_{i-1}; \theta) \quad (2-5)$$

这种单向建模方式使得 GPT 系列模型特别擅长文本生成任务。预训练阶段，模型在大规模无标注语料上学习语言的统计规律和语义表示；下游任务中，再通过微调或提示工程将预训练知识迁移至特定应用场景。

GPT-3 拥有 1750 亿参数，展示了上下文学习能力 (In-Context Learning)^[21]。上下文学习指模型不更新参数，仅凭输入中的少量示例即可适应新任务。这种能力源于预训练过程中对多样任务的隐式学习，模型通过示例模式泛化到待预测样本上。GPT-3 在翻译、问答、摘要等任务上的性能接近监督学习方法，表明

大模型有潜力作为通用任务求解器。

上下文学习的有效性高度依赖提示 (Prompt) 的设计。Brown 等人发现, 借助精心设计的任务描述和示例, GPT-3 在多项自然语言理解任务上达到了接近微调模型的水平。这一发现催生了提示工程 (Prompt Engineering) 研究方向。后续工作分析了上下文学习的内在机制, 包括示例选择策略、示例顺序的影响和标签空间覆盖的重要性等因素。

2.1.3 提示工程技术

提示工程是优化大语言模型输入以提升任务性能的一整套技术体系。按照所需示例的数量来分, 提示策略可以分为零样本 (Zero-Shot)、少样本 (Few-Shot) 和思维链 (Chain-of-Thought) 三种范式。

零样本提示向模型提供任务描述与待处理输入, 无需任何标注示例, 适用于快速原型验证和资源受限的场景。对于复杂任务, 零样本提示的性能通常不足。指令微调 (Instruction Tuning) 通过在多样化的指令-响应对上微调模型, 让模型更好地理解 and 执行新指令, 从而改善了零样本性能。

少样本提示在输入中嵌入若干标注示例, 引导模型理解任务模式。示例的选择、顺序和格式对性能影响很大。有效的少样本提示应确保示例与测试样本在分布上保持一致, 并覆盖任务的主要变化模式。KATE、EPR 等方法通过检索与测试样本相似的示例来优化提示; Self-Generated In-Context Learning 则让模型自己生成示例, 降低对人工标注的依赖。

思维链提示由 Wei 等人提出, 通过在示例中展示中间推理步骤, 激发模型的逐步推理能力。该方法将复杂问题拆分为一系列可解释的推理步骤, 提升了模型在算术推理、常识推理和符号推理任务上的表现。后续工作在此基础上发展出自一致性解码 (Self-Consistency)、思维树 (Tree of Thoughts) 等增强技术。自一致性通过多次采样并选出最一致的答案来提升推理可靠性; 思维树则通过探索多条推理路径并评估各路径的可行性, 实现更复杂的决策过程。

2.1.4 多模态大语言模型

多模态大语言模型 (Multimodal LLMs) 将纯文本模型的能力扩展到视觉、音频等多种模态, 使模型能够理解并生成多模态内容。在知识抽取领域, 视觉-语言模型 (Vision-Language Models) 尤其重要, 因为它可以直接处理扫描文档、幻灯片等图像格式的课程材料, 无需额外的 OCR 预处理步骤。

典型的视觉-语言模型架构包含视觉编码器、投影层和语言模型三个部分。视觉编码器 (如 ViT、CLIP) 将输入图像编码为视觉特征序列; 投影层负责将视觉特征映射到语言模型的语义空间; 语言模型基于融合后的多模态表示生成文本输出。早期视觉-语言模型如 BLIP、Flamingo 等通过端到端训练实现跨模态对齐; LLaVA、Qwen-VL 等工作采用两阶段训练策略: 先进行视觉-语言对齐预训练, 再进行指令微调, 使模型能够遵循指令。

Qwen-VL、InternVL 等模型在文档理解、图表解析等任务上表现好, 可直接用于教育材料自动化处理。这些模型能识别图像中的文本内容、理解版面布局、解析表格和图示结构, 提升了从非结构化文档中提取结构化信息的能力。对于包含复杂排版和数学公式的学术材料, 多模态模型的端到端处理能力优于传统的 OCR 加文本处理流水线。

2.2 基于大模型的命名实体识别

命名实体识别 (Named Entity Recognition, NER) 的目标是从非结构化文本中识别命名实体并对其分类。传统方法依赖大量标注数据和特定领域的特征工程, 而基于大模型的方法借助提示工程实现了低资源、甚至零资源场景下的实体识别。按照利用训练数据的方式, 现有方法分为零样本、少样本和代码提示三类范式^[22]。

2.2.1 零样本命名实体识别

零样本 NER 指在没有任何标注样本的情况下, 仅靠任务描述和实体类型定义完成实体识别, 适用于快速适应新领域、新实体类型。SLIMER^[7] 用丰富的实体定义和标注指南弥补训练数据的缺失, 采用单实体类型每查询 (Single Entity

Type Per Query) 策略, 将多类型 NER 任务拆分为多个二分类子任务, 降低了任务复杂度。该方法通过详细的类型描述、边界说明和示例指导模型做精确识别, 在多个基准数据集上比传统零样本方法更好。

UniversalNER 探索了运用 ChatGPT 进行自动标注并蒸馏到小模型的技术路线^[23]。该方法先用 ChatGPT 生成大规模弱监督数据, 再通过知识蒸馏将大模型的能力迁移到轻量级学生模型上。具体来说, UniversalNER 设计了一系列针对 NER 任务的提示模板, 引导 ChatGPT 生成高质量的伪标注数据, 然后使用这些数据训练专门的 NER 模型。实验表明, 这种范式在开放域 NER 任务上有竞争力, 同时降低了推理成本。

GLiNER 提出了一种基于双向 Transformer 的实体-跨度匹配架构^[24]。与传统序列标注方法不同, GLiNER 将 NER 建模为实体类型与文本跨度之间的匹配问题, 通过计算类型表示和跨度表示的相似度预测实体边界和类型。GLiNER 将实体类型视为可学习的嵌入, 使其泛化到训练时未见过的全新类型, 在零样本和少样本场景下均有效, 支持任意实体类型的灵活扩展。

2.2.2 少样本命名实体识别

少样本 NER 利用少量标注示例引导大模型适应特定领域和实体类型。GPT-NER^[6] 使用 @@ 和 ## 标记实体边界, 将 NER 转化为大模型擅长的文本生成任务。这种标记方式与 GPT 模型的预训练目标更契合, 能更好地激发模型的标注能力。GPT-NER 还引入了三层次演示检索策略, 分别从句子级、实体级和词级检索相似示例, 确保示例在多个粒度上与测试样本相关。此外, GPT-NER 通过自验证机制过滤低质量预测结果, 提高了输出的可靠性。

Self-Improving NER^[25] 通过自一致性投票和可靠性筛选实现模型性能的自我迭代提升。该方法先用不同提示变体生成多组预测结果, 通过一致性投票找出高置信度预测; 再基于可靠性指标筛选优质伪标签用于下一轮训练。这种自举式学习策略降低了对人工标注的依赖, 使模型从自身的预测中持续学习和改进。经过若干轮迭代后, 模型性能持续提升, 在某些任务上接近全监督方法的表现。

LLM-DA (LLM-based Data Augmentation) 从上下文和实体两个层面进行数据增强^[9]。上下文层面运用大模型生成与原始句子语义相似的变体, 同时保持实

体位置不变；实体层面通过实体替换和同义词扩展来丰富实体表达的多样性。增强后的数据与原始少样本数据联合训练，提升了模型的泛化能力。LLM-DA 借助大模型的语言理解能力进行语义保持的数据增强，生成的样本质量优于传统基于规则的增强方法。

2.2.3 代码提示范式

Code-as-Prompt 是一类较新的提示范式，将信息抽取任务表示为代码形式，利用大模型的代码理解能力提升任务性能。CodeIE^[8] 将 NER 和关系抽取任务转化为 Python 代码生成任务。实体识别被建模为从文本中提取特定类型值的函数实现，关系抽取被建模为返回实体对的函数。实验表明，代码形式的提示在自然语言理解任务上优于纯文本提示，这可能与代码的结构化特性以及大模型在代码预训练中获得的能力有关。代码表示能更清晰地表达任务的结构和约束条件，减少了自然语言歧义带来的理解偏差。

GoLLIE 扩展了代码提示范式^[14]，引入 Python 类定义来表示实体和关系的模式 (Schema)。每个实体类型和关系类型被定义为具有特定属性和文档字符串的 Python 类，文档字符串中详细描述了类型的定义和标注指南。这种表示方式将模式定义与提示模板统一起来，支持复杂嵌套结构的抽取。GoLLIE 在多个 IE 基准测试上达到了当时的 SOTA。KnowCoder^[26] 在此基础上构建了大规模代码风格知识模式库，通过代码预训练与指令微调两阶段学习，将通用预训练的知识抽取能力迁移到特定领域。

2.3 基于大模型的关系抽取

关系抽取 (Relation Extraction, RE) 的目标是识别文本中实体之间的语义关系。与命名实体识别相比，关系抽取需要建模实体对之间的复杂交互，任务难度更高。基于大模型的关系抽取方法在少样本和零样本场景下有优势，可借助预训练知识快速适应新的关系类型和领域。

2.3.1 少样本关系抽取

GPT-RE 针对少样本关系抽取提出了任务感知演示检索和金标签诱导推理两种技术^[10]。任务感知检索基于实体对和关系标签的联合相似度选择演示示例，确保示例与查询在实体分布和关系模式上高度一致；金标签诱导推理在提示中显式引导模型关注实体提及的位置，并通过标签的语义信息约束预测空间。两种技术的结合使 GPT-RE 在 FewRel 等基准上性能提升明显。GPT-RE 还探讨了不同检索策略和提示格式对性能的影响。

Self-Prompting^[27] 通过三阶段流程实现自动化的少样本关系抽取。第一阶段运用大模型生成多样化的合成样本，覆盖关系类型的多种表达模式；第二阶段对生成的样本进行质量筛选和去重，保留高质量的伪标注数据；第三阶段基于筛选后的样本自动构建提示模板，无需人工设计。这种自引导方法降低了对人工编写示例的依赖。Self-Prompting 的核心洞察在于，大模型本身具备生成合理训练样本的能力，通过适当的引导和筛选，可构建有效的自我监督流程。

2.3.2 文档级关系抽取

文档级关系抽取需要处理跨越多个句子的长文本，识别显式提到或隐式蕴含的实体关系。这项任务比句子级关系抽取更具挑战性，需要建模复杂的指代消解和跨句推理能力。AutoRE 提出了关系-头部-事实 (Relation-Head-Fact, RHF) 的统一范式^[12]，将关系抽取分解为关系识别、头部实体定位和事实抽取三个子任务。该方法采用 QLoRA 进行参数高效微调，在 DocRED 等文档级基准上性能好。RHF 范式将复杂的文档级关系抽取分解为多个更易管理的子任务，降低了学习难度，同时提升了可解释性。

Revisiting-RE 系统分析了文档级关系抽取中的关键挑战^[11]，提出将思维链增强和人工评估相结合的混合策略。直接使用大模型进行文档级关系抽取会面临实体指代消解困难和长距离依赖建模复杂等问题；引入逐步推理提示和人工反馈的迭代优化可缓解这些难题。该工作特别在评估协议和错误分析方面做了深入探讨，指出了当前方法的局限性与改进方向。

2.3.3 零样本关系抽取

GLiREL 延续了 GLiNER 的设计理念，将零样本关系抽取建模为关系类型与实体对之间的匹配问题^[28]。该模型选用轻量级双向 Transformer 架构，单次前向传播即可计算所有候选实体对和关系类型的匹配分数，实现了高效推理。GLiREL 支持任意关系类型的灵活扩展，无需针对新类型重新训练，实用性高。该方法将关系类型编码为可学习的嵌入向量，通过计算实体对表示与关系类型表示的兼容性来预测关系。

REPaL (Relation Extraction with Pairwise Loss) 探索了仅靠关系定义完成零样本抽取的可能性^[29]。该方法运用大模型生成关系定义的语义嵌入，通过对比学习使相关实体对的表示靠近、无关实体对的表示远离。REPaL 在零样本文档级关系抽取任务上性能领先，证明关系定义本身蕴含丰富的语义信息。REPaL 完全不依赖标注样本，仅凭关系类型的自然语言描述即可进行抽取，适合快速搭建原型系统以及处理新增的关系类型。

2.4 知识图谱构建技术

知识图谱构建涉及实体识别、关系抽取、实体链接、知识融合等多个环节。近年来，大语言模型凭借其语义理解能力，在知识图谱构建各环节中得到了应用。本节从流水线框架和实体规范化两个方向介绍相关技术进展^[30-31]。

2.4.1 流水线框架

LLMs-KG-Survey 系统综述了运用大模型构建知识图谱的研究进展^[5]。该综述将现有方法分为自主构建和协同构建两类，分析了各类方法的优势和局限。此外，AutoKG 多智能体框架通过规划、抽取、验证、修正等多个智能体之间的协作，实现了端到端的知识图谱构建。AutoKG 采用模块化设计，各智能体专注于特定子任务并通过消息传递进行协作，提升了系统的可扩展性和鲁棒性。

InstructUIE 采用多任务指令微调策略统一处理信息抽取任务^[13]。该方法将 NER、关系抽取、事件抽取等多种任务统一为文本到文本的生成任务，借助自然语言指令描述任务需求。指令微调使模型具备任务泛化能力，在未见过的任务

类型和领域上仍能维持合理性能。

OneKE 提出了基于 Schema 引导的多智能体知识抽取框架^[15]。该框架先用大模型从领域文档中自动抽取 Schema 定义，再基于 Schema 指导抽取智能体识别实体和关系，最后通过验证智能体保证抽取结果的一致性和完整性。OneKE 在教育、医疗等垂直领域适应性好。RUIE^[32] 从检索增强的角度探索了统一信息抽取，通过双编码器检索器配合 LLM 偏好评分实现跨任务的演示检索，在低资源场景下降低了模型微调成本。

2.4.2 实体规范化

实体规范化 (Entity Canonicalization) 的目标是识别指代同一现实实体的不同提及方式，是知识图谱构建的重要环节。EDC 提出了抽取-定义-规范化的三阶段方法^[33]：先从文本中抽取候选实体，再运用大模型为每个实体生成语义定义，最后基于定义相似度进行实体聚类 and 规范化。该方法处理了实体表达的多样性问题。通过引入语义定义作为中间表示，EDC 能捕捉实体提及的深层语义信息，而不只是依赖表面的字符串相似度。

KGGen 探索了聚类和大模型混合迭代的实体去重策略^[34]，先用传统聚类算法进行初步分组，再运用大模型对每个聚类进行语义审核和合并决策，迭代直至收敛。这种混合策略兼顾了效率和准确性，在大规模知识图谱构建中效果好。KGGen 将传统聚类的高效性与大模型的语义理解能力相结合，通过迭代优化提升了规范化质量。

SAC-KG 设计了生成器-验证器-剪枝器的三组件架构^[35]。生成器负责从源文本中抽取候选实体和关系；验证器基于大模型评估三元组的事实性和一致性；剪枝器移除低质量或重复的三元组。三个组件协同工作，确保知识图谱的高精度和低冗余。LOKE^[36] 从开放知识抽取与实体链接的角度提出了另一种方案，通过编辑距离算法将抽取的三元组链接到 Wikidata，在保障三元组完整性的同时实现了实体可链接性。

2.5 教育领域知识图谱

教育领域知识图谱面向课程教材、学术论文等教育资源，旨在构建结构化的学科知识体系，支撑智能问答、学习路径推荐等教育应用。与通用领域知识图谱相比，教育领域知识图谱的概念层次更清晰、知识关联更密集、应用场景更特定。本节梳理近年来教育领域知识图谱构建的代表性工作。

国内研究也开始从智能教育角度讨论知识图谱与大语言模型的协同共生关系，认为知识图谱可为大模型提供结构化知识约束，而大模型可降低知识图谱构建与维护成本^[37]。这与本文面向课程材料自动抽取知识并进行证据约束的技术路线一致。

Educational-KG-Pipeline 提出了面向教育资源的五阶段知识图谱构建流水线^[16]，包括文档解析、实体识别、关系抽取、实体链接和知识融合，针对 PDF、PPT 等格式的课程材料进行了专门优化。文档解析阶段处理了教育材料中常见的复杂版面和多媒体元素；后续阶段针对教育领域的实体类型和关系模式设计了专门的抽取策略。在计算机网络课程数据集上，该流水线将 F1 分数从 40% 提升至 47%。

Graphusion 专注于概念知识图谱的构建^[17]，采用种子概念扩展、候选三元组生成、全局融合的三阶段策略。该方法从少量人工标注的种子概念出发，运用大模型自动发现相关概念和关系；借助全局一致性约束解决冲突和冗余问题；最后构建了 TutorQA 基准数据集用于教育问答评估。Graphusion 在概念覆盖度和关系准确性方面表现好。该工作通过种子引导和自动扩展减少了对大规模人工标注的依赖，是一种低成本的概念图谱构建方法。

LLM-Curriculum-KG 探索了人机协作的课程知识图谱构建模式^[18]，设计了课程-领域-用户三层本体结构：课程层描述课程大纲和章节组织，领域层涵盖学科概念和知识关联，用户层记录学习者的知识状态和学习轨迹。大模型负责自动抽取和初步验证，人工专家进行质量审核和领域知识补充。这种人机协作模式兼顾了大模型的自动化处理能力和人类专家的专业判断。

2.6 本章小结

本章梳理了课程知识命名实体识别与关系抽取的关键技术。大语言模型部分聚焦 Transformer 的自注意力机制、GPT 系列的自回归预训练范式，以及多模态视觉-语言模型；命名实体识别部分对比了零样本、少样本和代码提示三类范式的核心思路与适用场景；关系抽取部分讨论了句子级与文档级场景下的任务感知检索、自引导提示与零样本匹配等方法；知识图谱构建部分介绍了流水线框架与实体规范化技术；教育领域部分分析了现有知识图谱方案的特点与局限。

3 课程知识抽取系统设计

课程教材层级结构深、术语密集、中英文混用，从中抽取实体和关系比通用场景更容易出错。本章从需求分析入手，明确系统的功能边界与约束条件；随后给出总体架构设计，再按文档预处理、文本分块、实体识别、关系抽取、知识融合、图存储与可视化六个设计模块，逐一说明设计决策和取舍理由。

3.1 总体架构设计

3.1.1 七阶段流水线架构

系统采用七阶段串行流水线，将原始教材逐步转化为可交互的知识图谱。七个阶段依次是：文档转图、OCR 识别、文本分块、三元组抽取、三元组合并、图数据库导入以及前端可视化，如图3-1所示。




图 3-1 七阶段流水线总体架构

选择七阶段串行架构，主要出于三点考虑：

(1) **关注点分离**。每个阶段拥有明确的输入契约和输出契约，职责单一。文档转图阶段只负责将 PDF/PPT 渲染为 PNG 图像，不关心后续 OCR 如何处理；OCR 阶段只负责图像到文本的转换，不关心文本如何分块。各阶段的独立性使其可以分别设计、测试与演进。

(2) **模块化与可替换性**。每个阶段对应一个独立的 CLI 命令（pdftopng、pngtotext、mdchunk 等），阶段之间通过文件系统中间产物（PNG、Markdown、JSON）传递数据。保持输入输出格式不变，任何阶段都可以替换实现。例如 OCR 阶段可从 VLM 切换为传统 OCR 引擎，无需改动上下游代码。

(3) **独立扩展与容错**。中间产物持久化存储在 data/ 目录下，流水线天然具备断点续跑能力。若某阶段因 API 限流或网络故障中断，重新运行该阶段即可

从中断点继续，无需从头开始。此外，不同阶段对计算资源的需求差异悬殊——OCR 阶段依赖 GPU 加速的多模态推理，分块阶段仅需 CPU 计算——独立阶段使资源可按需分配。

3.1.2 LLM 工厂模式

系统内多个阶段需要调用大语言模型，涉及 OCR、实体抽取、关系审核与实体嵌入等任务，各阶段对模型能力、速率限制和提示词策略的要求不同。为此，系统设计了 LLM 工厂模式 (TaskLLMFactory)，采用任务作用域的配置隔离。

每个任务 (ocr、extract、entity_embed 等) 通过 llm_profile 字段引用一个预定义的模型配置档案 (Profile)，档案内包含模型名称、API 端点、模态 (text/multimodal/embedding)、请求超时、重试策略及速率限制参数。切换模型时只需修改配置文件中的 Profile 引用，无需改动任何代码。

速率限制采用滑动窗口算法 (RollingRateLimiter)，维护 60 秒时间窗口内的请求计数，达到 RPM 上限后阻塞等待。并发控制通过信号量 (Semaphore) 实现，确保同时运行的 LLM 请求数不超过 max_concurrency。不同任务的速率限制参数可独立配置：OCR 任务使用 qwen3-v1-8b 模型，设为 RPM 100、并发 10；抽取任务使用 deepseek_v4_flash 模型，设为 RPM 3000、并发 3000，以匹配不同模型的配额和吞吐能力。

3.2 需求分析

本课题的目标是构建一个面向计算机网络课程的自动化知识图谱构建系统。在系统设计之前，需要明确系统的功能边界、用户交互方式、模块间接口约定以及非功能性约束。

3.2.1 功能需求

系统需覆盖从原始课程文档到可交互知识图谱的完整处理链路。

文档处理能力。系统应支持 PDF 讲义、PPT/PPTX 课件等多格式课程材料的

输入，自动完成页面渲染与文本提取，输出结构化 Markdown 文本。需处理包含中英文混排、数学公式、网络拓扑图等复杂版面的技术文档。

知识抽取能力。系统应从课程文本中自动识别预定义类型的命名实体和实体间的语义关系。实体类型至少覆盖协议名称 (protocol)、概念术语 (concept)、机制算法 (mechanism) 和性能指标 (metric) 四类；关系类型至少覆盖包含 (contains)、依赖 (depends_on)、对比 (compared_with) 和应用 (applied_to) 四类。抽取结果应附带原文证据，保证可追溯性。

知识融合能力。系统需处理跨文档抽取带来的实体冗余与名称变体问题，将同一实体的不同表述（如中英文全称与缩写）归一为标准名称。支持别名映射与语义嵌入两种规范化策略。

图存储与可视化能力。融合后的知识图谱应导入 Neo4j 图数据库持久化存储，并通过 Web 前端提供交互式浏览功能，支持节点过滤、关系导航和缩放查看。

3.2.2 界面（人机交互）需求

系统的目标用户为课程教师和学生。主要交互方式分为命令行工具和 Web 可视化界面两类。

命令行接口。各处理阶段以独立 CLI 命令暴露（如 pdftopng、pngtotext、kgextract 等），通过 config.yaml 统一配置模型参数和速率限制。用户可选择性执行特定阶段，利用中间产物实现断点续跑。

Web 可视化界面。前端提供力导向图布局的知识图谱浏览，支持：按实体类型和关系类型多维度过滤；缩放感知的节点标签显示；多边关系曲线的视觉区分；点击节点查看实体描述和关联证据。

3.2.3 接口（模块对外）需求

系统内部模块间通过文件系统交换数据，各阶段的输入输出格式约定如下：

文档渲染 → OCR： PNG 图像序列，按书籍分目录存储。

OCR → 文本分块： 结构化 Markdown 文本，标题使用 # 标记层级。

文本分块 → **知识抽取**: JSON chunks 数组, 每块包含文本内容、所属标题层级和 Token 计数。

知识抽取 → **知识融合**: JSON 三元组文件, 每文件包含实体列表 (含名称、类型、描述) 和关系列表 (含头尾实体、关系类型、证据字段)。

知识融合 → **图数据库**: 标准化的 merged_triples.json, 包含去重后的实体集合和关系集合。

图数据库 → **前端**: RESTful API (/api/graph), 返回节点数组和边数组的 JSON 格式。

3.2.4 性能等非功能需求

处理效率。单份 PDF 文档的处理时间应控制在分钟级, 整体流水线可在数小时内完成数百份文档的端到端处理。OCR 与知识抽取阶段采用并发处理, 充分利用 API 允许的并发配额。

可扩展性。流水线各阶段解耦, 任一阶段可独立替换实现而无需修改上下游代码。支持通过配置文件切换模型、调整 Token 预算和速率限制。新增实体类型或关系类型仅需修改 Schema 定义和提示词模板, 无需改动代码逻辑。

可靠性。API 调用失败时支持指数退避重试; 中间产物持久化存储, 支持断点续跑; 各阶段提供详细日志记录, 便于追踪处理进度和定位故障。

知识质量。所有关系三元组必须附带可验证的原文证据, 证据门控机制自动过滤无依据的虚假关系。实体规范化确保同一实体的不同表述被正确合并, 降低知识图谱的冗余度。

3.3 文档预处理设计

3.3.1 多格式文档输入

课程教材的原始格式包括 PDF 讲义、PPT 课件和 PPTX 演示文稿。系统将这些异构格式统一转换为 PNG 图像序列, 作为 VLM OCR 的标准化视觉输入。

对于 PDF 文件, 使用 PyMuPDF (fitz 库) 进行页面渲染。选择 PyMuPDF 而非 pdf2image (底层为 Poppler) 的原因有三: PyMuPDF 无需系统级安装 Poppler

依赖，部署更轻量；渲染速度远超 Poppler，批量处理数百页教材时优势突出；提供精确的 DPI 控制和矩阵变换接口，便于调整输出质量。渲染参数设为 $DPI=200$ ，缩放因子 $zoom = 200/72 \approx 2.78$ ，在文字清晰度与文件体积之间取得平衡。

对于 PPT/PPTX 文件，使用 LibreOffice 无头模式 (headless) 先转换为临时 PDF，再经 PDF 渲染器统一处理。LibreOffice 对 Microsoft Office 格式的兼容性优于其他开源方案，转换后的 PDF 保留原始幻灯片的版式和字体信息，确保 VLM OCR 阶段获得高质量视觉输入。

3.3.2 基于视觉语言模型的 OCR 设计

传统 OCR 引擎（如 Tesseract）对中文教材中数学公式、网络拓扑图和表格等复杂版面元素的识别能力有限。系统使用多模态视觉语言模型 (VLM) 作为 OCR 核心引擎，具体使用 Qwen3-VL-8B 模型，通过 PPIO API 以 OpenAI 兼容接口调用。

采用 VLM 进行 OCR 有三方面优势：(1) 模型具备视觉理解能力，可识别图表中的文字标注和网络拓扑结构的节点标签；(2) 原生支持中文文本识别，无需额外配置语言包；(3) 可根据版面特征推断标题层级，输出结构化 Markdown，供后续分块阶段使用。

OCR 提示词设计要求：输出须为有效 Markdown；保持原文语言不翻译；保留阅读顺序和换行；标题行使用 # 标记并遵循层级规则（# 一级、## 二级、### 三级）；对中文教材中常见的章节结构词（如“第 X 章”“第 X 节”）进行标题化处理。每页 OCR 结果保存为独立 Markdown 文件，由 kgmdcombine 阶段按页码顺序合并为完整的教材级 Markdown 文档，确保跨页内容的连贯性。

3.4 文本分块设计

3.4.1 分块问题的提出

大语言模型的上下文窗口通常限制在 4K–8K tokens。一本完整的计算机网络教材可能包含数十万 tokens，无法一次性输入 LLM。因此需要将教材级 Markdown 文档拆分为适当大小的文本块，每个块在 Token 预算内须包含足够的

上下文信息，使 LLM 能够准确识别其中的实体和关系。

分块策略的核心张力在于：块过大会超出 Token 预算，块过小则丢失上下文信息、降低抽取质量。此外，课程教材的层级结构（章、节、小节）较为清晰，在标题边界处切分有助于保持语义完整性；若在段落中间切分，则可能割裂实体间的关联。

系统使用 tiktoken 库的 `cl100k_base` 编码进行精确的 Token 计数。选择该编码而非字符数或词数计数的原因是：`cl100k_base` 是 GPT-4 系列模型使用的分词器，与实际 LLM 调用的 Token 计量方式一致，避免了计数偏差造成的截断或浪费。

Token 预算设为 $T_{max} = 4000$ 。LLM 的有效上下文窗口约 8K tokens，其中约 2K tokens 预留给系统提示词（Schema 定义、抽取指南、Few-shot 示例等）和模型输出（候选实体与三元组的 JSON）。从剩余的约 6K tokens 中取 4000 作为文本块上限，保留约 2K tokens 的安全余量以应对计数偏差。

3.4.2 递归标题感知分块算法

分块算法**优先在标题边界切分，无标题可分时才退至段落级别**。算法先将 Markdown 文档解析为标题树，再自顶向下递归处理每个子树。若某子树的 Token 总数未超出预算，则将其整体输出为一个块；若超出预算且存在子标题，则递归降至子标题层继续处理；若超出预算且无子标题可分，则在段落级别累积切分。

算法3-1统一表达了标题树构建、递归判定和段落级兜底切分过程。几个关键设计决策包括：（1）标题层级信息保留在每个输出块的元数据（*titles* 字段），供下游抽取阶段做上下文定位；（2）清洗步骤在分块之前执行，避免 OCR 伪影（如页码、页眉）污染文本块内容；（3）段落级累积切分作为兜底手段，确保即使没有标题结构的长文本也能正确分块。

分块流程如算法3-1所示。

算法 3-1 递归标题感知分块算法

Input: Markdown 文档 M , 最大 Token 数 T_{max}

Output: 分块列表 $C = [c_1, c_2, \dots, c_n]$

```
1: 清洗  $M$ : 去除 YAML 前置元数据、页码标记、页眉页脚等 OCR 伪影
2: 构建标题树  $H \leftarrow \text{parse\_headers}(M)$ 
   使用栈式解析 # 标记
3:  $C \leftarrow \text{chunk\_recursive}(H, T_{max})$ 
4: return  $C$ 

5: function  $\text{chunk\_recursive}(\text{node}, T_{max})$ 
6:   if  $\text{token\_count}(\text{node.content}) \leq T_{max}$  then
7:     return  $\{\text{node}\}$  ▷ 子树整体作为一个块
8:   else if  $\text{node}$  存在子标题节点 then
9:      $\text{result} \leftarrow []$ 
10:    for each 子标题节点  $\text{child} \in \text{node.children}$  do
11:       $\text{result} \leftarrow$ 
         $\text{result} \cup \text{chunk\_recursive}(\text{child}, T_{max})$ 
12:    end for
13:    return  $\text{result}$ 
14:  else
15:     $\text{chunks} \leftarrow [], \text{current} \leftarrow [], \text{tokens} \leftarrow 0$ 
16:    for each 段落  $p \in \text{node.paragraphs}$  do
17:      if  $\text{tokens} + \text{token\_count}(p) > T_{max}$  and  $\text{current} \neq \emptyset$  then
18:         $\text{chunks} \leftarrow \text{chunks} \cup \{\text{current}\}$ 
19:         $\text{current} \leftarrow [p], \text{tokens} \leftarrow \text{token\_count}(p)$ 
20:      else
21:         $\text{current} \leftarrow \text{current} \cup \{p\}, \text{tokens} \leftarrow \text{tokens} + \text{token\_count}(p)$ 
22:      end if
23:    end for
24:    return  $\text{chunks}$ 
25:  end if
26: end function
```

3.5 实体识别设计

实体识别是知识图谱构建的基础环节，目标是从课程文本中识别属于预定义类型的命名实体。与通用 NER 任务不同，课程知识 NER 需要处理领域特定的实体类型，且实体边界常跨越多个词汇（如“三次握手”“慢启动算法”等）。

系统定义了四种实体类型，覆盖计算机网络课程的核心知识元素。类型定义如表3-1所示。

表 3-1 实体类型 Schema 定义

类型标识	中文名称	定义	示例
protocol	协议	网络通信中遵循的规则或标准	TCP, HTTP, DNS, ARP, OSPF
concept	概念术语	计算机网络中的核心概念或术语	拥塞控制, 子网掩码, 路由表, 分层模型
mechanism	机制算法	具体的机制、算法或流程	三次握手, 慢启动, CSMA/CD, 滑动窗口
metric	性能指标	网络性能的度量指标	吞吐量, RTT, 丢包率, 带宽, 时延

Schema 设计遵循三项原则：（1）**互斥性**——四种类型在语义上互不重叠。协议与机制的区别在前者为通信标准、后者为操作流程，概念与指标的区别在前者为抽象术语、后者为可量化度量；（2）**完备性**——四种类型覆盖了计算机网络教材中的绝大多数知识元素，从协议标准到性能度量构成完整的知识维度；（3）**可操作性**——每种类型配有明确的判定规则和典型示例，降低 LLM 抽取时的歧义。

3.5.1 提示词工程设计

系统设计了两套抽取模式：零样本（Zero-shot）模式和少样本（Few-shot）模式。两种模式共用同一套 Schema 定义，但提示词策略不同。

零样本模式受 SLIMER^[7] 思路启发，在提示词中提供详细的实体类型定义、边界规则和抽取指南，不提供标注示例。零样本提示词包含三个核心组件：（1）Schema 定义——四种实体类型的名称、定义及示例；（2）抽取规则——仅从给定文本中抽取、不编造实体、使用原文中的名称；（3）输出格式约束——严格 JSON 输出，包含实体列表和三元组列表。零样本模式无需人工标注数据，适用

于快速启动和 Schema 调试阶段。

少样本模式在零样本基础上增加四个标注示例，分别覆盖四种关系类型 (compared_with、contains、depends_on、applied_to)，同时附带负面示例和粒度规则。这一设计借鉴了 GPT-RE^[10] 的少样本检索增强思路和 GoLLIE^[14] 的指令微调策略。少样本模式的设计逻辑：(1) 标注示例可提升 LLM 对 Schema 的理解精度，减少类型混淆——例如将“TCP 拥塞控制”整体标为单一实体，而非拆分为 TCP (protocol) 和拥塞控制 (concept)；(2) 负面示例 (“不抽过泛词：计算机、网络、系统”等) 可抑制 LLM 的过度抽取倾向；(3) 粒度规则 (“优先拆分协议 + 概念复合短语”) 可提升跨文档抽取的一致性。

3.5.2 实体描述生成

每个抽取出的实体除名称和类型外，还要求 LLM 生成一段简短描述 (description 字段)。例如，实体“TCP”的描述为“传输控制协议”，“慢启动算法”的描述为“拥塞窗口逐步增长机制”。引入描述字段有两重目的：(1) 为下游知识融合阶段提供语义信息——当两个名称不同但语义相同的实体需要合并时，描述信息可辅助判断；(2) 为知识图谱的交互式浏览提供可读的节点信息，提升用户体验。

3.6 关系抽取设计

关系抽取在实体识别的基础上，识别实体之间的语义关联，形成结构化的知识三元组 (head, relation, tail)。关系抽取的质量直接决定知识图谱的连通性和可用性。

系统定义了四种关系类型，每种都附带了头尾实体类型的约束条件，如表3-2所示。

关系类型系统的设计逻辑如下：(1) contains 不设类型约束，因为包含关系在课程知识中普遍存在——如“TCP 包含三次握手”“OSI 模型包含物理层”——过严的约束反而会遗漏有效关系；(2) depends_on 将头实体限定为 mechanism 或 concept，因为依赖关系描述的是机制或概念对其他知识元素的依赖；(3)

表 3-2 关系类型 Schema 定义

关系类型	中文名称	定义	头 → 尾类型约束
contains	包含关系	A 在结构或概念上包含 B	any → any
depends_on	依赖关系	A 在功能上依赖 B	mechanism/concept → mechanism/protocol
compared_with	对比关系	A 与 B 在功能或性能上可比较	protocol ↔ protocol, concept ↔ concept
applied_to	应用关系	A 被应用于 B 的场景	mechanism → protocol/concept

compared_with 限定为同类型实体间的对比（如 TCP 与 UDP、OSI 与 TCP/IP），避免跨类型的无意义对比；（4）applied_to 将头实体限定为 mechanism，因为“应用”关系描述的是机制或算法被应用到特定协议或概念的场景。

3.6.1 两阶段抽取架构

系统采用“提议—审核”（Propose-Review）两阶段抽取架构，如图3-2所示。




图 3-2 两阶段抽取与证据门控流程

阶段一（提议）：LLM 接收文本块和完整的 Schema 定义（实体类型、关系类型、抽取规则），以及对应模式的提示词（零样本或少样本），输出候选实体列表和三元组列表。此阶段侧重召回率——尽可能识别文本中存在的实体和关系，允许一定程度的噪声。

阶段二（审核）：通过一次独立的 LLM 调用，对每个候选三元组逐一进行严格验证。审核提示词要求 LLM 逐项检查以下条件：（1）关系类型是否属于预定义的四种之一；（2）证据字段（evidence）是否为文本块中的连续原文子串，且逐字一致；（3）头实体和尾实体是否均出现在证据字段中；（4）是否存在自环（head = tail）；（5）是否引入了文本块中不存在的新实体或新关系。每个三元组的审核结果包含 *decision*（keep/revise/drop）和 *reason_code*（如 SUPPORTED、

EVIDENCE_NOT_IN_CHUNK、HEAD_NOT_IN_EVIDENCE 等)。

两阶段架构源于对 LLM 输出质量的实际观察：单次 LLM 调用常夹带幻觉——模型可能编造文本中不存在的实体、生成不匹配的证据或构造逻辑不成立的关系。审核阶段作为质量门控，凭借严格的证据验证规则过滤不可靠的三元组。这一设计思路与 SAC-KG^[35] 的“自我评估”机制有相通之处，但本系统进一步引入了**证据门控**机制。

3.6.2 证据门控机制

证据门控是本系统在关系抽取中的核心创新。每个三元组必须附带 **evidence** 字段，且该字段须为输入文本块中的**连续原文子串**，头实体和尾实体均需出现在该子串中。这一约束为每个抽取的关系建立了可验证的文本依据，三元组的正确性可通过字符串匹配自动检验。

证据门控的设计逻辑：（1）**可验证性**——通过将 **evidence** 与原文做子串匹配，可自动验证三元组的正确性，无需人工逐一审核；（2）**可追溯性**——每个关系均有明确的文本出处，用户可在知识图谱中点击关系查看原始证据，提升可信度；（3）**幻觉抑制**——强制要求 **evidence** 为原文子串，从根源上杜绝 LLM 编造文本中不存在的关系：编造的 **evidence** 无法通过子串匹配验证。

证据门控的验证流程：审核阶段输出的三元组需经过证据检查——对每个三元组，系统在原始文本块中搜索 **evidence** 子串，找到则保留，未找到则丢弃或要求修正。该机制确保最终入库的每条三元组均有扎实的文本依据。

3.7 知识融合设计

从多个文本块中独立抽取的实体和三元组，不可避免地存在重复和变体。例如，“TCP”“TCP 协议”“传输控制协议”指向同一实体，“三次握手”在不同块中可能被标注为 **mechanism** 或 **concept**。知识融合阶段的目标是将这些冗余和变体统一为规范的知识表示。

3.7.1 实体规范化策略

系统采用两级实体规范化策略：别名规范化（Level 1）和基于嵌入的语义规范化（Level 2）。

Level 1：别名规范化。别名映射表维护中英文缩写与全称的对应关系（如“传输控制协议”映射到“TCP”、“往返时延”映射到“RTT”），同时通过正则表达式剥离实体名称末尾的类型后缀（“协议”“算法”“机制”“方法”“技术”“方式”等）。别名规范化处理常见缩写和全称变体效率高，但无法覆盖所有变体——例如，“滑动窗口机制”与“滑动窗口”在别名表中可能没有对应条目。

Level 2：基于嵌入的语义规范化。对于别名表未覆盖的长尾变体，系统通过嵌入向量进行语义匹配。具体流程如算法3-2所示。

算法 3-2 基于 FAISS 的嵌入实体规范化

Input: 实体列表 E ，相似度阈值 θ ，编码模板 T

Output: 规范化实体集合 E'

- 1: 按实体类型分桶（可选）: $E_{type} \leftarrow \{e \in E \mid e.type = type\}$
 - 2: **for each** 桶 B **do**
 - 3: 对每个实体 $e \in B$ ，构建编码文本：
 $T(e) \leftarrow$ “实体类型: $\{e.type\}$;
 实体名: $\{e.name\}$;
 定义: $\{e.description\}$ ”
 - 4: 调用 Embedding API 获取向量 v_e
 - 5: 构建 FAISS IndexFlatIP 索引（余弦相似度，内积归一化）
 - 6: 对每个实体查询 top_k 最相似实体
 - 7: 使用并查集（UnionFind）合并相似度 $\geq \theta$ 的实体对
 - 8: 选择规范代表名：频率最高 $\rightarrow$ 名称最短 $\rightarrow$ 字典序最小
 - 9: **end for**
 - 10: **return** E'
-

嵌入规范化参考了 EDC^[33] 的实体消解思路和 KGGen^[34] 的知识图谱构建方法。选择 FAISS 作为向量索引的原因：（1）FAISS 提供高效的近似最近邻搜索，适用于大规模实体集合；（2）IndexFlatIP 索引支持内积相似度搜索，配合向量归一化即可实现余弦相似度计算；（3）FAISS 的批量查询接口与系统的并发设计兼

容。

相似度阈值 θ 设为 0.85。阈值过低会将语义不同的实体错误合并（如“拥塞控制”与“流量控制”），阈值过高则无法合并真正的同义变体（如“TCP 协议”与“TCP”）。实验表明 0.85 在两者之间取得了平衡。

两级规范化的核心思路是**效率与覆盖率的互补**：别名表处理高频变体速度快、确定性高，但覆盖率受限于人工维护程度；嵌入方法覆盖长尾变体能力强，但计算成本较高且存在误合并风险。二者结合，构成“快速路径 + 深度路径”的混合策略。

图3-3展示了实体规范化的完整流程。




图 3-3 两级实体规范化流程

3.7.2 三元组合并与去重

实体规范化完成后，系统对三元组进行合并与去重。合并策略：以规范化后的 $(head, relation, tail)$ 三元组作为键分组，对同一键下的三元组累加 *frequency* 频次，并收集所有唯一的 *evidences* 证据文本。合并后还须过滤以下无效三元组：（1）自环三元组 $(head = tail)$ ；（2）头实体或尾实体不在有效实体集合中的三元组。

保留频次信息有两方面价值：（1）在知识图谱可视化中，频次可映射节点大小，高频实体在图中更为突出；（2）频次可作为实体重要性的量化指标，辅助后续知识检索和推荐。

3.8 图存储与可视化设计

3.8.1 Neo4j 图数据库 Schema 设计

知识图谱的存储使用 Neo4j 图数据库。Schema 设计如图3-4所示，包含四类节点标签和四种关系类型。




图 3-4 Neo4j 图数据库 Schema

每类节点存储以下属性：*name*（规范名称，作为唯一约束）、*description*（实体描述）、*frequency*（出现频次）。每种关系类型存储 *frequency*（关系出现频次）和 *evidences*（证据文本列表）。

查询策略采用诱导子图采样（Induced Subgraph Sampling）：首先按频次从高到低取前 N 个高频节点，然后查询这些节点之间的所有关系，构成诱导子图。选此策略的原因是：完整知识图谱可能包含数千个节点和上万个关系，直接渲染会导致视图混乱、性能下降；诱导子图采样既保留了高频核心实体及其关联，又将可视化规模控制在合理范围内，确保交互流畅性。节点数量上限和关系数量上限通过环境变量 `NEO4J_GRAPH_NODE_LIMIT` 和 `NEO4J_GRAPH_REL_LIMIT` 配置。

3.8.2 前端可视化架构设计

前端使用 Next.js 16 框架，基于 App Router 架构搭建。可视化核心使用 react-force-graph-2d 库，以 d3-force 引擎为底层进行力导向布局计算。

架构设计要点：（1）**对数节点映射**——节点大小按频次的对数映射（半径 2.5–11px），避免高频节点过度放大导致视觉失衡，同时确保低频节点仍然可见；（2）**多边曲线偏移**——两个节点间存在多条关系时，通过交替偏移曲率（curvature）使每条边在视觉上可区分；（3）**缩放感知标签**——仅在缩放比例超过 1.4 倍时显示节点标签，避免缩小状态下标签重叠造成视觉噪声；（4）**类型过滤**——提供实体类型和关系类型的复选框过滤，使用户能按需聚焦特定类型的知识元素。

API 路由 `/api/graph` 从 Neo4j 中查询诱导子图数据，返回 JSON 格式的节点数组和边数组。前端 `GraphCanvas` 组件接收数据后进行力导向布局渲染，主题配置（`graphTheme.ts`）为四类实体和四种关系定义对应的颜色方案，确保视觉一致性。

3.9 本章小结

本章阐述了七阶段流水线架构及各模块的设计。系统设计围绕三条主线：模块化——每个阶段独立封装、通过文件系统交换中间产物，支持独立测试与替换；可验证性——证据门控机制要求每条关系附带原文依据，三元组的正确性可自动检验；混合策略——别名表与嵌入语义互补完成实体规范化，两阶段抽取平衡召回率与精度。这些设计使系统在保持流水线灵活性的同时，确保最终知识图谱的质量可控。

4 系统实现

本章给出 QmrKG 系统各模块的具体实现，包括代码结构、关键参数和工程决策。系统架构和设计依据见第三章，本章不再重复。

4.1 文档渲染与 OCR 实现

4.1.1 PDF 渲染模块

渲染模块将 PDF 和 PowerPoint 文件转为 PNG 图像。PDF 页面通过 PyMuPDF 渲染：`fitz.Matrix(zoom, zoom)` 构造缩放矩阵，`page.get_pixmap(matrix)` 获取像素图并保存为 PNG，DPI 默认为 200 ($zoom = dpi/72$)。PPT/PPTX 文件先经 LibreOffice 无头模式转为临时 PDF，再由同一渲染管线处理。所有 PNG 按书籍分目录存放于 `data/png/`。

4.1.2 VLM OCR 实现

OCR 模块基于 Qwen3-VL-8B 模型，通过 PPIO API 的 OpenAI 兼容接口调用。每张 PNG 经 Base64 编码后与 OCR 提示词一同发送。提示词以中文撰写，要求输出有效 Markdown、保持原语言、保留阅读顺序、识别标题层级（#-###），并对章节结构词（“第 X 章”“第 X 节”）做标题化处理。

并发 OCR 使用 `ThreadPoolExecutor`，并发数由 `config.yaml` 中的 `max_concurrency` 控制。每页 OCR 结果写入独立 Markdown 文件，前端 YAML 元数据记录模型名称、Token 用量和耗时，之后由 `kgmdcombine` 按页码合并为完整教材文档。

4.2 文本分块实现

文本分块模块连接 OCR 输出与 LLM 知识抽取入口。系统使用 `tiktoken` 库（`cl100k_base` 编码）做 Token 计数，同时配备离线安全的字符级近似回退方案。分块算法为递归标题感知策略（见算法 3-1），Token 上限 $T_{max} = 4000$ ，优先在

标题边界切分，无标题可分时退至段落级累积切分。每个输出块记录所属标题层级（`titles` 字段）、Token 数量及源文件信息。

实现层面，Markdown 解析使用栈式结构处理 # 标记构建标题树，递归函数 `chunk_recursive()` 处理三种情况：子树在预算内则整体输出；超出预算且有子标题则递归下降；无子标题则在段落级切分。清洗步骤先去除 YAML 前置元数据、页码标记和页眉页脚等 OCR 伪影，再送入分块逻辑。

4.3 知识抽取实现

4.3.1 LLM 工厂与限流机制

所有 LLM 调用通过统一的工厂模式（`TaskLLMFactory`）管理。工厂按任务名称（`extract`、`ocr`、`entity_embed` 等）从配置文件加载对应的模型参数、API 密钥和速率限制策略，返回 `TaskLLMRunner` 实例。

`TaskLLMRunner` 集成了请求执行、重试与指数退避。遇到 429（速率限制）或 5xx（服务端错误）时自动指数退避重试（首次 1s，逐次翻倍，上限由 `max_retries` 配置）。`RollingRateLimiter` 使用滑动窗口算法，统计 60 秒内请求数，达到 RPM 上限后阻塞等待。

4.3.2 两阶段抽取流程

知识抽取采用 Propose-Review 两阶段架构，其设计依据和验证规则见第三章。实现上，两阶段均为独立的 LLM 调用：提议阶段输出候选实体列表和三元组 JSON；审核阶段逐一验证每个三元组，输出包含 `decision`（`keep` / `revise` / `drop`）和 `reason_code` 的审核结果。系统对每个文本块依次执行提议和审核，未通过证据门控的三元组被丢弃或标记修正。

4.3.3 抽取模式与提示词管理

系统支持 Zero-shot 和 Few-shot 两种抽取模式，通过命令行 `--mode` 参数切换。两种模式的提示词存放在 `config.yaml` 的 `extract.prompts` 配置段中，支持热更新，不修改代码即可生效。Few-shot 模式额外加载四个标注示例（每种

关系类型一个)和粒度规则的负面示例。抽取过程使用 `ThreadPoolExecutor` 并行化,并发度由 `max_concurrency` 控制。每个文本块的抽取结果保存为独立 JSON 文件, Zero-shot 和 Few-shot 模式分目录存放,支持结果对比。

4.4 知识融合实现

4.4.1 实体别名规范化

从多个文本块中抽取的实体存在名称变体(“传输控制协议”“TCP 协议”“TCP”等)。系统通过别名映射表(`ALIAS_MAP`)和正则后缀剥离((协议|算法|机制|方法|技术|方式)\$)处理。映射表包含 50 余条中英文缩写与全称对应关系(如“传输控制协议” $\rightarrow$ “TCP”、“往返时延” $\rightarrow$ “RTT”)。规范化后将名称与类型组成复合键进行合并,保留最高频名称和首个非空描述,累加频次。

4.4.2 基于嵌入的实体规范化

别名表无法覆盖的长尾实体通过嵌入向量做语义规范化。`EmbeddingCanonicalizer` 调用 `Embedding API` 将每个实体编码为语义向量,在 `FAISS IndexFlatIP` 索引上做最近邻搜索,通过并查集(`UnionFind`)合并余弦相似度 ≥ 0.85 的实体对。完整流程见算法 3-2。

嵌入缓存机制(`_EmbeddingBinaryCache`)将已计算的嵌入向量序列化为 `NumPy` 二进制文件(`.npy`)和 JSON 元数据文件,避免重复调用 `Embedding API`,降低大规模规范化的计算成本。

4.4.3 三元组合并与去重

以规范化后的(`head, relation, tail`)三元组为键分组,累加频次并收集全部 *evidences* 列表。合并后过滤自环三元组及头尾实体不在有效集合中的条目。合并结果写入 `merged_triples.json`, Zero-shot 和 Few-shot 结果分目录存放。

4.5 Neo4j 图数据库导入与前端可视化实现

4.5.1 Cypher 批量导入

KGNeo4jLoader 基于 neo4j Python 驱动 (Bolt 协议) 执行导入。连接参数 (NEO4J_URI、NEO4J_USER、NEO4J_PASSWORD) 从环境变量读取。导入时按实体类型创建不同标签的节点 (Protocol、Concept、Mechanism、Metric)，按关系类型创建有向边 (CONTAINS、DEPENDS_ON、COMPARED_WITH、APPLIED_TO)。使用 Cypher MERGE 语句保证幂等，节点以 *name* 为唯一约束，关系以头尾节点对和关系类型匹配。

4.5.2 前端力导向图实现

前端基于 Next.js 16 (App Router) 和 react-force-graph-2d (d3-force 引擎) 构建。API 路由 /api/graph 执行诱导子图查询，返回节点和边数组。GraphCanvas 组件集成对数节点映射 (半径 2.5–11px)、力碰撞检测、缩放感知标签 (缩放 $\geq 1.4\times$ 时显示)、多边曲线交替偏移、类型复选框过滤等功能。主题配置 graphTheme.ts 定义四类实体和四种关系的颜色方案。

4.6 本章小结

本章给出了 QmrKG 各模块的实现细节。文档渲染使用 PyMuPDF 和 LibreOffice；OCR 基于 Qwen3-VL-8B 并通过 ThreadPoolExecutor 并发；分块采用递归标题感知策略，Token 上限 4000；知识抽取实现两阶段架构和证据门控验证，支持 Zero-shot/Few-shot 模式切换；知识融合结合别名映射表和 FAISS 嵌入去重，嵌入结果通过缓存复用；Neo4j 导入使用 MERGE 幂等操作，前端通过诱导子图查询和力导向布局展示结果。

5 实验与结果分析

大语言模型评测需要结合任务场景、评价指标和输出可靠性设计评价口径^[38]。本章围绕基于大模型的课程知识实体识别与关系抽取系统，报告实验设计与运行结果。先介绍实验环境与配置参数，随后从课程语料构建、实体抽取评估、关系抽取评估、金标数据核查、零样本与少样本抽取对比、知识图谱质量分析以及典型案例分析等角度，对系统运行结果进行评估与讨论。

5.1 实验环境与配置

本实验在统一的软硬件环境下运行，实验配置如表 5-1 所示。硬件选用计算能力较强的服务器，软件环境基于 Python 3.13，使用 uv 作为包管理器。系统核心依赖大语言模型 API 完成 OCR 识别、知识抽取与向量化表示三类任务。

表 5-1 实验软硬件环境配置

配置类别	配置项	参数值
硬件配置	CPU	x86_64 架构多核处理器
	内存	32GB DDR4
	存储	SSD 固态硬盘
软件环境	操作系统	Linux (Ubuntu 24.04 LTS)
	Python 版本	3.13
	包管理器	uv
LLM 配置	OCR 模型	qwen3-vl-8b
	抽取模型	deepseek-v4-flash
	嵌入模型	qwen3-embedding-8b (向量维度 1024)

表 5-2 列出了流水线核心参数配置。PDF 渲染选用 200 DPI 分辨率以兼顾 OCR 识别质量；文本分块最大 token 数设为 4000，平衡上下文完整性与处理效率；知识抽取采用 few-shot 模式提高准确性；同时启用严格证据验证机制，要求所有抽取得到的三元组均可溯源至原文。

表 5-2 流水线核心参数配置

处理阶段	参数项	参数值
PDF 转 PNG	DPI 分辨率	200
文本分块	最大 token 数	4000
	分块策略	语义边界感知
知识抽取	抽取模式	few-shot (fs)
	证据审查	enabled
	严格证据	enabled
并发处理	OCR 并发数	10
	抽取并发数	4
	执行器类型	ThreadPoolExecutor

本实验使用 ThreadPoolExecutor 对 OCR 识别与知识抽取两个阶段进行并行加速。OCR 阶段并发数设为 10，知识抽取阶段并发数设为 4，该配置在 API 速率限制与处理效率之间取得了平衡。

5.2 课程语料构建结果

本实验构建了覆盖计算机网络课程全内容的多元化语料库。根据 data/pdf 目录下的实际源文件统计，语料来源包括课程课件与讲义、RFC 协议标准、实验与编程材料、作业与考核材料以及教材参考书，如表 5-3所示。

表 5-3 课程语料来源构成

来源类型	具体内容	数量
课程课件与讲义	课程介绍、章节讲义、UnderHIT 课件、Kurose 配套章节课件等	115 份
RFC/协议标准文档	TCP/IP、HTTP、TLS、DNS、IPv6 等相关 RFC 文档	72 份
实验与编程材料	Wireshark 实验、Socket 编程、实验指导书与 FAQ 等	44 份
作业与考核材料	Assignment、课后作业、历年试卷、模拟题、答案与解析等	33 份
教材与参考书	谢希仁《计算机网络》、Kurose & Ross《自顶向下方法》、《TCP/IP 详解》系列及复习资料等	19 份
总计	205 份 PDF、69 份 PPT/PPTX、9 份 Markdown 源文件	283 份

语料库构建结果统计如表 5-4 所示。在 283 份源文件中，205 份 PDF 文档进入 PDF 渲染与 OCR 流程，并生成 274 个 PNG 输出目录（每一个目录对应一个 PDF 页码集合）。系统最终产生了 16,438 个语义文本块，总 token 数达 10,398,922，平均每块 632.6 个 token。

表 5-4 语料库构建统计结果

统计指标	数值
输入 PDF 文档数	205 份
PNG 输出目录数	274 个
生成文本块数	16,438 个
总 token 数	10,398,922
平均每块 token 数	632.6

按进入 OCR 流程的 205 份 PDF 文档计算，平均每份 PDF 产生约 80 个文本块。PPT/PPTX 与 Markdown 源文件主要用于补充课程课件、实验说明和章节文本，教材与讲义的内容量较大。语料覆盖中英文双语材料，既有中文教材的系统阐述，也有英文 RFC 文档的原始技术规范，表明 pipeline 对多样化课程资源具备处理能力。

5.3 实体抽取评估

本实验从 16,438 个文本块中抽取了实体 23,600 个，实体类型分布如表 5-5 所示。系统采用四分类实体模式：concept（概念）、mechanism（机制）、protocol（协议）、metric（性能指标）。

表 5-5 实体类型分布统计			
实体类型	数量	占比	典型示例
概念 (concept)	16,719	70.8%	拥塞控制、流量控制、路由选择
机制 (mechanism)	3,063	13.0%	滑动窗口、CRC 校验、三次握手
协议 (protocol)	2,189	9.3%	TCP、UDP、HTTP、IP
性能指标 (metric)	1,629	6.9%	RTT、吞吐量、丢包率、带宽
总计	23,600	100%	—

表 5-5 显示，概念类型实体占比最高 (70.8%)，这与课程材料以阐述抽象网络概念与原理为主要的特性一致。机制类型实体占 13.0%，课程对实现技术给予了相当篇幅。协议类型实体仅占 9.3%，但协议在网络通信中处于基础地位，数量占比不反映其重要程度。性能指标类型实体占 6.9%，覆盖了网络性能评估的主要维度。

高频实体分布如表 5-6 所示。TCP 以 2,657 次的出现频率排在第一，UDP(1,411 次)、IP(1,020 次) 位列其后，三者是网络协议栈的基础协议。

实体出现频次的范围为 1 至 2,657，平均频次 3.9 次，呈典型的长尾分布。前 10 个高频实体累计占比约 38%，超过半数的实体 (约 12,000 个) 仅出现 1 ~ 2 次。该分布遵循幂律规律：高频术语在网络课程文献中被反复讨论，低频术语仅在

表 5-6 高频实体统计 (Top 10)

排名	实体	频次	类型	占比 *
1	TCP	2,657	protocol	11.3%
2	UDP	1,411	protocol	6.0%
3	IP	1,020	protocol	4.3%
4	HTTP	932	protocol	3.9%
5	DNS	723	protocol	3.1%
6	RTT	551	metric	2.3%
7	IPv6	521	protocol	2.2%
8	ICMP	492	protocol	2.1%
9	IPv4	469	protocol	2.0%
10	OSPF	451	protocol	1.9%

* 占总实体数的百分比

特定上下文中出现。

TCP、UDP、IP 等高频协议实体的频次远超均值，与它们在网络课程中的教学重心一致。系统识别了四类实体，为后续关系抽取与知识图谱构建提供了输入。

5.4 关系抽取评估

从 23,600 个实体中，本实验抽取了关系三元组 44,526 个。关系类型采用四分类体系：contains（包含）、applied_to（应用于）、depends_on（依赖于）、compared_with（比较于），分布统计如表 5-7 所示。

contains 与 applied_to 两类合计占 66.4%，反映了教育内容在知识结构上的两个特征：既强调概念的层级包含关系 (如”TCP 包含拥塞控制”)，也关注机制的具体应用场景 (如”滑动窗口应用于 TCP”)。depends_on 关系占 21.6%，源自网络协议栈的层次依赖特性 (如”HTTP 依赖于 TCP”)。

compared_with 关系占比最低 (12.1%)。比较分析属于高阶认知任务，在基础

表 5-7 关系类型分布统计

关系类型	数量	占比
包含 (contains)	15,251	34.3%
应用于 (applied_to)	14,291	32.1%
依赖于 (depends_on)	9,601	21.6%
比较于 (compared_with)	5,383	12.1%
总计	44,526	100%

教材中出现频率较低，但这类关系表达了概念间的对比与区别，对完整描述课程知识结构是必要的。

高频三元组统计如表 5-8所示。

表 5-8 高频关系三元组统计 (Top 5)

关系三元组	频次	关系类型
TCP <i>compared_with</i> UDP	421	比较
TCP <i>contains</i> 拥塞控制	133	包含
IPv6 <i>compared_with</i> IPv4	130	比较
HTTP <i>depends_on</i> TCP	122	依赖
TCP <i>depends_on</i> IP	75	依赖

TCP 与 UDP 之间的比较关系出现最为频繁：双向比较 (TCP↔UDP) 累计超过 600 次，说明传输层协议对比是课程反复涉及的话题。IPv6 与 IPv4 的比较关系出现 130 次，与网络层协议演进的教学内容直接相关。

本实验启用了严格证据验证机制 (strict_evidence enabled)，所有三元组均附带可追溯的原文证据。该机制过滤了无依据的虚假关系，确保每条三元组均可回溯到源文本。

5.5 金标数据核查与零样本/少样本对比

为了让 zero-shot (zs) 与 few-shot (fs) 的抽取结果可以进行公平比较, 本实验没有把任一模式的预测结果直接作为金标来源, 而是以 data/chunks 中的原始文本块为回溯对象, 构建并复核独立评估集。当前用于评估的金标文件为 data/eval/gold_triples.json, 它与 data/eval/gold_triples.500_reviewed.json 内容一致, 包含 500 条关系三元组和 594 个实体, 覆盖 88 个源文件以及 186 个源文本块。核查过程中逐条检查了 source_file、chunk_index 与 evidence 字段: 所有源文件均存在, 所有 chunk 索引均有效, 500 条证据文本均为对应源文本块中的连续原文子串。其中有 17 条证据最初只是空白折叠后的文本, 已替换为带原始换行的精确片段。

评估采用系统中的 kgeval 严格匹配口径。实体匹配要求实体名与类型完全一致, 三元组匹配要求 head、head_type、relation、tail 和 tail_type 五个字段完全一致, 不进行别名归一化、大小写折叠、后缀剥离或向量语义匹配。为了避免用全量图谱去对比 500 条抽样金标时把大量未标注但可能正确的关系误计为假阳性, 实验先把四种 raw 抽取输出过滤到金标覆盖的 186 个源文本块, 再在关闭 embedding 合并的条件下执行 kgmerge, 最后用同一份金标计算指标。该口径把比较范围限制在相同文本证据范围内, 适合观察 zs/fs 提示方式和复核开关对严格命中的影响。

表 5-9 零样本与少样本抽取在 500 条金标上的严格匹配结果

模式	Raw 文件	Raw 三元组	合并三元组	实体 P	实体 R	实体 F1	三元组 P	三元组 R	三元组 F1
zs-nocheck	184	418	337	0.2695	0.5168	0.3543	0.1899	0.1280	0.1529
zs-recheck	182	397	314	0.2745	0.5135	0.3578	0.1783	0.1120	0.1376
fs-nocheck	171	325	290	0.2436	0.4495	0.3160	0.1621	0.0940	0.1190
fs-recheck	176	392	304	0.2604	0.4529	0.3307	0.1579	0.0960	0.1194

表 5-9显示, 在严格三元组匹配口径下, zs-nocheck 的三元组 F1 最高 (0.1529), 三元组精确率和召回率也高于另外三种设置; zs-recheck 的实体 F1 最高 (0.3578)。在 few-shot 设置内部, 启用复核后实体 F1 从 0.3160 升至 0.3307, 三元组召回率从 0.0940 升至 0.0960, 但三元组精确率从 0.1621 降至 0.1579, 说明复核在保留更多候选关系的同时, 也引入了更多未被严格金标命中

的三元组。

本实验中的金标是经人工复核的正例参考集，并非对 186 个源文本块中所有可能正确关系的穷尽标注。因此，表中的精确率应理解为保守的严格重合精确率，不等于完整语义精确率；召回率反映系统对 500 条已接受金标三元组的严格覆盖能力。在当前提示词和严格匹配条件下，zero-shot 输出比 few-shot 更接近金标标注风格，后续优化应聚焦 few-shot 示例与金标标注规范的一致性，而非单纯增加示例数量。

5.6 原始抽取层面的零样本与少样本对比

上一节借助 kgmerge 合并后的三元组来评估 zs/fs 模式在最终知识图谱上的表现，但合并过程引入了实体归一化与去重步骤，可能遮盖了 LLM 直接抽取质量的差异。为了直接衡量两种提示策略在抽取阶段的原始能力，本实验设计了原始抽取层面的逐块评估方案，使用专用的 kgevalraw 评测工具，在未经过合并的 raw 三元组上直接与金标进行逐块对比。

评估方法如下：（1）将 500 条金标三元组按其来源的（source_file, chunk_index）分组；（2）在对应 raw 抽取目录中定位每个块的三元组文件，从其中的 entities 列表构建 {实体名 → 类型} 的查询表；（3）将查询到的 head_type 和 tail_type 注入 raw 三元组；（4）在严格精确匹配口径下计算各项指标。假阳性仅统计金标覆盖的 186 个块中出现的错误预测，假阴性则统计金标中存在但预测缺失的三元组。评估考察的维度如表 5-10 所示，涵盖实体、三元组、关系三个层面的 F1 以及三个关键属性的准确率。

表 5-11 展示了 zero-shot 与 few-shot 在三个 scope 层面的精确率、召回率与 F1 值对比。

表 5-12 进一步列出了三个关键属性（头实体类型、尾实体类型、关系标签）的逐项准确率对比。

表 5-13 给出了两种模式在 186 个金标文本块上的覆盖情况，用于辅助判断抽取结果的完整性。

实验结果显示：

(1) Zero-shot 在原始抽取质量上整体优于 Few-shot。在全部三个 scope 层

表 5-10 原始抽取评估维度说明

维度	匹配键	说明
Entity F1	(name, type)	实体名称与类型需要完全一致
Triple F1	(head, head_type, relation, tail, tail_type)	完整三元组严格匹配
Relation F1	(head_type, relation, tail_type)	忽略实体名，仅考察关系模式
head_type Acc	head_type	头实体类型分类准确率
tail_type Acc	tail_type	尾实体类型分类准确率
relation Acc	relation	关系标签分类准确率

面的 F1 指标上，zero-shot 均高于 few-shot：Entity F1 高 2.0 个百分点（0.3337 vs 0.3136），Triple F1 高 2.6 个百分点（0.1387 vs 0.1130），Relation F1 高 5.1 个百分点（0.6535 vs 0.6022）。这与上一节合并评估的结论一致，zero-shot 输出在严格匹配口径下更接近金标标注风格。Few-shot 示例可能引入了模式化偏差，使 LLM 倾向于生成与示例结构相似但偏离金标规范的三元组。Relation F1 上 5.1 个百分点的差距最大，说明 few-shot 示例的关系分类引导方向与人工标注偏好之间存在错位。

(2) Triple F1 与 Relation F1 的悬殊源于实体名称的严格匹配约束。Relation F1 在 zero-shot 模式下达到 0.6535，说明 LLM 对关系分类具备基本能力；但 Triple F1 仅 0.1387，差距超过 50 个百分点。这种悬殊来自实体名称的精确匹配约束：LLM 抽取时倾向于使用原文中的完整表述（如“传输控制协议”），而金标使用标准化缩写（“TCP”），导致大量语义正确但字符串不匹配的 false negative。这不反映 LLM 的抽取能力不足，而是严格精确匹配在评估实体名称变体时存在固有局限。

(3) Few-shot 在尾实体类型判断上有明显优势。在 head_type、tail_type 和 relation 三个属性的分类准确率中，few-shot 在 tail_type 上比 zero-shot 高 13.8 个百分点（0.8904 vs 0.7524），这是唯一一项 FS 明显优于 ZS 的指标。这一提升可能源于 few-shot 示例中明确提供了尾实体的标准分类标签，LLM 据此模仿了金标的标注习惯。head_type 和 relation 两个属性的准确率在两种模式下差异不大（差距均小于 2 个百分点），说明 LLM 对头实体类型和关系标签的判断受提示策

表 5-11 原始抽取层面 zero-shot 与 few-shot 的 scope 级指标对比

Scope	Metric	ZS	FS	Δ (FS-ZS)
Entity	Precision	0.4000	0.3690	-0.0310
	Recall	0.2862	0.2727	-0.0135
	F1	0.3337	0.3136	-0.0200
Triple	Precision	0.1644	0.1335	-0.0309
	Recall	0.1200	0.0980	-0.0220
	F1	0.1387	0.1130	-0.0257
Relation	Precision	0.5500	0.5385	-0.0115
	Recall	0.8049	0.6829	-0.1220
	F1	0.6535	0.6022	-0.0513

表 5-12 原始抽取层面属性分类准确率对比

属性	ZS	FS	Δ (FS-ZS)
head_type	0.8667	0.8493	-0.0174
tail_type	0.7524	0.8904	+0.1380
relation	0.8571	0.8630	+0.0059

略影响较小。

(4) **Few-shot 的抽取缺失更多**。表 5-13 显示，FS 有 10 个金标块找不到对应的 raw 抽取文件，而 ZS 仅 4 个，即 few-shot 模式下部分文本块的抽取可能完全失败（模型无有效输出），或输出文件命名不一致导致无法匹配。部署 few-shot 模式时需要额外的容错处理。

(5) **与合并评估的互补关系**。上一节的 kgmerge 合并评估反映的是经实体归一化与去重后的最终知识图谱质量，而本节原始抽取评估直接衡量 LLM 在逐块抽取阶段的表现。合并评估更适合衡量系统的端到端可用性（实体归一化弥补了一部分命名变体导致的严格匹配损失），原始抽取评估更直接地反映提示策略本身对 LLM 抽取行为的影响。zero-shot 提示策略在当前课程知识抽取任务中

表 5-13 原始抽取层面金标块覆盖统计

统计项	ZS	FS
金标覆盖块总数	186	186
找到对应 raw 文件的块数	182	176
缺失 raw 文件的块数	4	10
金标块内的 raw 三元组总数	397	392

整体优于 few-shot，而 few-shot 在尾实体类型分类等特定属性上的精准度优势，可在后续提示优化中加以利用。

5.7 知识图谱质量分析

在 44,526 个关系三元组的基础之上，本实验构建了包含 23,600 个节点、44,526 条边的课程知识图谱。图谱的基本统计指标如表 5-14所示。

表 5-14 知识图谱基本统计指标

统计指标	数值
实体节点数	23,600
关系边数	44,526
平均节点度数	3.77
实体平均出现频次	3.9 次
高频实体占比 (Top 10)	38%

平均节点度数约 3.8，知识图谱呈中等连接密度，既非完全稀疏的孤立节点集合，也非高度稠密的完全图。该密度与课程知识的组织规律一致：高频术语与多个概念关联，低频术语仅与少数概念关联。

系统采用双层归一化策略处理实体名称变体：词汇级归一化基于别名表，处理中英文名称对照（如”Transmission Control Protocol”↔”TCP”↔”传输控制协议”）；语义级归一化基于嵌入向量，合并语义相似但字面表述不同的实体。该策略解决了同一实体存在多种表述的问题，提高了图谱中实体名称的一致性。

协议实体在图谱中表现出枢纽特性。以 TCP 为例，该节点连接了拥塞控制、流量控制、三次握手等多个子概念 (contains 关系)，同时与 UDP 形成对比关系 (compared_with)，且被 HTTP、SMTP 等应用层协议依赖 (depends_on 的反向关系)。TCP 的高度连接与其在网络协议栈中的实际地位一致。

5.8 案例分析

本实验选取两个典型子图进行分析，以评估系统的知识抽取效果。

案例一：TCP 协议子图

TCP 协议子图展示了以 TCP 为核心的局部知识网络。该子图包含以下主要关系：

- **对比关系**：TCP *compared_with* UDP (双向，421+195=616 次)。该比较反复出现在传输层协议对比的教学内容中，是课程多次讨论的话题。
- **包含关系**：TCP *contains* 拥塞控制 (133 次)、TCP *contains* 流量控制 (89 次)。描述了 TCP 的内部机制组成。
- **依赖关系**：TCP *depends_on* IP(75 次)、HTTP *depends_on* TCP(122 次)、SMTP *depends_on* TCP(56 次)。TCP 作为传输层协议，承载上层应用 (HTTP、SMTP) 并依赖下层网络层协议 (IP)。

TCP 子图覆盖了三个知识维度：协议对比 (TCP vs UDP)、内部机制 (拥塞控制、流量控制) 和协议栈依赖关系 (HTTP→TCP、TCP→IP)，展示了 TCP 在课程中的知识广度。

案例二：协议演进对比子图

网络协议演进对比是课程教学的重要内容。本系统抽取出了以下经典对比：

- IPv6 *compared_with* IPv4 (130 次)：对应网络层地址空间演进的课程内容。
- TCP *compared_with* UDP (616 次双向)：传输层可靠性与效率权衡的经典对比。

系统抽取了上述对比关系，覆盖了课程中反复出现的对比主题。比较关系的高频出现与这些内容在教学材料中的覆盖密度一致，系统通过统计频次识别出了教学重点。

5.9 本章小结

本章对基于大模型的课程知识 NER 系统进行了实验评估。系统处理了 205 份 PDF 文档，构建出包含 23,600 个实体、44,526 个关系三元组的课程知识图谱。实体抽取以概念类型为主 (70.8%)，呈长尾分布；关系抽取以 `contains` 和 `applied_to` 为主 (66.4%)，反映了教育内容的结构性与应用性双重特点；图谱平均节点度数 3.8，形成中等密度的知识网络。在零样本与少样本对比方面，合并评估与原始抽取评估两个层面的结果一致表明：在当前提示词与严格匹配条件下，zero-shot 整体表现优于 few-shot（合并层面三元组 F1 为 0.1529 vs 0.1194，原始层面三元组 F1 为 0.1387 vs 0.1130），few-shot 在尾实体类型分类上具有局部优势。实验表明，本系统能够完成课程知识图谱的自动化构建，全流程可在学期更新周期内运行。

6 总结与展望

(1) 在课程语料构建与预处理方面, 本课题实现了一套面向计算机网络课程的多源语料自动化预处理流程。语料覆盖教材(谢希仁《计算机网络》第8版^[39]、Kurose&Ross《计算机网络: 自顶向下方法》第8版、《TCP/IP 详解》等)、课堂讲义(9章课件及10次授课讲稿)、实验指导书、历年试题以及50余份RFC标准文档, 共205份PDF文档。预处理阶段使用PyMuPDF渲染PDF页面, LibreOffice无头模式处理PPT/PPTX格式文档, Qwen3-VL-8B多模态视觉语言模型执行OCR文字提取, 最终输出结构化Markdown文本。该语料库覆盖多种来源与格式, 为后续知识抽取阶段提供了基础。

(2) 在命名实体识别方面, 本课题为计算机网络领域定义了四类实体: 协议名称(protocol, 如TCP、HTTP、OSPF)、概念术语(concept, 如拥塞控制、子网掩码、分层模型)、机制算法(mechanism, 如三次握手、慢启动、CSMA/CD)和性能指标(metric, 如吞吐量、RTT、丢包率)。考虑到课程领域缺乏标注数据, 研究了零样本(zero-shot)和少样本(few-shot)两种提示策略。零样本模式通过详细的实体类型定义与标注指南引导模型行为; 少样本模式在此基础上增加了四条覆盖全部关系类型的标注示例以及负面示例, 改进模型对课程术语边界的识别。实验抽取到23,600个实体, 频次跨度从1次到2,657次(平均3.9次), 高频实体如TCP(2,657次)、UDP(1,411次)、IP(1,020次)等, 分布与计算机网络课程的知识结构大体一致。

(3) 在关系抽取方面, 本课题定义了四类关系类型: 包含关系(contains), 表达概念或协议间的结构组成; 依赖关系(depends_on), 表示功能实现上的前置条件; 对比关系(compared_with), 描述同类实体间的异同; 应用关系(applied_to), 说明机制算法在具体协议或场景中的部署方式。抽取架构上, 设计了“Propose-Review”提议—审核”两阶段流程: 第一阶段由大语言模型按Schema生成候选三元组; 第二阶段通过独立审核提示词进行质量门控, 逐条检查证据是否为输入文本的连续原文子串、头尾实体是否均出现在证据中、关系类型是否合法。该机制要求每条三元组给出可回溯的原文证据, 减少了模型生成不实内容的情况。知识融合阶段, 通过别名映射表(如“传输控制协议”→“TCP”)以及基于FAISS

索引的嵌入语义规范化（结合 UnionFind 算法）实现跨文档实体消歧。最终生成三元组 44,526 个，包含 23,600 个节点、44,526 条边，平均节点度约 3.8。

(4) 在知识抽取管线与可视化系统方面，本课题构建了七阶段端到端自动化流程：文档渲染（PDF→PNG）→OCR 文字提取（PNG→Markdown）→文本分块（Markdown→JSON Chunks）→三元组抽取（Chunks→Raw Triples）→知识融合（Raw Triples→Merged Triples）→图数据库导入（Merged Triples→Neo4j）→前端可视化。流水线采用工厂模式统一管理 LLM 调用，通过滑动窗口速率限制和指数退避重试保障 API 调用稳定性。各阶段经中间文件解耦，支持断点续跑与独立调试。可视化层面，基于 Next.js 16 框架和 react-force-graph-2d 库开发了交互式力导向图前端，支持按实体类型与关系类型多维度过滤、缩放感知的标签显示以及多边关系曲线渲染，可用于课程知识的浏览与分析。系统验证了大语言模型在课程知识建模中的可行性。

未来可从以下方面继续改进：

(1) 模型优化。尝试用 LoRA 或 QLoRA 等参数高效微调方法，在人工审核后的三元组上微调抽取模型，提升实体识别和关系分类的准确率。

(2) 跨领域扩展。将当前的抽取流程迁移至操作系统、数据结构等课程，测试系统在其他领域的表现，并尝试自动发现课程之间的先修关系和交叉引用。

(3) 架构升级。参考 OneKE 等多智能体方案，将 Schema 管理、抽取与审核拆分为独立模块，引入反思机制和错误案例库，逐步改进抽取质量，并降低新增实体类型和关系类型时的扩展成本。

(4) 教学应用。在实际教学中试用本系统，包括：基于知识图谱的智能问答，帮助学生查询和理解课程概念；按知识图谱的先修关系推荐学习路径；尝试自动生成作业和批改，观察知识图谱对学习效果的影响。

参考文献

- [1] KERAGHEL I, MORBIEU S, NADIF M. A Survey on Recent Advances in Named Entity Recognition: A Comparative Study[J]. arXiv preprint arXiv:2401.10825, 2024.
- [2] XU D, CHEN W, PENG W, et al. Large Language Models for Generative Information Extraction: A Survey[J]. arXiv preprint arXiv:2312.17617, 2023.
- [3] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.
- [4] 王耀祖, 李擎, 戴张杰, 等. 大语言模型研究现状与趋势[J/OL]. 工程科学学报, 2024, 46(8): 1411-1425. DOI: 10.13374/j.issn2095-9389.2023.10.09.003.
- [5] ZHU Y, WANG X, CHEN J, et al. Large Language Models for Knowledge Graph Construction and Reasoning[J]. arXiv preprint arXiv:2305.13168, 2023.
- [6] WANG S, SUN X, LI X, et al. GPT-NER: Named Entity Recognition via Large Language Models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL). 2023.
- [7] ZAMAI S, BOUTHORS M, MINARD A L, et al. SLIMER: Show Less, Instruct More—Entity Recognition with Definitions and Guidelines[C]//Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING). 2024: 3347-3356.
- [8] LI P, SUN T, TANG Q, et al. CodeIE: Large Code Generation Models are Better Few-Shot Information Extractors[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL). 2023: 15339-15353.
- [9] YE J, XU N, WANG Y, et al. LLM-DA: Data Augmentation via Large Language Models for Few-Shot Named Entity Recognition[J]. arXiv preprint arXiv:2402.14568, 2024.
- [10] WAN Z, CHENG F, MAO Z, et al. Large Language Models are Few-Shot Relation Extractors[C]//Findings of the Association for Computational Linguistics: EMNLP 2023. 2023: 3534-3547.
- [11] ELVA R, SCHLICHTKRULL M, TITOV I. Revisiting Relation Extraction in the

- Era of Large Language Models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL). 2023: 15566-15589.
- [12] XUE L, ZHANG D, DONG Y, et al. AutoRE: Document-level Relation Extraction with Large Language Models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL). 2024: 211-220.
- [13] WANG X, ZHOU W, ZU C, et al. InstructUIE: Multi-task Instruction Tuning for Unified Information Extraction[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2023.
- [14] SAINZO, GARCÍA-FERRERO I, AGERRIR, et al. GoLLIE: Annotation Guidelines Improve Zero-Shot Information Extraction[C]//The Twelfth International Conference on Learning Representations (ICLR). 2024.
- [15] LUO Y, ZHANG X, HE Y, et al. OneKE: A Dockerized Schema-Guided LLM Agent-based Knowledge Extraction System[C]//Companion Proceedings of the ACM Web Conference 2025 (WWW). 2025: 2871-2874.
- [16] AIN Q, CHOUDHARY M A, SARTOLI S. An Optimized Pipeline for Automatic Educational Knowledge Graph Construction from PDF Learning Material [J]. arXiv preprint arXiv:2509.05392, 2025.
- [17] YANG R, SALA F, WU C, et al. Graphusion: Zero-shot Knowledge Graph Construction from Free Text[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2024.
- [18] ISHTIAQ U, ZAFAR N, ZIA M A. Personalized Higher Education Course Modeling using Large Language Models[J]. arXiv preprint arXiv:2501.12300, 2025.
- [19] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.
- [20] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C/OL]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT). 2019: 4171-

4186. DOI: 10.18653/v1/N19-1423.
- [21] BROWN T, MANN B, RYDER N, et al. Language Models are Few-Shot Learners [C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 1877-1901.
- [22] 车万翔, 郭江, 崔一鸣. 自然语言处理: 基于预训练模型的方法[M]. 北京: 电子工业出版社, 2021.
- [23] ZHOU W, ZHANG S, GU Y, et al. UniversalNER: Targeted Distillation from Large Language Models for Open Named Entity Recognition[J]. arXiv preprint arXiv:2308.03279, 2023.
- [24] ZARATIANA U, TOMEH N, HOLAT P, et al. GLiNER: Generalist Model for Named Entity Recognition using Bidirectional Transformer[J]. arXiv preprint arXiv:2311.08526, 2023.
- [25] XIE T, LI Q, ZHANG J, et al. Self-Improving Zero-Shot Named Entity Recognition with Large Language Models[J]. arXiv preprint arXiv:2311.08921, 2023.
- [26] YU D, LI Z, YU D, et al. KnowCoder: Coding Structured Knowledge into Large Language Models for Unified Information Extraction[J]. arXiv preprint arXiv:2403.07969, 2024.
- [27] WANG S, LI Y, DING N, et al. Unleashing Large Language Models' Potential for Zero-Shot Relation Extraction via Self-Prompting[J]. arXiv preprint arXiv:2410.01154, 2024.
- [28] ABDELKADER A, NAJAR A, BOUDJELLAL N. GLiREL: Generalist Lightweight Model for Zero-Shot Relation Extraction[J]. arXiv preprint arXiv:2501.03172, 2025.
- [29] GAO T, FISCH A, CHEN D. REPaL: Relation Extraction with Relation Definitions[J]. arXiv preprint arXiv:2402.11142, 2024.
- [30] 赵军, 刘康, 何世柱, 等. 知识图谱[M]. 北京: 高等教育出版社, 2018.
- [31] 王昊奋, 漆桂林, 陈华钧. 知识图谱: 方法、实践与应用[M]. 北京: 电子工业出版社, 2019.
- [32] ZHANG X, LIU S, WANG X. RUIE: Retrieval-based Unified Information Ex-

- traction using Large Language Models[J]. arXiv preprint arXiv:2409.11673, 2024.
- [33] ZHANG C, QIU Y, LI S, et al. EDC: Extract-Define-Canonicalize—An End-to-End Framework for Knowledge Graph Construction[J]. arXiv preprint arXiv:2404.03868, 2024.
- [34] BELISLE M, GONZALEZ I, BROWN T. KGGen: Extracting Knowledge Graphs from Plain Text with Large Language Models[J]. arXiv preprint arXiv:2502.09956, 2025.
- [35] CHEN H, LIU X, SHAO H, et al. SAC-KG: Exploiting LLMs as Skilled Authors for Domain Knowledge Graph Construction[J]. arXiv preprint arXiv:2410.02811, 2024.
- [36] HOGAN A, BLOMQVIST E, COCHEZ M, et al. LOKE: Linked Open Knowledge Extraction for Knowledge Graphs[J]. arXiv preprint arXiv:2311.09366, 2023.
- [37] 李晓理, 刘春芳, 耿劭坤. 知识图谱与大语言模型协同共生模式及其教育应用综述[J/OL]. 计算机工程与应用, 2025, 61(15): 1-13. DOI: 10.3778/j.issn.1002-8331.2410-0481.
- [38] 罗文, 王厚峰. 大语言模型评测综述[J]. 中文信息学报, 2024, 38(1): 1-23.
- [39] 谢希仁. 计算机网络[M]. 8 版. 北京: 电子工业出版社, 2021.

致 谢

时光荏苒，转眼就到本科毕业的时候了。这篇论文的完成，离不开许多人的帮助，在这里一一感谢。

首先要感谢我的指导老师。从选题到方案设计，从实验调试到论文撰写，老师在每个阶段都给了我很多具体的指导。老师的严谨和对问题的判断力，我一直很佩服，也跟着学了不少。遇到瓶颈的时候，老师总能几句话帮我理清思路，绕开死胡同。

感谢实验室的同学们。项目开发期间，大家经常凑在一起讨论方案，互相看代码、提意见，这种氛围让很多问题提前暴露出来。特别感谢几位同学在系统架构和代码实现上给我的建议，你们的想法让我看到了一些自己完全没想到的地方。

也感谢班级的同学们。大家研究方向各不相同，平时聊起来反而更容易碰撞出意想不到的想法。谢谢你们在生活上的关照，一起熬夜、一起吃饭的日子，我会记得。

感谢我的家人。父母这么多年一直在背后支持我，从来不给压力，只是在我需要的时候说几句实在话。累的时候、怀疑自己的时候，想到他们就又能撑下去了。

回头看整个毕设，从对知识图谱和自然语言处理只有模糊概念，到能独立搭出一套完整的方案并跑通，这个过程中我慢慢学会了两件事：遇到不懂的就去学，一个人搞不定就找人帮忙。这两点听上去简单，做起来并不容易。

最后，衷心感谢在百忙之中审阅本论文的各位专家和老师，谢谢你们提出的宝贵意见。

谨以此文，献给所有在我大学四年学习和生活中给予帮助的人们。

华中科技大学
计算机科学与技术学院
2026 年 6 月