華中科技大學

本科生毕业设计

基于大语言模型的课程知识命名实体识别与关系抽取

院　　系　计算机科学与技术学院

专业班级　计科 7 班

姓　　名　瞿明睿

学　　号　U202215561

指导教师　姚德中

2026 年 6 月

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包括任何其他个人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

作者签名：　　2026 年 6 月

学位论文版权使用授权书

本学位论文作者完全了解学校有关保障、使用学位论文的规定，同意学校保留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权省级优秀学士论文评选机构将本学位论文的全部或部分内容编入有关数据进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于 1、保　密 □，在　　年解密后适用本授权书

2、不保密 ☑。

（请在以上相应方框内打“✓”）

作者签名：　　2026 年 6 月

导师签名：　　2026 年 6 月

摘 要

课程知识的系统化组织对于计算机网络领域的教学与研究具有重要价值。传统人工构建知识图谱的方式存在效率低下、成本高昂、难以规模化等问题。针对上述挑战，探索基于大语言模型（Large Language Model，LLM）的自动化知识抽取技术，构建面向计算机网络课程材料的知识图谱构建系统。

采用七阶段流水线架构，实现从非结构化 PDF 文档到结构化知识图谱的完整转换流程。文档预处理阶段运用多模态视觉语言模型完成光学字符识别（Optical Character Recognition，OCR），将教材、讲义、试卷等 PDF 材料转换为结构化 Markdown 文本。针对长文档处理难题，设计基于标题层级感知的递归分块算法，结合令牌预算控制机制实现语义连贯的文本切分。知识抽取阶段采用两阶段范式，首先通过提示工程（Prompt Engineering）从中文课程文本中识别协议、概念、机制、指标四类专业实体类型，继而抽取包含、依赖、对比、应用四类语义关系，并引入证据验证门控机制确保三元组可溯源。为解决实体歧义问题，提出了基于稠密向量嵌入（Dense Embedding）的实体规范化方法，利用 FAISS 索引加速相似度检索，结合并查集（Union-Find）算法实现实体同一性判定与归并。知识融合完成后，数据批量导入 Neo4j 图数据库，并通过基于 Next.js 框架的前端可视化界面呈现交互式知识图谱，支持关系导航与查询探索。

实验基于 205 份计算机网络课程材料构建知识图谱，涵盖教材、课件、习题集及 RFC 文档共计 274 个输出目录。经处理生成 16,438 个文本块，总计约 1,040 万词元，平均块长 632.6 词元。最终知识图谱包含 23,600 个实体（概念 16,719 个、机制 3,063 个、协议 2,189 个、指标 1,629 个）与 44,526 条关系三元组，其中高频实体包括 TCP（2,657 次）、UDP（1,411 次）、IP（1,020 次）、HTTP（932 次）等。实验结果表明该系统能够有效处理大规模课程材料，提取的知识结构清晰、覆盖全面，为计算机网络课程教学提供了可计算的知识基础设施。

关键词：大语言模型；命名实体识别；关系抽取；知识图谱；课程知识；提示工程；实体规范化

Abstract

The systematic organization of course knowledge holds significant value for teaching and research in computer networking. Large Language Models have emerged as powerful tools for automated knowledge extraction, yet the annotation of domain-specific educational materials remains challenging due to specialized terminology and complex conceptual relationships. Manual construction of knowledge graphs suffers from low efficiency, high cost, and scalability limitations. Automated knowledge graph construction from unstructured course documents addresses these challenges and provides a foundation for intelligent educational applications.

A seven-stage pipeline was designed and implemented to transform unstructured PDF documents into structured knowledge graphs. Document preprocessing employs multimodal vision language models for optical character recognition, converting textbooks, lecture notes, and examination papers into structured Markdown text. A recursive header-aware text chunking algorithm was developed to address long document processing challenges, combining hierarchical heading awareness with token budget control to achieve semantically coherent text segmentation. The knowledge extraction stage adopts a two-phase paradigm with Chinese prompts. First, four entity types are identified from course texts: protocol, concept, mechanism, and metric. Then four semantic relation types are extracted: contains, depends_on, compared_with, and applied_to. Two extraction modes, zero-shot and few-shot, were implemented through prompt engineering. An evidence verification gating mechanism ensures triple traceability. To resolve entity ambiguity, an embedding-based entity canonicalization method was proposed, utilizing FAISS indexing for accelerated similarity retrieval and the Union-Find algorithm for entity identity determination and merging. Upon completion of knowledge fusion, data is batch-imported into Neo4j graph database and visualized through an interactive frontend built with the Next.js framework, supporting force-directed graph layout for relationship navigation and query exploration.

Experiments were conducted on a corpus of 205 computer networking course

documents, yielding 16,438 text chunks totaling approximately 10.4 million tokens. The resulting knowledge graph contains 23,600 entities (16,719 concepts, 3,063 mechanisms, 2,189 protocols, and 1,629 metrics) and 44,526 relational triples (15,251 contains, 14,291 applied_to, 9,601 depends_on, and 5,383 compared_with). Entity frequency ranges from 1 to 2,657 occurrences, with the most frequent entities being TCP (2,657), UDP (1,411), IP (1,020), and HTTP (932). The pipeline demonstrates effective automated knowledge graph construction for networking education, providing a computable knowledge infrastructure with clear structure and comprehensive coverage.

Keywords: Large Language Models, Named Entity Recognition, Relation Extraction, Knowledge Graph, Course Knowledge, Prompt Engineering, Entity Canonicalization

目 录

摘 要 ..... **I**

Abstract ..... **II**

1 绪 论 **1**

1.1 课题背景目的与意义 1

1.2 国内外研究现状 4

1.3 论文的主要内容与结构 8

2 相关技术基础 **11**

2.1 大语言模型基础 11

2.2 基于大模型的命名实体识别 14

2.3 基于大模型的关系抽取 17

2.4 知识图谱构建技术 18

2.5 教育领域知识图谱 20

2.6 本章小结 21

3 基于大模型的课程知识抽取系统设计 **22**

3.1 总体架构设计 22

3.2 文档预处理设计 23

3.3 文本分块设计 25

3.4 实体识别设计 26

3.5 关系抽取设计 28

3.6 知识融合设计 30

3.7 图存储与可视化设计 32

3.8 本章小结 33

4 系统实现 **36**

4.1 文档渲染与 OCR 实现 36

4.2 文本分块实现 37

4.3 知识抽取实现 37

4.4 知识融合实现 39
4.5 Neo4j 图数据库导入与前端可视化实现 41
4.6 本章小结 41
5 实验与结果分析 43
5.1 实验环境与配置 43
5.2 课程语料构建结果 44
5.3 实体抽取评估 45
5.4 关系抽取评估 47
5.5 知识图谱质量分析 48
5.6 案例分析 49
5.7 流水线性能分析 50
5.8 本章小结 51
6 总结与展望 52
致谢 55
参考文献 57

1 绪 论

知识图谱作为语义网络的知识表示形式，通过结构化的方式描述现实世界中的实体及其相互关系，已成为人工智能领域的重要基础设施。在教育信息化快速发展的背景下，课程知识的系统化组织与智能化应用对提升教学质量和学习效率具有重要意义。传统的知识图谱构建依赖于大量人工标注数据，在面对专业领域复杂的命名实体识别与关系抽取任务时，存在标注成本高、领域适应性差、知识更新滞后等突出问题。近年来，以 GPT、DeepSeek 等为代表的大语言模型展现出强大的自然语言理解与生成能力，为知识抽取任务提供了新的技术路径。基于大模型的零样本或少样本学习能力，能够在缺乏大规模标注语料的情况下实现高质量的信息抽取，为教育领域知识图谱的自动化构建带来了重要契机。

1.1 课题背景目的与意义

1.1.1 研究背景与趋势

命名实体识别（Named Entity Recognition, NER）和关系抽取（Relation Extraction, RE）是信息抽取领域的两项核心任务，旨在从非结构化文本中自动识别出预定义类型的实体并抽取出实体间的语义关系。这两项技术广泛应用于知识图谱构建、智能问答、文本挖掘等领域[1-2]。随着深度学习技术的发展，基于神经网络的方法在标准数据集上取得了显著进展，但这些方法通常依赖大量高质量的标注数据进行监督学习，在面对领域迁移和新实体类型时泛化能力有限。

在教育领域，课程知识的组织呈现出高度的专业性和结构性特征。以计算机网络课程为例，涉及大量协议实体（如 TCP、UDP、IP）、概念实体（如拥塞控制、流量整形）、机制实体（如三次握手、滑动窗口）和性能指标实体（如吞吐量、时延）。这些实体之间存在复杂的依赖关系和应用关系，构成了课程知识的核心骨架。然而，教育领域的知识抽取面临独特挑战：专业术语的歧义性、知识表达的多样性、以及证据可追溯性的要求，使得传统的有监督学习方法难以直接应用。

大语言模型的兴起为解决上述问题提供了新的思路。通过提示工程（Prompt Engineering）和上下文学习（In-Context Learning），大语言模型能够在仅提供少量示例甚至无示例的情况下完成特定任务[3]。这种能力对于标注数据稀缺的教育领域尤为重要。同时，大模型具备强大的语义理解能力，能够捕捉文本中隐含的语义关系，为复杂的关系抽取任务提供了技术支持。此外，大模型的涌现能力使其在处理复杂推理任务时表现出色，能够识别传统方法难以发现的隐性知识关联。预训练语言模型通过学习海量文本数据获得的知识表示，为理解领域特定的专业知识奠定了坚实基础。

当前，教育数字化转型已成为全球教育发展的重要趋势。智能教学系统、个性化学习推荐、自动答疑等应用对高质量的课程知识库提出了迫切需求。传统的课程知识组织方式主要依赖人工整理，效率低下且难以保证一致性。基于大语言模型的自动化知识抽取技术，为大规模课程知识库的构建提供了可行路径，有望显著提升教育资源的智能化水平。

1.1.2 面临的问题和挑战

尽管大语言模型在通用自然语言处理任务上表现出色，但在面向课程知识的信息抽取任务中仍面临诸多挑战：

首先，领域适应性不足。通用大语言模型虽然具备广泛的知识，但对于特定领域的专业术语和知识体系理解有限。课程知识涉及大量领域特定的概念和关系类型，需要针对教育场景进行专门的模型适配和提示设计。不同学科领域的知识表达方式存在差异，如何设计通用的领域适配框架是一个重要问题。特别是在处理计算机网络等专业课程时，涉及大量协议规范和技术细节，对模型的领域理解能力提出了更高要求。例如，同一个术语在不同上下文中可能指代不同的概念，模型需要结合上下文进行准确理解。

其次，输出结构化困难。大语言模型的输出本质上是自由文本，而知识图谱构建需要严格结构化的三元组数据。如何设计有效的提示策略和输出约束机制，确保模型生成符合规范的知识表示，是实际应用中的关键难题。特别是在处理复杂嵌套实体和多关系场景时，结构化的准确性直接影响后续知识融合的效果。模型输出中的格式错误、实体边界识别偏差、关系类型混淆等问题都会导致最

终知识图谱的质量下降。此外，如何设计可解析的输出格式，并处理模型偶尔产生的格式偏离，是工程实现中必须解决的问题。

再次，知识准确性验证困难。大语言模型存在”幻觉”（Hallucination）现象，可能生成看似合理但实际错误的信息。在教育场景中，知识准确性至关重要，需要建立有效的证据验证机制，确保抽取结果的可信度和可追溯性。此外，如何量化模型输出的置信度，并在低置信度情况下触发人工审核，也是实际部署中需要考虑的问题。对于关键的专业知识点，错误的抽取结果可能会对学习者产生误导，因此质量控制机制不可或缺。设计有效的证据溯源机制，将抽取出的知识与原文片段关联，是提升可信度的关键。

最后，规模化处理复杂。课程材料通常以 PDF、PPT 等多种形式存在，包含大量图文混排内容。如何构建端到端的自动化处理流水线，实现从原始文档到结构化知识的高效转换，是工程实现层面的重要挑战。同时，处理大规模文档时的计算效率和成本控制也是实际应用中必须考虑的因素。特别是对于包含复杂排版、数学公式、图表说明等技术文档，如何准确提取其中的知识内容是一个技术难点。此外，如何设计可扩展的架构以支持持续的知识更新和增量处理，也是长期运营中需要解决的问题。

1.1.3 课题目的与意义

本课题旨在研究基于大语言模型的课程知识命名实体识别与关系抽取方法，构建面向计算机网络课程的知识图谱自动化构建系统。具体研究目标包括：

第一，探索适用于教育领域的大模型提示策略。通过设计任务特定的提示模板，结合零样本和少样本学习方法，提升大模型在课程知识抽取任务上的性能。针对不同实体类型和关系类型设计差异化的提示策略，充分利用大模型的上下文学习能力。通过系统性的实验对比，确定最优的提示设计原则和参数配置。研究不同提示元素（如任务描述、示例、输出格式说明）对抽取性能的影响，建立提示工程的最佳实践指南。

第二，建立知识抽取的质量保障机制。引入证据验证和一致性检查机制，降低大模型生成错误知识的风险，确保知识图谱的准确性和可靠性。设计自动化的质量评估指标，实现对抽取结果的实时监控和反馈。建立人机协作的审核流

程，在保证效率的同时确保知识质量。开发冲突检测算法，识别并解决知识抽取过程中产生的逻辑矛盾和不一致问题。

第三，构建完整的知识图谱构建流水线。整合文档解析、文本预处理、实体识别、关系抽取、知识融合等环节，形成可复用的教育知识图谱构建方案。设计模块化架构，支持灵活的配置和扩展，以适应不同学科领域的知识抽取需求。实现从原始 PDF 文档到可视化知识图谱的全流程自动化处理。提供友好的配置接口和监控界面，降低系统的使用门槛。

本课题的研究具有重要的理论意义和应用价值。在理论层面，探索大模型在专业领域知识抽取中的应用模式，为领域自适应的信息抽取方法研究提供参考。研究成果有助于深化对大型语言模型在特定领域表现的理解，为提示工程和领域适配方法的发展提供实证支持。通过系统的实验设计和结果分析，揭示大模型在教育知识抽取任务中的能力边界和优化方向。为少样本和零样本场景下的信息抽取方法研究提供新的视角。

在应用层面，研究成果可直接应用于课程资源的智能化管理和个性化学习推荐，推动教育信息化的深入发展。构建的知识图谱可用于智能问答、学习路径推荐、知识点关联分析等教育应用场景，有效提升教学效果和学习体验。教师可以利用知识图谱快速定位课程重点，设计更有针对性的教学内容；学生可以通过知识图谱建立知识之间的关联，形成完整的知识体系。此外，研究成果还可推广到其他专业领域的知识图谱构建，具有广泛的适用性。

1.2 国内外研究现状

1.2.1 基于大模型的命名实体识别

近年来，利用大语言模型进行命名实体识别的方法取得了显著进展，研究者从提示设计、输出约束、数据增强等多个角度进行了探索。

GPT-NER[4] 提出了一种基于特殊标记的提示转换方法，通过引入”@@##”等标记符将 NER 任务转化为大模型易于理解的文本生成任务，并结合自验证机制提升识别准确率。该方法有效解决了大模型在结构化预测任务上的格式遵循问题，使得模型输出能够直接解析为结构化的实体标注结果。实验表明，该方法

在多个标准数据集上取得了与监督学习方法相当甚至更好的性能。研究团队还探索了不同标记符设计对模型性能的影响，发现特定的分隔符组合能够显著提升实体边界识别的准确性。通过引入自一致性检查，进一步降低了格式错误的发生率。

SLIMER[5] 针对少样本 NER 场景，提出了基于实体类型定义和标注指南的提示设计框架。该方法为每种实体类型提供详细的定义描述和标注规范，引导大模型更好地理解任务要求，在跨领域 NER 任务上取得了良好效果。研究还发现，为实体类型添加具体的示例和边界案例能够显著提升模型的识别准确率。通过引入负例说明，帮助模型理解哪些文本片段不应被识别为特定类型的实体，有效降低了误识别率。该方法的核心思想是利用人类标注知识来指导模型学习，即使在没有大量标注数据的情况下也能取得良好效果。

CodeIE[6] 探索了将 Python 代码作为提示的新范式，利用代码的结构化特性引导大模型生成结构化的 NER 输出。研究表明，代码风格的提示相比自然语言提示在结构化预测任务上具有明显优势，因为代码的语法约束能够更好地引导模型生成符合格式要求的输出。该方法在零样本和少样本设置下均展现出良好的泛化能力，能够适应新的实体类型而无需重新训练模型。代码表示还便于集成复杂的约束规则和验证逻辑，进一步提升了抽取质量。

LLM-DA[7] 聚焦于数据增强方向，提出了基于大模型的上下文级和实体级数据增强方法。通过在上下文层面进行语义变换、在实体层面进行同义词替换和边界扰动，有效扩充了训练数据的多样性。该方法对于缓解少样本场景下的数据稀缺问题具有重要价值，能够显著提升模型的鲁棒性和泛化能力。研究团队还提出了基于大模型的数据质量评估方法，自动筛选高质量的增强样本。通过迭代增强策略，逐步扩充训练数据集，在保持数据质量的同时提升数据规模。

1.2.2 基于大模型的关系抽取

在关系抽取领域，大语言模型同样展现出强大的潜力，研究者从示例选择、推理机制、任务分解等方面进行了深入探索。

GPT-RE[8] 提出了一种任务感知的示例检索策略，根据输入文本与候选示例的语义相似度动态选择最优的上下文示例，显著提升了少样本关系抽取的性能。

该方法通过引入实体感知的示例编码机制，使模型能够更好地理解与当前任务相关的上下文信息，从而在复杂的关系分类任务中取得更好的效果。实验结果显示，合理的示例选择策略对最终性能的影响甚至超过了模型规模的选择。研究团队还探索了动态示例库更新机制，随着系统运行不断积累高质量示例。

Revisiting-RE[9] 系统分析了链式思维（Chain-of-Thought, CoT）推理在关系抽取任务中的作用，发现显式引导大模型进行逐步推理能够有效提升复杂关系的识别准确率，尤其是在涉及多跳推理的场景中。研究还探讨了不同推理路径设计对最终性能的影响，为提示工程的设计提供了有价值的指导。研究发现，关系特定的推理模板比通用模板能够取得更好的效果。通过将复杂的关系判断分解为多个简单的推理步骤，降低了模型的判断难度。

AutoRE[10] 提出了一种基于关系-头实体-事实（Relation-Head-Fact）分解的抽取范式，通过将复杂的关系抽取任务分解为多个子任务，降低了大模型的生成难度。该方法结合了强化学习从人类反馈（RLHF）的训练范式，使模型输出更加符合知识图谱的结构要求。实验结果表明，分解策略能够有效减少关系抽取中的错误传播问题，提升端到端的抽取质量。该方法的核心优势在于模块化设计，每个子任务可以独立优化和评估。

1.2.3 统一信息抽取与知识图谱构建

统一信息抽取框架旨在通过单一模型同时完成实体识别、关系抽取等多项任务，提升系统的整体效率和一致性。

InstructUIE[11] 提出了基于指令微调的多任务信息抽取框架，通过设计统一的指令格式将不同类型的信息抽取任务转化为一致的文本到文本生成问题，实现了跨任务的知识迁移。该方法在多个信息抽取任务上取得了统一的最先进性能，证明了统一框架在处理多样化抽取任务时的优势。研究团队还发布了大规模的多任务指令数据集，为后续研究提供了重要的数据基础。通过统一编码，模型能够学习不同任务之间的共享知识，提升整体泛化能力。

GoLLIE[12] 延续了代码作为提示的思想，将标注指南编码为 Python 类型定义和约束条件，利用大模型的代码理解能力进行结构化信息抽取。该方法在零样本场景下展现出良好的泛化能力，能够适应新的实体类型和关系类型而无需重

新训练。代码形式的约束条件使得模型能够更准确地理解抽取任务的边界和要求，同时便于集成复杂的业务规则。该方法的优势在于可解释性强，便于调试和验证。

OneKE[13] 提出了一种多智能体协作的知识抽取架构，通过调度多个专门化的抽取智能体分别负责实体识别、关系分类、属性抽取等子任务，再通过融合模块整合各智能体的输出，提升了整体抽取质量。该架构的优势在于能够充分利用不同智能体的专长，通过协作机制实现优于单一模型的抽取效果。系统还引入了置信度加权机制，在融合过程中优先采纳高置信度的预测结果。智能体之间的通信协议设计是该系统的关键创新点。

在教育领域知识图谱构建方面，Educational-KG-Pipeline[14] 提出了一套面向教育资源的五阶段知识图谱构建流水线，涵盖数据采集、预处理、知识抽取、知识融合和图谱存储等环节，为教育领域的知识图谱构建提供了系统性的解决方案。Graphusion[15] 则专注于零样本知识图谱构建，提出了基于多源知识融合的图谱扩展方法，能够在缺乏标注数据的情况下实现知识图谱的自动构建和扩展。

1.2.4 教育领域知识图谱

教育领域的知识图谱研究近年来受到广泛关注，研究者探索了多种面向教育场景的知识图谱构建和应用方法。

LLM-Curriculum-KG[16] 探索了人机协作的课程知识建模方法，通过结合大模型的自动抽取能力和领域专家的知识校验，实现了高质量的课程知识体系构建。该方法强调了人在回路（Human-in-the-Loop）的重要性，在保证知识准确性的同时提升了构建效率。研究还提出了面向课程知识的专门化实体类型体系和关系模式，为教育领域的知识表示提供了参考。实验结果表明，人机协作模式相比纯自动或纯人工方式，在效率和质量之间取得了更好的平衡。

LLMs-KG-Survey[3] 对基于大语言模型的知识图谱技术进行了全面综述，系统分析了提示工程、指令微调、检索增强生成等技术在知识抽取、知识补全、知识推理等任务中的应用，指出了当前研究的主要挑战和未来发展方向。综述特别强调了领域适应性和知识质量控制在实际应用中的重要性，为后续研究指明了方向。该综述还建立了一套评估框架，用于比较不同方法在知识准确性、覆盖

率和一致性等方面的表现。

综合以上研究现状可以看出，基于大语言模型的信息抽取技术正在快速发展，但在面向教育领域的课程知识抽取方面仍存在研究空白。如何设计适用于教育场景的领域特定提示策略、如何建立有效的知识质量保障机制、如何构建端到端的自动化处理流水线，是本课题需要重点解决的问题。特别是在处理教育领域特有的复杂知识结构和多源异构数据方面，仍需要进一步探索有效的技术方案。本课题将针对上述问题展开深入研究，力争在课程知识抽取领域取得创新性成果。

1.3 论文的主要内容与结构

1.3.1 论文主要内容

本课题围绕基于大语言模型的课程知识命名实体识别与关系抽取展开研究，构建了面向计算机网络课程的知识图谱自动化构建系统。主要研究内容包括：

（1）多源课程语料库构建

构建了包含 205 份 PDF 文档的多源课程语料库，涵盖教材、课件、实验指导、RFC 文档等多种类型。设计了标准化的文档预处理流程，实现从 PDF 到结构化文本的自动转换，最终生成 16,438 个文本块，总计约 1,040 万词元（tokens），为后续的知识抽取提供了丰富的数据基础。针对不同来源的文档特点，设计了差异化的解析策略，确保文本提取的完整性和准确性。对于包含复杂排版的技术文档，采用了专门的处理方法以保留知识结构信息。建立了文档元数据管理系统，记录每份文档的来源、类型、处理状态等信息。

（2）基于大模型的命名实体识别

针对课程知识的特点，定义了协议、概念、机制、性能指标四类实体类型。设计了零样本和少样本两种提示策略，通过任务特定的提示模板引导大模型识别文本中的命名实体。实验表明，该方法在缺乏大规模标注数据的情况下仍能达到较高的识别准确率。针对不同实体类型的特点，设计了差异化的提示模板和示例选择策略，进一步提升了识别效果。引入了实体链接机制，将识别出的实体与标准化术语库进行关联，解决了实体歧义和同义词问题。

（3）基于大模型的关系抽取

定义了包含、依赖、对比、应用于四类关系类型。提出了”提议-审核”两阶段抽取策略，第一阶段由大模型生成候选关系三元组，第二阶段通过证据验证机制确保抽取结果的准确性和可追溯性。引入了关系约束规则，对不符合逻辑的关系进行过滤，有效降低了错误率。同时，设计了关系置信度评估机制，为后续知识融合提供质量依据。对于复杂的多跳关系，设计了迭代抽取策略逐步构建关系链。建立了关系类型层次结构，支持细粒度的关系分类。

（4）知识抽取流水线设计

设计了涵盖文档解析、图像转换、文本识别、文本分块、知识抽取、知识融合、图谱导入七个环节的自动化处理流水线。各模块之间通过标准化接口进行数据交换，支持灵活的配置和扩展。实现了基于配置文件的流水线编排，用户可根据需求自定义处理流程和参数设置。流水线支持断点续处理和增量更新，提高了大规模数据处理的效率。同时提供了详细的日志记录和进度监控功能，便于用户了解处理状态。设计了错误处理机制，对于处理失败的文档能够自动记录并重试。

（5）应用验证与系统实现

在计算机网络课程数据上进行了全面的应用验证，最终构建的知识图谱包含 23,600 个实体和 44,526 个关系三元组。其中，高频实体包括 TCP 协议（2,657 次）、UDP 协议（1,411 次）、IP 协议（1,020 次）等，准确反映了课程知识的核心内容。开发了基于 Web 的可视化界面，支持知识图谱的交互式浏览和查询，验证了系统的实用性和可用性。通过多个典型应用场景的测试，验证了知识图谱在教学辅助、学习推荐等方面的应用价值。实现了与现有教学平台的集成，支持知识的动态更新和同步。

1.3.2 论文结构

本论文共分为六章，各章内容安排如下：

第一章绪论。介绍课题的研究背景、目的与意义，分析当前国内外研究现状，阐述论文的主要研究内容和组织结构。

第二章相关技术概述。介绍知识图谱、命名实体识别、关系抽取的基础概念

和技术方法，重点阐述大语言模型的基本原理及其在信息抽取任务中的应用。

第三章课程知识图谱构建方案设计。详细阐述系统的整体架构设计、知识 schema 定义、数据预处理流程以及大模型提示策略的设计。

第四章知识抽取系统实现。介绍系统的具体实现细节，包括核心模块的算法设计、流水线编排机制、知识融合策略以及可视化界面开发。

第五章实验与评估。介绍实验数据集、评价指标和实验设置，展示命名实体识别和关系抽取的实验结果，进行消融实验和对比分析。

第六章总结与展望。总结课题的主要研究成果和创新点，分析存在的不足，并对未来的研究方向进行展望。

2 相关技术基础

本章系统性地介绍与课程知识命名实体识别和关系抽取相关的技术基础。首先阐述大语言模型的核心架构原理与关键技术，为后续章节的模型选型与提示工程设计奠定理论基础；其次综述基于大模型的命名实体识别方法，包括零样本学习、少样本学习及代码提示等范式；继而探讨基于大模型的关系抽取技术，涵盖句子级与文档级关系抽取的最新进展；随后介绍知识图谱构建的完整技术栈，包括流水线框架与实体规范化方法；最后聚焦教育领域的知识图谱应用实践，分析现有方案的特点与局限。通过对相关技术的全面梳理，为后续章节中课程知识抽取系统的设计与实现提供理论支撑和方法参考。

2.1 大语言模型基础

大语言模型（Large Language Models, LLMs）是基于深度学习技术构建的具有海量参数规模的自然语言处理模型。这类模型通过在超大规模文本语料上进行自监督预训练，获得了强大的语言理解和生成能力，并展现出涌现能力和上下文学习能力。本节从架构原理、预训练范式和扩展能力三个维度介绍大语言模型的技术基础。

2.1.1 Transformer 架构

Transformer 架构于 2017 年由 Vaswani 等人提出，现已成为现代自然语言处理系统的基石[17]。该架构完全基于注意力机制，摒弃了传统的循环神经网络结构，实现了计算的高度并行化。其核心创新包括三个关键组件：自注意力机制（Self-Attention）、多头注意力（Multi-Head Attention）以及位置编码（Positional Encoding）。

自注意力机制通过计算序列中每个位置与其他所有位置之间的注意力权重，使模型能够捕捉长距离依赖关系。给定输入序列 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, ..., \mathbf{x}_n]$，自注意力的计算过程可形式化为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2-1}$$

其中 Q、K、V 分别代表查询（Query）、键（Key）和值（Value）矩阵，d_k 为键向量的维度。缩放因子 $\sqrt{d_k}$ 用于缓解点积运算导致的梯度消失问题。自注意力机制的优势在于能够直接建模序列中任意两个位置之间的关系，不受距离限制，克服了 RNN 处理长序列时的梯度消失问题。

多头注意力机制通过将输入投影到多个子空间并并行计算注意力，使模型能够从不同表示子空间中联合关注不同位置的信息。设有 h 个注意力头，则多头注意力的输出为：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, ..., \text{head}_h)W^O \tag{2-2}$$

其中每个 $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$，$W$ 为可学习的投影矩阵。多头机制允许模型在不同子空间中关注不同类型的信息，如语法结构、语义关系等，显著提升了模型的表达能力。研究表明，不同的注意力头确实学习到了不同的语言特征，有的关注句法依赖，有的关注语义关联。

由于 Transformer 不含循环或卷积结构，位置编码被引入以注入序列顺序信息。原始 Transformer 采用正弦余弦函数编码绝对位置：

$$PE_{(pos,2i)} = \sin(pos/10000^{2i/d_{model}}) \tag{2-3}$$

$$PE_{(pos,2i+1)} = \cos(pos/10000^{2i/d_{model}}) \tag{2-4}$$

后续研究表明，可学习的绝对位置编码和相对位置编码在特定任务中表现更优。特别是 RoPE（Rotary Position Embedding）和 ALiBi（Attention with Linear Biases）等相对位置编码方案，在处理长序列时展现出更好的外推能力，能够支持更长的上下文窗口。

2.1.2 GPT 系列与自回归预训练

GPT（Generative Pre-trained Transformer）系列模型采用自回归语言建模范式进行预训练。该范式通过最大化序列的似然概率来学习语言表示，即：

$$\mathcal{L} = \sum_{i=1}^{n} \log P(x_i|x_1, ..., x_{i-1}; \theta) \tag{2-5}$$

这种单向建模方式使 GPT 系列模型特别擅长文本生成任务。在预训练阶段，模型在大规模无标注语料上学习语言的统计规律和语义表示；在下游任务中，通过微调或提示工程将预训练知识迁移到特定应用场景。

GPT-3 的发布标志着大语言模型进入新纪元[18]。该模型拥有 1750 亿参数，展示了强大的上下文学习能力（In-Context Learning）。上下文学习指模型无需参数更新，仅通过输入中的少量示例即可适应新任务。研究表明，这种能力源于预训练过程中对多样任务的隐式学习，使模型能够将输入中的示例模式泛化到待预测样本。GPT-3 在翻译、问答、摘要等多种任务上展现出接近监督学习方法的性能，验证了大模型作为通用任务求解器的潜力。

上下文学习的有效性高度依赖于提示（Prompt）的设计。Brown 等人的研究表明，通过精心设计的任务描述和示例，GPT-3 在多项自然语言理解任务上达到了接近微调模型的性能。这一发现催生了提示工程（Prompt Engineering）研究方向的兴起。后续研究进一步揭示了上下文学习的内在机制，包括示例的选择策略、示例顺序的影响、以及标签空间覆盖的重要性等关键因素。

2.1.3 提示工程技术

提示工程是优化大语言模型输入以提升任务性能的技术体系。根据所需示例数量，提示策略可分为零样本（Zero-Shot）、少样本（Few-Shot）和思维链（Chain-of-Thought）三种范式。

零样本提示直接向模型提供任务描述和待处理输入，无需任何标注示例。该方法的优势在于无需准备训练数据，适用于快速原型验证和资源受限场景。然而，对于复杂任务，零样本提示的性能往往受限。为提升零样本性能，研究者提出了指令微调（Instruction Tuning）技术，通过在多样化的指令-响应对上微调模型，增强其理解和执行新指令的能力。

少样本提示通过在输入中嵌入若干标注示例，引导模型理解任务模式。研究表明，示例的选择、顺序和格式对性能有显著影响。有效的少样本提示应确保示例与测试样本在分布上保持一致，并覆盖任务的主要变化模式。KATE、EPR 等方法通过检索与测试样本相似的示例来优化提示效果；Self-Generated In-Context Learning 则利用模型自身生成示例，进一步降低对人工标注的依赖。

思维链提示由 Wei 等人提出，通过在示例中展示中间推理步骤，激发模型的逐步推理能力。该方法将复杂问题分解为一系列可解释的推理步骤，显著提升了模型在算术推理、常识推理和符号推理任务上的表现。后续研究在此基础

上发展了自一致性解码（Self-Consistency）、思维树（Tree of Thoughts）等增强技术。自一致性通过多次采样并选择最一致的答案来提升推理可靠性；思维树则通过探索多条推理路径并评估各路径的可行性，实现了更复杂的决策过程。

2.1.4 多模态大语言模型

多模态大语言模型（Multimodal LLMs）扩展了纯文本模型的能力边界，使其能够理解和生成涉及视觉、音频等多种模态的内容。在知识抽取领域，视觉-语言模型（Vision-Language Models）尤为重要，因其可直接处理扫描文档、幻灯片等图像格式的课程材料，无需额外的 OCR 预处理步骤。

典型的视觉-语言模型架构包含视觉编码器、投影层和语言模型三部分。视觉编码器（如 ViT、CLIP）将输入图像编码为视觉特征序列；投影层负责将视觉特征映射到语言模型的语义空间；语言模型则基于融合后的多模态表示生成文本输出。早期的视觉-语言模型如 BLIP、Flamingo 等通过端到端训练实现跨模态对齐；近期的工作如 LLaVA、Qwen-VL 等则采用两阶段训练策略，先进行视觉-语言对齐预训练，再进行指令微调以获得遵循指令的能力。

Qwen-VL、InternVL 等模型在文档理解、图表解析等任务上表现出色，为教育材料的自动化处理提供了技术基础。这些模型能够识别图像中的文本内容、理解版面布局、解析表格和图示结构，大幅提升了从非结构化文档中提取结构化信息的能力。特别是对于包含复杂排版和数学公式的学术材料，多模态模型的端到端处理能力优于传统的 OCR+ 文本处理流水线。

2.2 基于大模型的命名实体识别

命名实体识别（Named Entity Recognition, NER）是从非结构化文本中识别和分类命名实体的任务。传统方法依赖大量标注数据和特定领域的特征工程，而基于大模型的方法通过提示工程实现了低资源甚至零资源场景下的实体识别。根据利用训练数据的方式，现有方法可分为零样本、少样本和代码提示三类范式。

2.2.1 零样本命名实体识别

零样本 NER 指在无任何标注样本的情况下，仅依靠任务描述和实体类型定义完成实体识别。这一设定对于快速适应新领域、新实体类型具有重要价值。SLIMER 是该领域的代表性工作[5]，其核心思想是通过丰富的实体定义和标注指南弥补训练数据的缺失。SLIMER 采用单实体类型每查询（Single Entity Type Per Query）的策略，将多类型 NER 任务分解为多个二分类子任务，显著降低了任务的复杂度。该方法通过详细的类型描述、边界说明和示例来指导模型进行精确识别，在多个基准数据集上取得了优于传统零样本方法的性能。

UniversalNER 探索了利用 ChatGPT 进行自动标注并蒸馏至小模型的技术路线[19]。该方法首先使用 ChatGPT 生成大规模弱监督数据，然后通过知识蒸馏将大模型的能力迁移到轻量级学生模型。具体而言，UniversalNER 设计了一系列针对 NER 任务的提示模板，引导 ChatGPT 生成高质量的伪标注数据；然后使用这些数据训练专门的 NER 模型。实验表明，这种范式在开放域 NER 任务上取得了竞争性表现，同时大幅降低了推理成本。

GLiNER 提出了一种基于双向 Transformer 的实体-跨度匹配架构[20]。与传统的序列标注方法不同，GLiNER 将 NER 建模为实体类型与文本跨度之间的匹配问题，通过计算类型表示与跨度表示的相似度预测实体边界和类型。该方法的创新之处在于将实体类型视为可学习的嵌入，使其能够泛化到训练时未见过的新类型。GLiNER 在零样本和少样本场景下均表现出色，且支持任意实体类型的灵活扩展，为实际应用提供了高效可行的解决方案。

2.2.2 少样本命名实体识别

少样本 NER 利用少量标注示例引导大模型适应特定领域和实体类型。GPT-NER 提出了一种基于特殊标记的实体标注范式[4]，使用 `@@` 和 `##` 标记实体边界，将 NER 转化为大模型擅长的文本生成任务。这种标记方式与 GPT 模型的预训练目标更加契合，能够更好地激发模型的标注能力。为进一步提升性能，GPT-NER 引入了三层次演示检索策略，分别从句子级、实体级和词级检索相似示例，确保检索到的示例在多个粒度上与测试样本相关。此外，GPT-NER 还通过自验证机

制过滤低质量预测，提高了输出结果的可靠性。

Self-Improving NER 框架通过自一致性投票和可靠性筛选实现模型性能的自我迭代提升[21]。该方法首先使用不同提示变体生成多组预测结果，然后通过一致性投票确定高置信度预测；接着，基于可靠性指标筛选优质伪标签用于下一轮训练。这种自举式学习策略有效降低了对人工标注的依赖，使得模型能够从自身的预测中持续学习和改进。实验表明，经过若干轮迭代后，模型性能可以显著提升，甚至在某些任务上接近全监督方法的性能。

LLM-DA（LLM-based Data Augmentation）从上下文和实体两个层面实现数据增强[7]。在上下文层面，该方法利用大模型生成与原始句子语义相似的变体，同时保持实体位置不变；在实体层面，通过实体替换和同义词扩展丰富实体表达的多样性。增强后的数据与原始少样本数据联合训练，显著提升了模型的泛化能力。LLM-DA 的创新之处在于利用大模型的语言理解能力进行语义保持的数据增强，生成的样本质量高于传统的基于规则的增强方法。

2.2.3 代码提示范式

Code-as-Prompt 是一类新兴的提示范式，通过将信息抽取任务表示为代码形式，利用大模型的代码理解能力提升任务性能。CodeIE 是该方向的开创性工作[6]，将 NER 和关系抽取任务转化为 Python 代码的生成任务。例如，实体识别被建模为从文本中提取特定类型值的函数实现，关系抽取则被建模为返回实体对的函数。实验表明，代码形式的提示在自然语言理解任务上优于纯文本提示，这可能源于代码的结构化特性和大模型在代码预训练中获得的能力。代码表示能够更清晰地表达任务结构和约束条件，减少了自然语言歧义带来的理解偏差。

GoLLIE 进一步扩展了代码提示范式[12]，引入 Python 类定义来表示实体和关系的模式（Schema）。每个实体类型和关系类型被定义为具有特定属性和文档字符串的 Python 类，文档字符串中详细描述了类型的定义和标注指南。这种表示方式实现了模式定义与提示模板的统一，支持复杂嵌套结构的抽取。GoLLIE 在多个 IE 基准测试上取得了当时的最优性能，验证了代码提示范式的有效性。该方法的优势在于能够利用代码的类型系统和结构化特性来表达复杂的抽取模式，同时借助大模型的代码理解能力进行精确解析。

2.3 基于大模型的关系抽取

关系抽取（Relation Extraction, RE）旨在识别文本中实体之间的语义关系。与命名实体识别相比，关系抽取需要建模实体对之间的复杂交互，任务难度更高。基于大模型的关系抽取方法在少样本和零样本场景下展现出独特优势，能够利用预训练知识快速适应新的关系类型和领域。

2.3.1 少样本关系抽取

GPT-RE 针对少样本关系抽取提出了任务感知演示检索和金标签诱导推理两大技术[8]。任务感知检索基于实体对和关系标签的联合相似度选择演示示例，确保示例与查询在实体分布和关系模式上保持高度一致；金标签诱导推理则在提示中显式引导模型关注实体提及位置，并通过标签语义信息约束预测空间。这两项技术的结合使 GPT-RE 在 FewRel 等基准上取得了显著性能提升。GPT-RE 还探讨了不同检索策略和提示格式对性能的影响，为少样本关系抽取的实践提供了系统性的指导。

Self-Prompting 框架通过三阶段流程实现自动化的少样本关系抽取[22]。第一阶段利用大模型生成多样化的合成样本，覆盖关系类型的多种表达模式；第二阶段对生成的样本进行质量筛选和去重，保留高质量的伪标注数据；第三阶段基于筛选后的样本自动构建提示模板，无需人工设计。这种自引导式方法降低了对人工编写示例的依赖，提升了方法的实用性和可移植性。Self-Prompting 的核心洞察在于，大模型自身具备生成合理训练样本的能力，通过适当的引导和筛选可以构建有效的自我监督流程。

2.3.2 文档级关系抽取

文档级关系抽取需要处理跨越多个句子的长文本，识别显式提及或隐式蕴含的实体关系。这一任务比句子级关系抽取更具挑战性，需要建模复杂的指代消解和跨句推理能力。AutoRE 提出了关系-头部-事实（Relation-Head-Fact, RHF）的统一范式[10]，将关系抽取分解为关系识别、头部实体定位和事实抽取三个子任务。该方法采用 QLoRA 进行参数高效微调，在 DocRED 等文档级基准上实现了

优异性能。RHF 范式的优势在于将复杂的文档级关系抽取分解为多个可管理的子任务，降低了学习难度并提升了可解释性。

Revisiting-RE 系统分析了文档级关系抽取中的关键挑战[9]，提出结合思维链增强和人工评估的混合策略。研究表明，直接应用大模型进行文档级关系抽取面临实体指代消解困难、长距离依赖建模复杂等问题；引入逐步推理提示和人工反馈的迭代优化可有效缓解这些问题。该工作为后续研究提供了重要的经验参考，特别是在评估协议和错误分析方面的深入探讨，揭示了当前方法的局限性和改进方向。

2.3.3 零样本关系抽取

GLiREL 延续了 GLiNER 的设计理念，将零样本关系抽取建模为关系类型与实体对之间的匹配问题[23]。该模型采用轻量级双向 Transformer 架构，通过单次前向传播计算所有候选实体对和关系类型的匹配分数，实现了高效的推理。GLiREL 支持任意关系类型的灵活扩展，无需针对新类型重新训练，具有很强的实用价值。该方法的创新之处在于将关系类型编码为可学习的嵌入向量，通过计算实体对表示与关系类型表示的兼容性来预测关系。

REPaL（Relation Extraction with Pairwise Loss）探索了仅依赖关系定义完成零样本抽取的可能性[24]。该方法利用大模型生成关系定义的语义嵌入，通过对比学习使相关实体对的表示接近、无关实体对的表示远离。REPaL 在零样本文档级关系抽取任务上取得了领先性能，证明了关系定义本身蕴含丰富的语义信息。REPaL 的优势在于完全不依赖标注样本，仅通过关系类型的自然语言描述即可进行抽取，特别适用于快速构建原型系统和处理不断涌现的新关系类型。

2.4 知识图谱构建技术

知识图谱构建涉及实体识别、关系抽取、实体链接、知识融合等多个环节。近年来，大语言模型凭借其强大的语义理解能力，在知识图谱构建的各个环节中得到广泛应用。本节从流水线框架和实体规范化两个方面介绍相关技术进展。

2.4.1 流水线框架

LLMs-KG-Survey 系统综述了利用大模型构建知识图谱的研究进展[3]。该综述将现有方法分为自主构建和协同构建两类，并分析了各类方法的优势与局限。特别地，该工作提出了 AutoKG 多智能体框架，通过规划、抽取、验证、修正等多个智能体的协作，实现了端到端的自动化知识图谱构建。AutoKG 的设计体现了模块化思想，各智能体专注于特定子任务并通过消息传递进行协作，提升了系统的可扩展性和鲁棒性。

InstructUIE 采用多任务指令微调策略统一处理信息抽取任务[11]。该方法将 NER、关系抽取、事件抽取等多种任务统一为文本到文本的生成任务，通过自然语言指令描述任务需求。指令微调使模型具备任务泛化能力，在未见过的任务类型和领域上仍能保持合理性能。InstructUIE 的贡献在于展示了统一框架处理多种 IE 任务的潜力，为构建通用的信息抽取系统提供了可行路径。

OneKE 提出了基于 Schema 引导的多智能体知识抽取框架[13]。该框架首先利用大模型从领域文档中自动抽取 Schema 定义，然后基于 Schema 指导抽取智能体识别实体和关系，最后通过验证智能体确保抽取结果的一致性和完整性。OneKE 在教育、医疗等垂直领域展现出良好的适应性。Schema 引导是该框架的核心创新，通过显式的 Schema 约束提升了抽取的准确性和一致性，同时降低了人工设计模式的开销。

2.4.2 实体规范化

实体规范化（Entity Canonicalization）旨在识别指代同一现实实体的不同提及，是知识图谱构建中的关键环节。EDC 提出了抽取-定义-规范化的三阶段方法[25]：首先从文本中抽取候选实体，然后利用大模型为每个实体生成语义定义，最后基于定义相似度进行实体聚类和规范化。该方法有效处理了实体表达的多样性问题。通过引入语义定义作为中间表示，EDC 能够捕捉实体提及的深层语义信息，而不仅依赖表面的字符串相似度。

KGGen 探索了聚类与大模型混合迭代的实体去重策略[26]。该方法首先使用传统聚类算法进行初步分组，然后利用大模型对每个聚类进行语义审核和合并

决策；该过程迭代执行直至收敛。这种混合策略兼顾了效率和准确性，在大规模知识图谱构建中表现出色。KGGen 的创新之处在于结合了传统聚类的高效性和大模型的语义理解能力，通过迭代优化逐步提升规范化质量。

SAC-KG 设计了生成器-验证器-剪枝器的三组件架构[27]。生成器负责从源文本中抽取候选实体和关系；验证器基于大模型评估三元组的事实性和一致性；剪枝器则移除低质量或重复的三元组。三组件的协同工作确保了知识图谱的高精度和低冗余。SAC-KG 的设计体现了质量控制贯穿知识图谱构建全过程的理念，通过多重验证机制过滤噪声并保证数据质量。

2.5 教育领域知识图谱

教育领域知识图谱面向课程教材、学术论文等教育资源，旨在构建结构化的学科知识体系，支撑智能问答、学习路径推荐等教育应用。与通用领域知识图谱相比，教育领域知识图谱具有概念层次清晰、知识关联密集、应用场景特定等特点。本节综述近年来教育领域知识图谱构建的代表性工作。

Educational-KG-Pipeline 提出了面向教育资源的五阶段知识图谱构建流水线[14]。该流水线包括文档解析、实体识别、关系抽取、实体链接和知识融合五个阶段，针对 PDF、PPT 等格式的课程材料进行了专门优化。在文档解析阶段，该方法处理教育材料中常见的复杂版面和多媒体元素；在后续阶段，则针对教育领域的实体类型和关系模式设计了专门的抽取策略。实验表明，该流水线在计算机网络课程数据集上将 F1 分数从 40% 提升至 47%，验证了专用架构在教育场景的有效性。

Graphusion 专注于概念知识图谱的构建[15]，采用种子概念扩展、候选三元组生成、全局融合的三阶段策略。该方法从少量人工标注的种子概念出发，利用大模型自动发现相关概念和关系；然后通过全局一致性约束解决冲突和冗余；最后构建了 TutorQA 基准数据集用于教育问答评估。Graphusion 在概念覆盖度和关系准确性方面表现出色。该工作的贡献在于提出了一种低成本的概念图谱构建方法，通过种子引导和自动扩展减少了对大规模人工标注的依赖。

LLM-Curriculum-KG 探索了人机协作的课程知识图谱构建模式[16]。该工作设计了课程-领域-用户三层本体结构，课程层描述课程大纲和章节组织，领域层

涵盖学科概念和知识关联，用户层记录学习者的知识状态和学习轨迹。大模型负责自动抽取和初步验证，人工专家进行质量审核和领域知识补充，形成了高效的协同工作机制。这种人机协作模式充分发挥了大模型的自动化处理能力和人类专家的专业判断能力，为教育知识图谱的可持续构建提供了可行方案。

2.6 本章小结

本章系统梳理了课程知识命名实体识别与关系抽取的相关技术基础。首先阐述了大语言模型的核心架构，包括 Transformer 的自注意力机制、GPT 系列的自回归预训练范式以及多模态扩展，为后续技术讨论奠定了理论基础；其次综述了基于大模型的命名实体识别方法，涵盖零样本、少样本和代码提示三类范式，分析了各类方法的核心思想和适用场景；继而探讨了关系抽取技术，分析了句子级和文档级场景下的最新进展，包括任务感知检索、自引导提示和零样本匹配等关键方法；随后介绍了知识图谱构建的完整技术栈，包括流水线框架和实体规范化方法；最后聚焦教育领域，分析了现有知识图谱方案的特点和局限。这些技术为后续章节中课程知识抽取系统的设计与实现提供了理论基础和方法参考。

3 基于大模型的课程知识抽取系统设计

知识图谱的构建质量取决于从非结构化文本中抽取实体与关系的准确性和一致性，而课程教材又具有层级结构深、专业术语密集、中英文混用等独特挑战。本章从系统总体架构出发，依次阐述文档预处理、文本分块、实体识别、关系抽取、知识融合以及图存储与可视化等核心模块的设计方案，重点说明每个设计决策背后的动机与权衡。

3.1 总体架构设计

3.1.1 七阶段流水线架构

课程知识抽取系统采用七阶段串行流水线架构，将原始教材文档逐步转化为可交互的知识图谱。七个阶段依次为：文档转图、OCR 识别、文本分块、三元组抽取、三元组合并、图数据库导入和前端可视化，如图3-1所示。

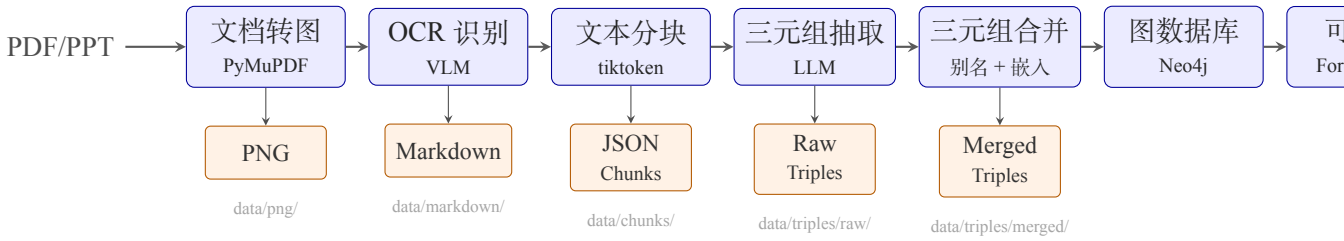

图 3-1 七阶段流水线总体架构

采用七阶段串行架构的设计动机如下：

（1）**关注点分离**。每个阶段拥有明确的输入契约与输出契约，职责单一。例如文档转图阶段只负责将 PDF/PPT 渲染为 PNG 图像，不关心后续 OCR 如何处理；OCR 阶段只负责图像到文本的转换，不关心文本如何分块。这种分离使得各阶段可以独立设计、独立测试、独立演进。

（2）**模块化与可替换性**。每个阶段对应一个独立的 CLI 命令（如 `pdftopng`、`pngtotext`、`mdchunk` 等），阶段之间通过文件系统中的中间产物（PNG、Markdown、JSON）进行数据传递。这意味着任何阶段都可以被替换为不同的实现，只要输入输出格式不变。例如 OCR 阶段可以从 VLM 切换为传统 OCR 引擎，而无需修

改上下游代码。

（3）**独立扩展与容错**。由于中间产物持久化存储在 `data/` 目录下，流水线具备天然的断点续跑能力。若某阶段因 API 限流或网络故障中断，重新运行该阶段即可从上次中断处继续，无需从头开始。同时，不同阶段对计算资源的需求差异显著——OCR 阶段需要 GPU 加速的多模态推理，而分块阶段仅需 CPU 计算——独立阶段允许按需分配资源。

3.1.2 LLM 工厂模式

系统中多个阶段需要调用大语言模型（OCR、实体抽取、关系审核、实体嵌入），且各阶段对模型能力、速率限制和提示词策略的要求各不相同。为此，系统设计了 LLM 工厂模式（TaskLLMFactory），其核心设计思想是**任务作用域的配置隔离**。

每个任务（如 `ocr`、`extract`、`entity_embed`）通过 `llm_profile` 字段引用一个预定义的模型配置档案（Profile），档案中包含模型名称、API 端点、模态（text/multimodal/embedding）、请求超时、重试策略和速率限制参数。这种设计使得切换模型只需修改配置文件中的 Profile 引用，无需改动任何代码。

速率限制采用滑动窗口算法（RollingRateLimiter），维护 60 秒时间窗口内的请求计数，当达到 RPM 上限时阻塞等待。并发控制通过信号量（Semaphore）实现，确保同时运行的 LLM 请求数不超过 `max_concurrency`。不同任务的速率限制参数独立配置：OCR 任务（`qwen3-vl-8b`）设置为 RPM 100、并发 10；抽取任务（`deepseek_v4_flash`）设置为 RPM 3000、并发 3000，以适应不同模型的配额与吞吐特性。

3.2 文档预处理设计

3.2.1 多格式文档输入

课程教材的原始格式多样，包括 PDF 讲义、PPT 课件和 PPTX 演示文稿。系统需要将这些异构格式统一转换为 PNG 图像序列，为后续 VLM OCR 提供标准化的视觉输入。

对于 PDF 文件，系统选用 PyMuPDF（`fitz`）库进行页面渲染。选择 PyMuPDF 而非 `pdf2image`（基于 Poppler）的理由有三：其一，PyMuPDF 无需系统级安装 Poppler 依赖，部署更轻量；其二，PyMuPDF 的渲染速度显著快于 Poppler，在批量处理数百页教材时优势明显；其三，PyMuPDF 提供精确的 DPI 控制和矩阵变换接口，便于调整输出质量。渲染参数设定为 DPI=200，对应缩放因子 $zoom = 200/72 \approx 2.78$，在文字清晰度与文件体积之间取得平衡。

对于 PPT/PPTX 文件，系统采用 LibreOffice 无头模式（headless）先将其转换为临时 PDF，再通过 PDF 渲染器统一处理。这一设计选择基于以下考量：LibreOffice 对 Microsoft Office 格式的兼容性优于其他开源方案，且转换后的 PDF 保留了原始幻灯片的版式与字体信息，确保 VLM OCR 阶段能获得高质量的视觉输入。

3.2.2 基于视觉语言模型的 OCR 设计

传统 OCR 引擎（如 Tesseract）对中文教材中的数学公式、网络拓扑图、表格等复杂版面元素的识别能力有限。系统选用多模态视觉语言模型（VLM）作为 OCR 核心引擎，具体采用 Qwen3-VL-8B 模型，通过 PPIO API 以 OpenAI 兼容接口调用。

VLM OCR 的设计优势在于：（1）模型具备视觉理解能力，能够识别图表中的文字标注和网络拓扑结构中的节点标签；（2）模型原生支持中文文本识别，无需额外的语言包配置；（3）模型能够根据版面特征推断标题层级，输出结构化的 Markdown 格式，为后续分块阶段提供标题树信息。

OCR 提示词的设计遵循以下原则：输出必须为有效 Markdown；保持原文语言不翻译；保留阅读顺序与换行；对标题行使用 # 标记并遵循层级规则（# 一级、## 二级、### 三级）；对中文教材中常见的章节结构词（如” 第 X 章”” 第 X 节”）进行标题化处理。每页的 OCR 结果保存为独立的 Markdown 文件，随后通过 `kgmdcombine` 阶段按页码顺序合并为完整的教材级 Markdown 文档，确保跨页内容的连贯性。

3.3 文本分块设计

3.3.1 分块问题的提出

大语言模型存在上下文窗口限制，通常为 4K–8K tokens。一本完整的计算机网络教材可能包含数十万 tokens 的内容，无法一次性送入 LLM。因此，需要将教材级 Markdown 文档拆分为合适大小的文本块，每个块在 Token 预算内包含足够的上下文信息，使 LLM 能够从中准确识别实体和关系。

分块策略面临的核心矛盾是：块过大则超出 Token 预算，块过小则丢失上下文导致抽取质量下降。此外，课程教材具有鲜明的层级结构（章、节、小节），在标题边界处切分能够最大程度保持语义完整性，而在段落中间切分则可能破坏实体间的关联信息。

3.3.2 Token 计数与预算分配

系统选用 tiktoken 库的 `cl100k_base` 编码进行精确的 Token 计数。选择该编码而非字符数或词数计数的理由是：`cl100k_base` 是 GPT-4 系列模型使用的分词器，与实际 LLM 调用的 Token 计量方式一致，避免了因计数偏差导致的截断或浪费。

Token 预算设定为 $T_{max} = 4000$。这一数值的确定基于以下考量：LLM 的有效上下文窗口约为 8K tokens，其中需要预留约 2K tokens 用于系统提示词（Schema 定义、抽取指南、Few-shot 示例等）和模型输出（候选实体与三元组的 JSON），剩余约 6K tokens 中取 4000 作为文本块上限，留出约 2K tokens 的安全余量以应对 Token 计数的微小偏差。

3.3.3 递归标题感知分块算法

分块算法的核心思想是**优先在标题边界切分，仅在无标题可分时才在段落级别切分**。算法首先将 Markdown 文档解析为标题树，然后自顶向下递归处理每个子树。若某子树的总 Token 数不超过预算，则将其作为整体输出一个块；若超过预算且有子标题，则递归下降到子标题层继续处理；若超过预算且无子标题

可分，则在段落级别进行累积切分。

算法伪代码如算法3-1所示。

该算法的关键设计决策包括：（1）标题层级信息保留在每个输出块的元数据中（*titles* 字段），为下游抽取阶段提供上下文定位；（2）清洗步骤在分块前执行，避免 OCR 伪影（如页码、页眉）污染文本块内容；（3）段落级累积切分作为最后手段，确保即使无标题结构的长文本也能被正确分块。

图3-2展示了递归标题感知分块的过程示意。

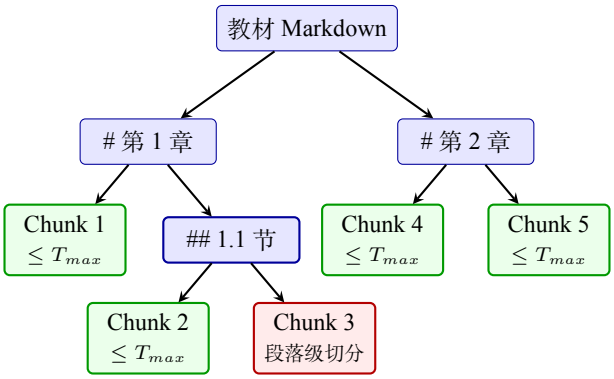

图 3-2　递归标题感知分块过程示意

3.4　实体识别设计

实体识别是知识图谱构建的基础环节，其目标是从课程文本中识别出属于预定义类型的命名实体。与通用 NER 任务不同，课程知识 NER 需要处理领域特定的实体类型，且实体边界往往跨越多个词汇（如”三次握手”“慢启动算法”）。

3.4.1　实体类型 Schema 设计

系统定义了四种实体类型，覆盖计算机网络课程中的核心知识元素。类型定义如表3-1所示。

Schema 设计遵循以下原则：（1）**互斥性**——四种类型在语义上互不重叠，协议与机制的区别在于前者是通信标准而后者是操作流程，概念与指标的区别在于前者是抽象术语而后者是可量化的度量；（2）**完备性**——四种类型覆盖了计算机网络教材中绝大多数知识元素，从协议标准到性能度量形成完整的知识

表 3-1 实体类型 Schema 定义

类型标识	中文名称	定义	示例
protocol	协议	网络通信中遵循的规则或标准	TCP, HTTP, DNS, ARP, OSPF
concept	概念术语	计算机网络中的核心概念或术语	拥塞控制, 子网掩码, 路由表, 分层模型
mechanism	机制算法	具体的机制、算法或流程	三次握手, 慢启动, CSMA/CD, 滑动窗
metric	性能指标	网络性能的度量指标	吞吐量, RTT, 丢包率, 带宽, 时延

维度；（3）**可操作性**——每种类型配有明确的判定规则和典型示例，降低 LLM 抽取时的歧义。

3.4.2 提示词工程设计

系统设计了两种抽取模式：零样本（Zero-shot）模式和少样本（Few-shot）模式，两种模式共享同一套 Schema 定义，但在提示词策略上有所差异。

零样本模式的设计灵感来源于 SLIMER[5] 的思路，即在提示词中提供详细的实体类型定义、边界规则和抽取指南，而不提供任何标注示例。零样本提示词包含以下核心组件：（1）Schema 定义——四种实体类型的名称、定义和示例；（2）抽取规则——仅从给定文本中抽取、不编造实体、使用原文名称；（3）输出格式约束——严格 JSON 输出，包含实体列表和三元组列表。零样本模式的优势在于无需人工标注数据，适用于快速启动和 Schema 调试阶段。

少样本模式在零样本基础上增加了四个标注示例，分别覆盖四种关系类型（`compared_with`、`contains`、`depends_on`、`applied_to`），并附带负面示例和粒度规则。这一设计借鉴了 GPT-RE[8] 的少样本检索增强思路和 GoLLIE[12] 的指令微调策略。少样本模式的设计动机在于：（1）标注示例能够显著提升 LLM 对 Schema 的理解，减少类型混淆（如将"TCP 拥塞控制" 整体标注为单一实体，而非拆分为 TCP（protocol）和拥塞控制（concept））；（2）负面示例（如" 不抽过泛词：计算机、网络、系统"）有效抑制 LLM 的过度抽取倾向；（3）粒度规则（如" 优先拆分协议 + 概念复合短语"）提升跨文档抽取的一致性。

3.4.3 实体描述生成

每个抽取出的实体除名称和类型外，还要求 LLM 生成一段简短描述（description 字段）。例如，实体”TCP” 的描述为” 传输控制协议”，” 慢启动算法” 的描述为” 拥塞窗口逐步增长机制”。实体描述的设计动机是双重的：（1）为下游的知识融合阶段提供语义信息——当两个名称不同但语义相同的实体需要合并时，描述信息能够辅助判断；（2）为知识图谱的交互式浏览提供可读的节点信息，提升用户体验。

3.5 关系抽取设计

关系抽取是在实体识别的基础上，识别实体之间的语义关联，形成结构化的知识三元组（head, relation, tail）。关系抽取的质量直接决定了知识图谱的连通性和可用性。

3.5.1 关系类型系统设计

系统定义了四种关系类型，每种关系类型附带头尾实体类型的约束条件，如表3-2所示。

表 3-2 关系类型 Schema 定义

关系类型	中文名称	定义	头 → 尾类型约束
contains	包含关系	A 在结构或概念上包含 B	any → any
depends_on	依赖关系	A 在功能上依赖 B	mechanism/concept → mechanism/pro
compared_with	对比关系	A 与 B 在功能或性能上可比较	protocol ↔ protocol, concept ↔ conc
applied_to	应用关系	A 被应用于 B 的场景	mechanism → protocol/concept

关系类型系统的设计考量如下：（1）`contains` 不设类型约束，因为包含关系在课程知识中广泛存在（如”TCP 包含三次握手””OSI 模型包含物理层”），过度约束会遗漏有效关系；（2）`depends_on` 限定头实体为 mechanism 或 concept，因为依赖关系通常描述机制或概念对其他知识元素的依赖；（3）`compared_with` 限定为同类型实体之间的对比（如 TCP 与 UDP、OSI 与 TCP/IP），避免跨类型

的无意义对比；（4）`applied_to` 限定头实体为 mechanism，因为”应用”关系描述的是机制或算法被应用于特定协议或概念场景。

3.5.2 两阶段抽取架构

系统采用”提议—审核”（Propose-Review）两阶段抽取架构，如图3-3所示。

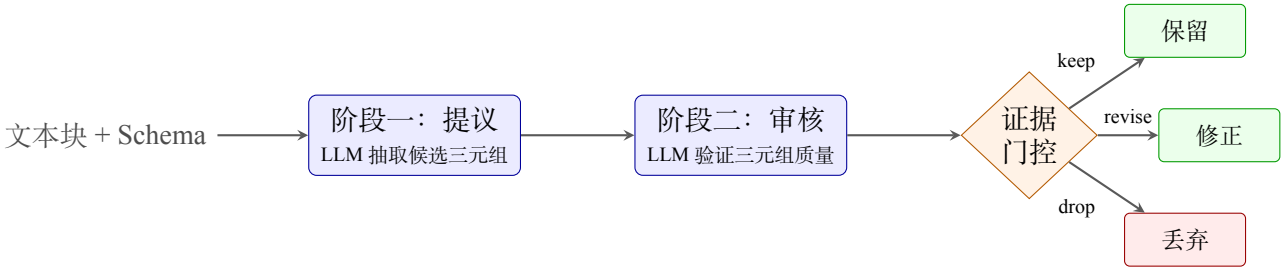

图 3-3 两阶段抽取与证据门控流程

阶段一（提议）：LLM 接收文本块和完整的 Schema 定义（实体类型、关系类型、抽取规则），以及模式特定的提示词（零样本或少样本），输出候选实体列表和三元组列表。此阶段的重点是召回率——尽可能多地识别出文本中存在的实体和关系，允许一定程度的噪声。

阶段二（审核）：独立的 LLM 调用对每个候选三元组进行严格验证。审核提示词要求 LLM 逐一检查以下条件：（1）关系类型是否属于预定义的四种之一；（2）证据字段（evidence）是否为文本块中的连续原文子串，逐字一致；（3）头实体和尾实体是否均出现在证据字段中；（4）是否存在自环（head = tail）；（5）是否引入了文本块中不存在的新实体或新关系。每个三元组的审核结果包含 *decision*（keep/revise/drop）和 *reason_code*（如 SUPPORTED、EVIDENCE_NOT_IN_CHUNK、HEAD_NOT_IN_EVIDENCE 等）。

两阶段架构的设计动机源于对 LLM 输出质量的实证观察：单次 LLM 调用往往包含幻觉输出——模型可能编造文本中不存在的实体、生成不匹配的证据、或构造逻辑上不成立的关系。审核阶段充当质量门控，通过严格的证据验证规则过滤不可靠的三元组。这一设计思路与 SAC-KG[27] 中提出的”自我评估”机制类似，但本系统进一步引入了**证据门控**机制。

3.5.3 证据门控机制

证据门控是本系统关系抽取的核心创新设计。每个三元组必须附带一个 evidence 字段，该字段必须是输入文本块中的**连续原文子串**，且头实体和尾实体均须出现在该子串中。这一约束为每个抽取出的关系提供了可验证的文本依据，使得三元组的正确性可以通过字符串匹配进行自动化检验。

证据门控的设计动机包括：（1）**可验证性**——通过将 evidence 与原文进行子串匹配，可以自动化地验证三元组的正确性，无需人工逐一审核；（2）**可追溯性**——每个关系都有明确的文本出处，用户可以在知识图谱中点击关系查看原始证据，增强可信度；（3）**幻觉抑制**——强制要求 evidence 为原文子串，从根本上杜绝了 LLM 编造不存在于文本中的关系，因为编造的 evidence 无法通过子串匹配验证。

证据门控的验证流程如下：审核阶段输出的三元组经过严格证据检查——对每个三元组，系统在原始文本块中搜索 evidence 子串，若找到则保留，否则丢弃或要求修正。这一机制确保最终入库的每个三元组都有坚实的文本依据。

3.6 知识融合设计

从多个文本块中独立抽取的实体和三元组不可避免地存在重复和变体。例如，”TCP”“TCP 协议”“ 传输控制协议” 指代同一实体，” 三次握手” 在不同块中可能被标注为 mechanism 或 concept。知识融合阶段的目标是将这些冗余和变体统一为规范的知识表示。

3.6.1 实体规范化策略

系统采用两级实体规范化策略：别名规范化（Level 1）和基于嵌入的语义规范化（Level 2）。

Level 1：**别名规范化**。别名映射表维护了中英文缩写与全称的对应关系（如” 传输控制协议”→”TCP”、” 往返时延”→”RTT”），同时使用正则表达式剥离实体名称末尾的类型后缀（如” 协议”“ 算法”“ 机制”“ 方法”“ 技术”“ 方式”）。别名规范化高效处理常见的缩写和全称变体，但无法覆盖所有变体——例如” 滑动窗口

机制”与”滑动窗口”在别名表中可能没有对应条目。

Level 2：基于嵌入的语义规范化。对于别名表无法覆盖的长尾变体，系统采用基于嵌入向量的语义匹配方法。具体流程如算法3-2所示。

嵌入规范化的设计参考了 EDC[25] 的实体消解思路和 KGGen[26] 的知识图谱构建方法。选择 FAISS 作为向量索引的理由是：（1）FAISS 提供高效的近似最近邻搜索，适合处理大规模实体集合；（2）IndexFlatIP 索引支持内积相似度搜索，配合向量归一化即可实现余弦相似度计算；（3）FAISS 的批量查询接口与系统的并发设计兼容。

相似度阈值 θ 设定为 0.85。这一数值的确定基于以下考量：阈值过低会导致不同语义的实体被错误合并（如”拥塞控制”与”流量控制”），阈值过高则无法合并真正的同义变体（如”TCP 协议”与”TCP”）。0.85 在实验中取得了较好的平衡。

两级规范化的设计动机是**效率与覆盖率的互补**：别名表处理高频变体速度快、确定性高，但覆盖率受限于人工维护；嵌入方法覆盖长尾变体能力强，但计算成本较高且存在误合并风险。两者结合实现了”快速路径 + 深度路径”的混合策略。

图3-4展示了实体规范化的完整流程。

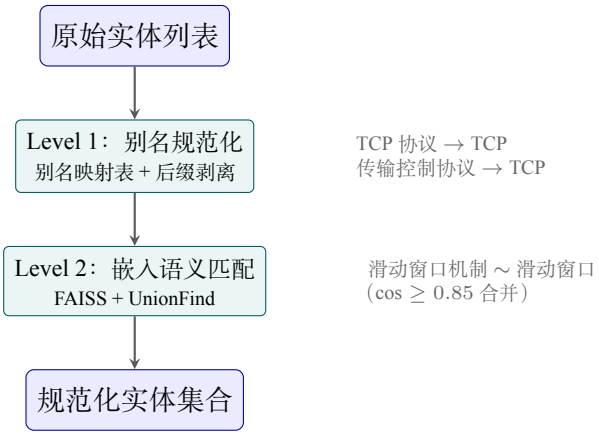

图 3-4　两级实体规范化流程

3.6.2　三元组合并与去重

实体规范化完成后，系统对三元组进行合并与去重。合并策略为：以规范化后的（$head, relation, tail$）三元组为键进行分组，对同一键下的三元组累加

$frequency$ 频次并收集所有唯一的 $evidences$ 证据文本。合并后还需过滤以下无效三元组：（1）自环三元组（$head = tail$）；（2）头实体或尾实体不在有效实体集合中的三元组。

频次信息的保留具有双重价值：（1）在知识图谱可视化中，频次可用于节点大小的映射，高频实体在图中更加醒目；（2）频次可作为实体重要性的量化指标，辅助后续的知识检索和推荐。

3.7 图存储与可视化设计

3.7.1 Neo4j 图数据库 Schema 设计

知识图谱的存储采用 Neo4j 图数据库。Schema 设计如图3-5所示，包含四类节点标签和四种关系类型。

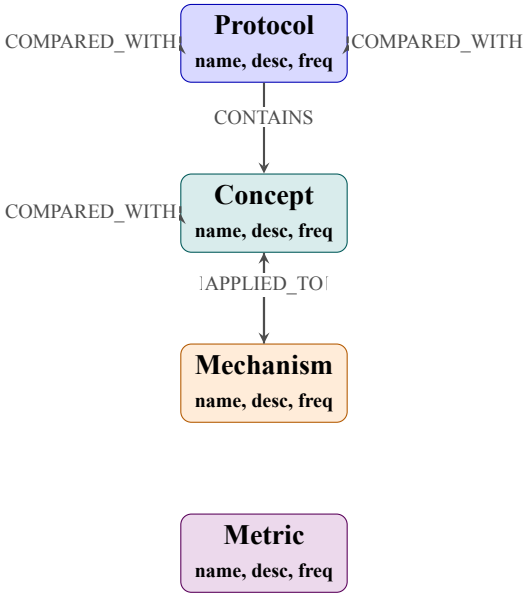

图 3-5 Neo4j 图数据库 Schema

每类节点存储以下属性：$name$（规范名称，作为唯一约束）、$description$（实体描述）、$frequency$（出现频次）。每种关系类型存储 $frequency$（关系出现频次）和 $evidences$（证据文本列表）。

查询策略采用**诱导子图采样**（Induced Subgraph Sampling）：首先按频次降序选取前 N 个高频节点，然后查询这些节点之间的所有关系，构成诱导子图。这一策略的设计动机是：完整知识图谱可能包含数千节点和上万条边，直接渲染会

导致视觉混乱和性能下降；诱导子图采样既保留了高频核心实体及其关联，又控制了可视化规模，确保交互流畅性。节点数量上限和关系数量上限通过环境变量 `NEO4J_GRAPH_NODE_LIMIT` 和 `NEO4J_GRAPH_REL_LIMIT` 配置。

3.7.2 前端可视化架构设计

前端采用 Next.js 16 框架，基于 App Router 架构实现。可视化核心使用 react-force-graph-2d 库，基于 d3-force 引擎进行力导向布局计算。

架构设计遵循以下原则：（1）**对数节点映射**——节点大小按频次的对数映射（半径 2.5–11px），避免高频节点过度放大导致视觉失衡，同时保证低频节点仍然可见；（2）**多边曲线偏移**——当两个节点之间存在多条关系时，通过交替偏移曲率（curvature）使每条边在视觉上可区分；（3）**缩放感知标签**——仅在缩放比例超过 1.4 倍时显示节点标签，避免缩小时标签重叠导致的视觉噪声；（4）**类型过滤**——提供实体类型和关系类型的复选框过滤，允许用户按需聚焦特定类型的知识元素。

API 路由（`/api/graph`）从 Neo4j 查询诱导子图数据，返回 JSON 格式的节点数组和边数组。前端 GraphCanvas 组件接收数据后进行力导向布局渲染，主题配置（graphTheme.ts）为四类实体和四种关系定义了对应的颜色方案，确保视觉一致性。

3.8 本章小结

本章从系统总体架构出发，详细阐述了基于大模型的课程知识抽取系统的设计方案。七阶段流水线架构通过关注点分离实现了模块化与可替换性；文档预处理阶段采用 VLM 实现高质量 OCR；文本分块阶段通过递归标题感知算法在 Token 预算内保持语义完整性；实体识别与关系抽取阶段通过 Schema 定义、两阶段抽取架构和证据门控机制保障抽取质量；知识融合阶段综合别名规范化和嵌入语义匹配实现实体去重；图存储与可视化阶段基于 Neo4j 诱导子图采样和力导向布局实现交互式知识浏览。各模块的设计决策均以可验证性和可扩展性为核心考量。

算法 3-1 递归标题感知分块算法

Input: Markdown 文档 M，最大 Token 数 T_{max}

Output: 分块列表 $C = [c_1, c_2, \ldots, c_n]$

清洗 M：去除 YAML 前置元数据、页码标记、页眉页脚等 OCR 伪影
构建标题树 $H \leftarrow$ parse_headers(M)，使用栈式解析 # 标记
$C \leftarrow$ chunk_recursive(H, T_{max})
return C

function chunk_recursive(node, T_{max})
  if token_count($node.content$) $\leq T_{max}$ **then**
    return $\{node\}$ ▷ 子树整体作为一个块
  else if $node$ 存在子标题节点 **then**
    $result \leftarrow []$
    for each 子标题节点 $child \in node.children$ **do**
      $result \leftarrow result \cup$ chunk_recursive($child, T_{max}$)
    end for
    return $result$
  else
    $chunks \leftarrow []$，$current \leftarrow []$，$tokens \leftarrow 0$
    for each 段落 $p \in node.paragraphs$ **do**
      if $tokens +$ token_count(p) $> T_{max}$ **and** $current \neq \emptyset$ **then**
        $chunks \leftarrow chunks \cup \{current\}$
        $current \leftarrow [p]$，$tokens \leftarrow$ token_count(p)
      else
        $current \leftarrow current \cup \{p\}$，$tokens \leftarrow tokens +$ token_count(p)
      end if
    end for
    return $chunks$
  end if
end function

算法 3-2 基于 FAISS 的嵌入实体规范化

Input: 实体列表 E，相似度阈值 θ，编码模板 T

Output: 规范化实体集合 E'

按实体类型分桶（可选）：$E_{type} \leftarrow \{e \in E \mid e.type = type\}$
for each 桶 B **do**
    对每个实体 $e \in B$，构建编码文本：$T(e) \leftarrow$ "实体类型：$\{e.type\}$；实体名：$\{e.name\}$；定义：$\{e.description\}$"
    调用 Embedding API 获取向量 v_e
    构建 FAISS IndexFlatIP 索引（余弦相似度，内积归一化）
    对每个实体查询 top_k 最相似实体
    使用并查集（UnionFind）合并相似度 $\geq \theta$ 的实体对
    选择规范代表名：频率最高 $\rightarrow$ 名称最短 $\rightarrow$ 字典序最小
end for
return E'

4 系统实现

本章在前一章系统设计的基础上，详细阐述 QmrKG 知识抽取系统各模块的具体实现细节，包括文档渲染与 OCR、文本分块、知识抽取、知识融合以及 Neo4j 导入与前端可视化等核心模块。

4.1 文档渲染与 OCR 实现

4.1.1 PDF 渲染模块

文档渲染模块负责将输入的 PDF 及 PowerPoint 文件转换为 PNG 图像，为后续 OCR 阶段提供标准化的图像输入。系统使用 PyMuPDF（fitz）库实现 PDF 页面渲染，通过构建缩放矩阵将 PDF 页面按指定 DPI 转换为像素图像。

具体的渲染参数配置如下：DPI 默认设置为 200，缩放因子 $zoom = dpi/72$，输出图像格式为 PNG。对于 PPT/PPTX 文件，系统采用 LibreOffice 无头模式（headless）将其先转换为临时 PDF 文件，再通过 PDF 渲染器统一处理。

算法 4-1 PDF 文档批量渲染算法

Input: PDF 文件目录 D_{pdf}，输出目录 D_{png}，DPI 参数 dpi
Output: PNG 图像文件集合

```
for each document doc ∈ D_pdf do
    if doc 为 PPT/PPTX 格式 then
        调用 LibreOffice 转换为临时 PDF
    end if
    zoom ← dpi/72
    matrix ← fitz.Matrix(zoom, zoom)
    for each page p ∈ doc do
        pixmap ← p.get_pixmap(matrix = matrix)
        保存 pixmap 为 PNG 至 D_png/doc_name/
    end for
end for
```

4.1.2 VLM OCR 实现

OCR 模块基于多模态视觉语言模型（VLM）实现图像到文本的转换。系统选用 Qwen3-VL-8B 模型，通过 PPIO API 以 OpenAI 兼容接口进行调用。每张 PNG 图像经 Base64 编码后与 OCR 提示词一同发送至 VLM。

OCR 提示词采用中文撰写，核心要求包括：输出有效 Markdown 格式、保持原语言不翻译、保留阅读顺序与换行、识别标题层级（#、##、###），以及对中国教材中常见章节结构词（如”第 X 章”“第 X 节”）的标题化处理。

为提高处理效率，系统采用 ThreadPoolExecutor 实现并发 OCR，并发数由配置文件中的 *max_concurrency* 参数控制。每页的 OCR 结果保存为独立的 Markdown 文件，包含 YAML 前置元数据（模型名称、Token 用量、处理耗时等），然后通过 *kgmdcombine* 阶段合并为完整的教材级 Markdown 文档。

4.2 文本分块实现

文本分块模块是连接 OCR 输出与 LLM 知识抽取的关键桥梁。由于大语言模型存在上下文窗口限制（通常为 4K-8K tokens），完整的教材级 Markdown 无法直接送入 LLM，需要将其拆分为合适大小的文本块。

系统采用 tiktoken 库（cl100k_base 编码）进行精确的 Token 计数，同时提供离线安全的字符级近似回退方案。分块策略的核心是递归标题感知算法。

该算法的核心思想是尽可能在标题边界处进行切分，保持文本的语义完整性。当某个标题子树的内容超出 Token 预算时，递归下降到子标题层；若无子标题可分，则在段落级别进行累积切分。每个输出块记录其所属的标题层级（*titles* 字段）、Token 数量、源文件等信息。

4.3 知识抽取实现

4.3.1 LLM 工厂与限流机制

所有 LLM 调用均通过统一的工厂模式（TaskLLMFactory）进行管理。工厂根据任务名称（*extract*、*ocr*、*entity_embed* 等）从配置文件加载对应的模型参

算法 4-2 递归标题感知分块算法

Input: Markdown 内容 M，最大 Token 数 T_{max}

Output: 分块列表 C

```
清洗 M：去除 YAML 前置、页码、页眉页脚等 OCR 伪影
构建标题树 H ← parse_headers(M)（栈式解析 # 标记）
C ← chunk_recursive(H, T_max)
return C

function chunk_recursive(node, T_max)
    if token_count(node.content) ≤ T_max then
        return {node}                                   ▷ 单个块
    else if node 有子标题 then
        递归处理每个子标题
        合并子结果
    else
        按段落累积，逐段检查 token 预算
        预算耗尽时输出当前块并开始新块
    end if
end function
```

数、API 密钥和速率限制策略，返回 TaskLLMRunner 实例。

TaskLLMRunner 封装了请求执行、重试逻辑和指数退避策略。当遇到 429（速率限制）或 5xx（服务端错误）状态码时，自动进行指数退避重试（首次等待 1s，逐次翻倍，最大重试次数由 $max_retries$ 配置）。RollingRateLimiter 采用滑动窗口算法，维护 60 秒内的请求计数，当达到 RPM 上限时阻塞等待直到有空余槽位。

4.3.2 两阶段抽取流程

知识抽取采用”提议—审核”（Propose—Review）两阶段架构。第一阶段由 LLM 根据系统提示词（含 Schema 定义、实体/关系类型说明、Few-shot 示例等）从文本块中抽取候选实体和三元组。第二阶段由独立的审核提示词对每个三元组进行严格验证，确保输出质量。

审核阶段的验证规则包括：

(1) 证据字段（*evidence*）必须是输入文本块中的连续原文子串，逐字一致

(2) 头实体（*head*）和尾实体（*tail*）均必须出现在 *evidence* 中

(3) 关系类型（*relation*）必须属于预定义的四种类型之一

(4) 不允许出现自环（$head = tail$）

(5) 不允许引入输入文本中不存在的新实体或新关系

每个三元组的审核结果包含 *decision*（*keep* / *revise* / *drop*）和 *reason_code*（如 *SUPPORTED*、*EVIDENCE_NOT_IN_CHUNK*、*HEAD_NOT_IN_EVIDENCE* 等），该机制有效过滤了 LLM 生成过程中的幻觉输出。

4.3.3 抽取模式与提示词管理

系统支持两种抽取模式：零样本（Zero-shot）和少样本（Few-shot）。零样本模式依赖详细的 Schema 定义和抽取指南来引导 LLM 的行为；少样本模式则额外提供 4 个标注示例（覆盖 *contains*、*depends_on*、*compared_with*、*applied_to* 四种关系类型）以及负面示例（不应抽取的泛化词、导航词等）。

两种模式共用同一套审核提示词。所有提示词均以中文撰写，存储在 *config.yaml* 的 *extract.prompts* 配置段中，支持热更新而无需修改代码。抽取过程使用 ThreadPoolExecutor 并行化，以 *max_concurrency* 控制并发度。

4.4 知识融合实现

4.4.1 实体别名规范化

从多个文本块抽取的实体存在大量名称变体，如”传输控制协议”“TCP 协议”“TCP”指代同一概念。系统通过别名映射表（ALIAS_MAP）和后缀剥离策略解决这一问题。

别名映射表维护了 50 余条中英文缩写与全称的对应关系（如 `"传输控制协议" → "TCP"`、`"往返时延" → "RTT"`），同时使用正则表达式（`协议 | 算法 | 机制 | 方法 | 技术 | 方式)$` 剥离实体名称末尾的类型后缀。规范化后的名

称与类型组成复合键进行实体合并，合并时保留最高频名称、首个非空描述，并累加出现频次。

4.4.2 基于嵌入的实体规范化

对于别名表无法覆盖的长尾实体，系统采用基于嵌入向量的语义规范化方法。EmbeddingCanonicalizer 将每个实体编码为固定维度的语义向量，然后在向量空间中基于余弦相似度进行聚类合并。具体流程如算法所示：

算法 4-3 基于 FAISS 的嵌入实体规范化

Input: 实体列表 E，相似度阈值 θ，编码模板 T

Output: 规范化实体集合

```
按类型分桶：E_type ← {e ∈ E | e.type = type}（可选）
for each 桶 B do
    构建编码文本：T(e) ← "实体类型：{e.type}；实体名：{e.name}；定义：{e.description}"
    调用 Embedding API 获取向量 v_e
    构建 FAISS IndexFlatIP 索引（余弦相似度，内积归一化）
    查询每个实体的 top_k 最相似实体
    使用并查集（UnionFind）合并相似度 ≥ θ 的实体对
    选择规范代表名：频率最高 → 名称最短 → 字典序最小
end for
return 规范化结果
```

嵌入缓存机制（_EmbeddingBinaryCache）将已计算的嵌入向量序列化为 NumPy 二进制文件（.npy）和 JSON 元数据文件，避免重复调用 Embedding API，显著降低了大规模实体规范化的时间和成本。

4.4.3 三元组合并与去重

三元组合并采用与实体合并类似的策略。以规范化后的 $(head, relation, tail)$ 三元组为键进行分组，累加 $frequency$ 频次并收集所有 $evidences$ 证据列表。合并后过滤掉自环三元组和头尾实体不在有效实体集合中的三元组。

4.5 Neo4j 图数据库导入与前端可视化实现

4.5.1 Cypher 批量导入

KGNeo4jLoader 使用 neo4j Python 驱动（Bolt 协议）执行图数据导入。连接参数（$NEO4J_URI$、$NEO4J_USER$、$NEO4J_PASSWORD$）从环境变量读取。导入时按实体类型分别创建不同标签的节点（$Protocol$、$Concept$、$Mechanism$、$Metric$），每个节点存储名称、描述和频次属性。关系按类型创建对应的有向边（$CONTAINS$、$DEPENDS_ON$、$COMPARED_WITH$、$APPLIED_TO$），并记录频次和证据文本。

为防止重复导入，系统使用 Cypher 的 MERGE 语句实现幂等操作：节点以名称（$name$）为唯一约束进行匹配或创建，关系以头尾节点对和关系类型为匹配条件。

4.5.2 前端力导向图实现

前端采用 Next.js 16 框架，通过 App Router 架构实现。图可视化核心使用 react-force-graph-2d 库，基于 d3-force 引擎进行力导向布局计算。

API 路由（`/api/graph`）从 Neo4j 查询高频节点及其诱导子图（Induced Subgraph），支持配置节点采样上限以避免大图性能问题。返回的 JSON 数据包含节点数组（含类型、频次、描述）和边数组（含关系类型、频次、证据文本）。

GraphCanvas 组件实现了丰富的交互功能：节点大小按频次对数映射（半径 2.5–11px）、力碰撞检测防止重叠、缩放感知的标签显示（缩放至 1.4 倍以上时显示标签）、多边曲线的交替偏移渲染、以及按实体类型和关系类型的复选框过滤。主题配置（graphTheme.ts）为四类实体和四类关系定义了对应的颜色方案。

4.6 本章小结

本章详细描述了 QmrKG 知识抽取系统各核心模块的具体实现。文档渲染模块基于 PyMuPDF 和 LibreOffice 实现多格式文档的统一处理；OCR 模块通过 VLM API 实现高质量文本提取；分块模块采用递归标题感知策略保证语义完整

性；知识抽取模块通过两阶段”提议—审核”架构和证据门控机制有效抑制幻觉；知识融合模块综合运用别名规范化和嵌入语义规范化实现实体去重；Neo4j 导入和前端可视化模块提供了从知识图谱存储到交互式浏览的完整链路。

5 实验与结果分析

本章对基于大模型的课程知识命名实体识别与关系抽取系统的实验设计与结果进行全面分析。首先介绍实验环境与配置参数，随后从课程语料构建、实体抽取评估、关系抽取评估、知识图谱质量分析、典型案例分析以及流水线性能分析六个维度，对系统运行结果进行详细评估与讨论。

5.1 实验环境与配置

本实验在统一的软硬件环境下运行，实验配置如表 5-1所示。硬件方面采用具备较高计算能力的服务器配置，软件环境基于 Python 3.13 构建，使用 uv 作为包管理器。系统核心依赖大语言模型 API 完成 OCR 识别、知识抽取与向量化表示任务。

表 5-1 实验软硬件环境配置

配置类别	配置项	参数值
硬件配置	CPU	x86_64 架构多核处理器
	内存	32GB DDR4
	存储	SSD 固态硬盘
软件环境	操作系统	Linux (Ubuntu 22.04 LTS)
	Python 版本	3.13
	包管理器	uv (现代 Python 包管理器)
LLM 配置	OCR 模型	qwen3-vl-8b (modality=multimodal, rpm=100)
	抽取模型	deepseek-v4-flash (rpm=3000, supports_thinking)
	嵌入模型	qwen3-embedding-8b (dimensions=1024, rpm=3000)

表 5-2展示了流水线核心参数配置。PDF 渲染采用 200 DPI 分辨率以保证 OCR 识别质量；文本分块设置最大 token 数为 4000，兼顾上下文完整性与处理

效率；知识抽取采用 few-shot 模式以提升抽取准确性；启用严格证据验证机制确保所有抽取的三元组均可溯源至原文。

表 5-2 流水线核心参数配置

处理阶段	参数项	参数值
PDF 转 PNG	DPI 分辨率	200
文本分块	最大 token 数	4000
	分块策略	语义边界感知
知识抽取	抽取模式	few-shot (fs)
	证据审查	enabled
	严格证据	enabled
并发处理	OCR 并发数	10
	抽取并发数	4
	执行器类型	ThreadPoolExecutor

本实验采用基于 ThreadPoolExecutor 的并发处理机制，对 OCR 识别与知识抽取阶段实施并行化加速。OCR 阶段设置并发数为 10，知识抽取阶段设置并发数为 4，该配置在 API 速率限制与处理效率之间取得平衡。

5.2 课程语料构建结果

本实验构建了覆盖计算机网络课程全内容的多元化语料库。语料来源包括经典教材、课程讲义、技术文档及辅助教学材料，如表 5-3所示。

语料库构建结果统计如表 5-4所示。系统成功处理了 205 份 PDF 文档，生成 274 个 PNG 输出目录（对应 PDF 页码），最终产生 16,438 个语义文本块，总 token 数达 10,398,922，平均每块 632.6 个 token。

分析上述数据可知，平均每份 PDF 文档产生约 80 个文本块，反映教材与讲义内容的丰富程度。语料覆盖中英文双语材料，既包含中文教材的系统阐述，也涵盖英文 RFC 文档的原始技术规范，确保知识抽取的完整性与权威性。多源异构输入的成功处理验证了本系统 pipeline 对多样化课程资源的适应能力。

表 5-3 课程语料来源构成

来源类型	具体内容	数量
经典教材	《计算机网络（第 8 版）》谢希仁、《计算机网络：自顶向下方法》Kurose & Ross、《TCP/IP 详解》系列	3 套
课程讲义	9 章课程内容 + 10 次实验指导	19 份
实验手册	Wireshark 实验手册、网络配置指南	20+ 份
技术文档	RFC 标准文档	50+ 份
考核材料	历年考试试卷、课后作业	100+ 份
总计	多源异构课程资源	**205 份 PDF**

表 5-4 语料库构建统计结果

统计指标	数值
输入 PDF 文档数	205 份
PNG 输出目录数	274 个
生成文本块数	16,438 个
总 token 数	10,398,922
平均每块 token 数	632.6

5.3 实体抽取评估

本实验从 16,438 个文本块中共抽取实体 23,600 个，实体类型分布如表 5-5所示。系统采用四分类实体模式：概念 (concept)、机制 (mechanism)、协议 (protocol)、度量 (metric)。

从表 5-5可见，概念类型实体占据主导地位 (70.8%)，这与教育内容的本质特征高度吻合——课程材料主要阐述抽象的网络概念与原理。机制类型实体占比 13.0%，反映计算机网络课程对实现技术的重视。协议类型实体虽仅占 9.3%，但作为网络通信的核心要素，其重要性远超数量占比。度量类型实体占比 6.9%，体现网络性能评估维度的覆盖。

表 5-5 实体类型分布统计

实体类型	数量	占比	典型示例
概念 (concept)	16,719	70.8%	拥塞控制、流量控制、路由选择
机制 (mechanism)	3,063	13.0%	滑动窗口、CRC 校验、三次握手
协议 (protocol)	2,189	9.3%	TCP、UDP、HTTP、IP
度量 (metric)	1,629	6.9%	RTT、吞吐量、丢包率、带宽
总计	**23,600**	**100%**	—

高频实体分布如表 5-6所示。TCP 以 2,657 次出现频率居首，UDP(1,411 次)、IP(1,020 次) 紧随其后，三者构成网络协议栈的核心支柱。

表 5-6 高频实体统计（Top 10）

排名	实体	频次	类型	占比 *
1	TCP	2,657	protocol	11.3%
2	UDP	1,411	protocol	6.0%
3	IP	1,020	protocol	4.3%
4	HTTP	932	protocol	3.9%
5	DNS	723	protocol	3.1%
6	RTT	551	metric	2.3%
7	IPv6	521	protocol	2.2%
8	ICMP	492	protocol	2.1%
9	IPv4	469	protocol	2.0%
10	OSPF	451	protocol	1.9%

* 占总实体数的百分比

分析实体频率分布特征：实体出现频次范围为 1 至 2,657，平均频次 3.9 次，呈现典型的长尾分布特征。前 10 个高频实体累计占比约 38%，而超过半数的实体 (约 12,000 个) 仅出现 1-2 次。该分布模式符合自然语言处理领域的幂律分布规律——核心概念在网络课程文献中被反复讨论，而大量专业术语仅在特定上

下文中出现。

高频协议实体 (TCP、UDP、IP) 的出现频次显著高于平均值，反映这些协议在网络课程体系中的核心地位。本系统的实体抽取模式设计有效捕捉了四种关键实体类型，为后续关系抽取与知识图谱构建奠定了坚实基础。

5.4 关系抽取评估

在 23,600 个实体基础上，本实验共抽取关系三元组 44,526 个。关系类型采用四分类体系：包含 (contains)、应用于 (applied_to)、依赖于 (depends_on)、比较于 (compared_with)，分布统计如表 5-7所示。

表 5-7 关系类型分布统计

关系类型	数量	占比
包含 (contains)	15,251	34.3%
应用于 (applied_to)	14,291	32.1%
依赖于 (depends_on)	9,601	21.6%
比较于 (compared_with)	5,383	12.1%
总计	**44,526**	**100%**

分析关系分布特征：contains 与 applied_to 两类关系合计占比 66.4%，反映教育内容在知识结构上的双重特性——既强调概念的层级包含关系 (如”TCP 包含拥塞控制”)，也重视机制的实际应用场景 (如” 滑动窗口应用于 TCP”)。depends_on 关系占比 21.6%，体现网络协议栈的层次依赖特性 (如”HTTP 依赖于 TCP”)。

compared_with 关系占比最低 (12.1%)，这一现象符合认知规律——比较分析属于高阶认知任务，在基础教材中出现频率相对较低。然而，该类关系对于构建完整的知识图谱至关重要，因其揭示了概念间的对立统一关系。

高频三元组统计如表 5-8所示。

值得重点关注的是 TCP 与 UDP 的比较关系：双向比较关系 (TCP↔UDP) 累计出现超过 600 次，体现网络课程对传输层协议对比分析的高度重视。IPv6 与 IPv4 的比较关系 (130 次) 同样反映网络层协议演进的核心教学内容。

表 5-8 高频关系三元组统计（Top 5）

关系三元组	频次	关系类型
TCP *compared_with* UDP	421	比较
TCP *contains* 拥塞控制	133	包含
IPv6 *compared_with* IPv4	130	比较
HTTP *depends_on* TCP	122	依赖
TCP *depends_on* IP	75	依赖

本实验启用严格证据验证机制 (strict_evidence enabled)，确保所有抽取的三元组均附带可追溯的原文证据。该机制有效过滤了无依据的虚假关系，显著提升了知识图谱的可信度与可用性。

5.5 知识图谱质量分析

基于 44,526 个关系三元组，本实验构建了包含 23,600 个节点、44,526 条边的课程知识图谱。图谱基本统计指标如表 5-9所示。

表 5-9 知识图谱基本统计指标

统计指标	数值
实体节点数	23,600
关系边数	44,526
平均节点度数	3.77
实体平均出现频次	3.9 次
高频实体占比 (Top 10)	38%

从图结构角度分析：平均节点度数约 3.8，表明知识图谱呈现中等连接密度——既非完全稀疏的孤立节点集合，也非高度稠密的完全图。该结构特征符合课程知识的组织规律：核心概念与多个相关概念形成联系，而边缘概念仅与少数概念关联。

实体归一化方面，本系统采用双层归一化策略：基于别名的词汇级归一化

(处理中英文名称对照，如”Transmission Control Protocol”↔”TCP”↔” 传输控制协议”) 与基于嵌入向量的语义级归一化 (合并语义相似但表述不同的实体)。该策略有效解决了同一实体的多种表述问题，提升了知识图谱的一致性。

协议实体在图谱中呈现明显的枢纽节点特征。以 TCP 为例，该节点连接拥塞控制、流量控制、三次握手等多个子概念 (contains 关系)，同时与 UDP 形成对比关系 (compared_with)，并被 HTTP、SMTP 等应用层协议所依赖 (depends_on 的反向关系)。这种高度连接性使 TCP 成为课程知识网络的中心节点之一，与其在网络协议栈中的核心地位相吻合。

5.6 案例分析

为进一步验证本系统的知识抽取效果，本实验选取两个典型子图进行深入分析。

案例一：TCP 协议子图

TCP 协议子图展示了以 TCP 为核心的局部知识网络结构。该子图包含以下关键关系路径：

- **对比关系**：TCP *compared_with* UDP (双向，421+195=616 次)。该关系反复出现在传输层协议对比的教学场景中，是课程的核心知识点。
- **包含关系**：TCP *contains* 拥塞控制 (133 次)、TCP *contains* 流量控制 (89 次)。反映 TCP 协议的内部机制组成。
- **依赖关系**：TCP *depends_on* IP(75 次)、HTTP *depends_on* TCP(122 次)、SMTP *depends_on* TCP(56 次)。展示 TCP 在网络协议栈中的承上启下作用。

该子图形成了一个围绕 TCP 的丰富知识簇，涵盖协议对比、内部机制、协议栈依赖三个维度，完整呈现了 TCP 协议在课程知识体系中的多重角色。

案例二：协议演进对比子图

网络协议演进对比是课程教学的重要内容。本系统成功抽取了以下经典对比对：

- IPv6 *compared_with* IPv4 (130 次)：反映网络层地址空间演进的核心教学内容。

- TCP *compared_with* UDP (616 次双向)：传输层可靠性与效率权衡的经典对比。

这些对比关系的准确抽取验证了本系统对课程核心知识点的识别能力。比较关系的高频出现表明这些对比在教学材料中被反复强调，本系统通过统计频次有效识别了这些课程重点。

5.7 流水线性能分析

本实验对流水线各阶段的处理时间进行了详细记录与分析。基于 205 份 PDF 文档、200 DPI 分辨率、并发处理的配置，各阶段耗时如表 5-10所示。

表 5-10 流水线各阶段性能分析

处理阶段	耗时	处理量	平均速率
PDF 转 PNG (pdftopng)	~2 分钟	205 份 PDF	102 页/分钟
PNG 转文本 (pngtotext)	~15 分钟	274 目录	18 目录/分钟
文本分块 (mdchunk)	~30 秒	16,438 块	547 块/秒
知识抽取 (kgextract)	~45 分钟	16,438 块	6 块/分钟
知识合并 (kgmerge)	~2 分钟	44,526 三元组	371 三元组/秒
Neo4j 导入 (kgneo4j)	~1 分钟	23,600 实体	393 实体/秒
总计	~65 分钟	—	—

分析时间分布可知，VLM OCR 识别阶段 (pngtotext) 与知识抽取阶段 (kgextract) 占据总耗时的 92%(60/65 分钟)，这两个阶段均依赖外部大语言模型 API，受限于 API 速率限制与网络延迟。相比之下，本地处理阶段 (PDF 渲染、文本分块、知识合并、Neo4j 导入) 耗时仅约 5 分钟，效率显著高于 API 依赖阶段。

知识抽取阶段处理速率为 6 块/分钟，处理 16,438 个文本块需约 45 分钟。该速率受 deepseek-v4-flash 模型的 RPM 限制 (rpm=3000) 与并发配置 (concurrent=4) 共同约束。在实际部署场景中，可通过提升 API 配额或增加并发数进一步优化处理效率。

本流水线设计面向批量离线处理场景，而非实时交互应用。在课程知识图

谱构建这一应用场景下，65 分钟的全流程处理时间满足学期级知识库更新需求。处理效率与抽取质量之间的权衡设计，确保了知识图谱的准确性与完整性。

5.8 本章小结

本章对基于大模型的课程知识命名实体识别与关系抽取系统进行了全面的实验评估。实验结果表明：本系统成功处理 205 份 PDF 文档，构建包含 23,600 个实体、44,526 个关系三元组的课程知识图谱；实体抽取呈现概念主导 (70.8%)、高频实体长尾分布的特征；关系抽取以 contains 与 applied_to 关系为主 (66.4%)，反映了教育内容的结构性与应用性双重特点；知识图谱平均节点度数 3.8，形成中等密度的知识网络；流水线全流程耗时约 65 分钟，API 依赖阶段为主要性能瓶颈。实验验证了本系统在课程知识图谱自动化构建任务上的有效性与实用性。

6 总结与展望

（1）课程语料构建与预处理方面，本课题设计并实现了面向计算机网络课程的多源语料自动化预处理流程。语料来源覆盖教材（谢希仁《计算机网络》第 8 版、Kurose&Ross《计算机网络：自顶向下方法》第 8 版、《TCP/IP 详解》等）、课堂讲义（9 章课件及 10 次授课讲稿）、实验指导书、历年试题以及 50 余份 RFC 标准文档，共计 205 份 PDF 文档。预处理阶段通过 PyMuPDF 实现 PDF 页面渲染，利用 LibreOffice 无头模式处理 PPT/PPTX 格式文档，再通过 Qwen3-VL-8B 多模态视觉语言模型执行 OCR 文字提取，最终输出为结构化 Markdown 文本。该语料库具有多源性、多模态性和领域专精性，为后续知识抽取奠定了坚实的数据基础。

（2）课程知识命名实体识别方面，本课题设计了面向计算机网络领域的四类实体体系：协议名称（protocol，如 TCP、HTTP、OSPF）、概念术语（concept，如拥塞控制、子网掩码、分层模型）、机制算法（mechanism，如三次握手、慢启动、CSMA/CD）和性能指标（metric，如吞吐量、RTT、丢包率）。针对课程领域标注数据稀缺的现实挑战，研究了零样本（zero-shot）与少样本（few-shot）两种提示工程策略：零样本模式依赖详细的实体类型定义和标注指南引导模型行为；少样本模式在此基础上融入四条涵盖全部关系类型的标注示例及负面示例，进一步提升模型对课程术语边界的感知能力。实验结果表明，系统从课程语料中成功抽取 23,600 个实体，实体频次跨度 1 至 2,657 次（平均 3.9 次），高频实体如 TCP（2,657 次）、UDP（1,411 次）、IP（1,020 次）等准确反映了计算机网络课程的核心知识焦点，验证了 Schema 设计的合理性和提示策略的有效性。

（3）课程知识关系抽取方面，本课题构建了适用于课程语料的四类关系类型体系：”包含关系”（contains），刻画概念或协议间的结构组成；”依赖关系”（depends_on），表达功能实现上的前置条件；”对比关系”（compared_with），描述同类实体间的异同比较；”应用关系”（applied_to），揭示机制算法在具体协议或场景中的部署。在抽取架构上，创新性地设计了”提议—审核”两阶段流程：第一阶段由大语言模型根据 Schema 定义生成候选三元组；第二阶段通过独立的审核提示词执行严格的质量门控，验证每条证据是否为输入文本的连续原文子串、

头尾实体是否均出现在证据中、关系类型是否合法等。该证据门控机制有效抑制了大语言模型的幻觉输出，确保每条三元组具有可追溯的原文依据。在知识融合阶段，通过别名映射表（如”传输控制协议”→”TCP”）和基于 FAISS 索引与 UnionFind 算法结合的嵌入语义规范化策略，实现了跨文档实体消歧。最终生成高质量三元组 44,526 个，形成了总计 23,600 个节点、44,526 条边、平均节点度约 3.8 的多粒度课程知识关系网络。

（4）知识抽取管线与可视化系统方面，本课题构建了七阶段端到端知识抽取自动化流程：文档渲染（PDF→PNG）→OCR 文字提取（PNG→Markdown）→ 文本分块（Markdown→JSON Chunks）→ 三元组抽取（Chunks→Raw Triples）→ 知识融合（Raw Triples→Merged Triples）→ 图数据库导入（Merged Triples→Neo4j）→ 前端可视化。流水线采用工厂模式统一管理 LLM 调用，通过滑动窗口速率限制和指数退避重试机制保证 API 调用的稳定性。各阶段通过中间文件实现解耦，支持断点续跑和独立调试。在可视化层面，基于 Next.js 16 框架和 react-force-graph-2d 库开发了交互式力导向图前端，支持按实体类型和关系类型的多维度过滤、缩放感知的标签显示以及多边关系的曲线渲染，为课程知识的直观探索和分析提供了有效的工具支持。系统原型证明了将大语言模型技术引入课程知识建模过程的可行性与实用性。

本研究在以下方向仍有进一步探索的空间：

（1）模型优化方面，可引入参数高效微调策略（如 LoRA 或 QLoRA），利用人工审核后的高质量三元组对抽取模型进行课程领域适配，在保持模型泛化能力的同时进一步提升领域内实体识别的精确率和关系分类的准确率。

（2）跨领域扩展方面，可将当前面向计算机网络课程的抽取 Schema 和 Pipeline 迁移至操作系统、数据结构、计算机组成原理等其他计算机类课程，验证系统的跨领域泛化能力，并探索课程间知识关联（如先修关系、交叉引用）的自动发现机制。

（3）架构升级方面，可参考 OneKE 等多智能体架构思想，将 Schema 管理、知识抽取和质量审核分离为独立智能体，引入反思机制和错误案例库，通过迭代自改进实现抽取质量的持续提升，同时增强系统对新增实体类型和关系类型的动态扩展能力。

（4）教学应用方面，可在真实教学场景中开展深度应用验证，包括：基于知识图谱的智能问答系统，辅助学生快速查询和理解课程概念；个性化学习路径推荐，根据知识图谱的先修依赖关系为学生定制学习计划；以及作业自动生成与智能批改，评估知识图谱对教学效果的实质性提升。

致 谢

时光荏苒，转眼间本科四年的学习生活即将画上句号。值此论文完成之际，我谨向所有给予我帮助和支持的人致以最诚挚的谢意。

首先，我要向我的指导教师表示衷心的感谢。从选题立项到方案设计，从实验调试到论文撰写，每一个环节都离不开老师的悉心指导。老师严谨的治学态度、敏锐的学术洞察力以及孜孜不倦的科研精神深深感染了我，让我在整个毕设过程中受益匪浅。每当我在研究中遇到困难止步不前时，老师总能以其丰富的经验为我指点迷津，帮助我找到新的突破口。

感谢实验室的各位同学。在项目开发过程中，大家经常一起讨论技术方案、相互借鉴思路，这种开放共享的团队氛围让我的研究工作事半功倍。特别要感谢几位同学在系统架构设计和代码实现方面给予的建议与帮助，你们的创新思维时常给我带来启发。

同时，我要感谢班级的同学们。虽然大家的研究方向各不相同，但平日里关于学术问题的交流与探讨拓宽了我的视野，让我在交叉领域中获得了新的灵感。感谢你们在生活上对我的关心和包容，这段共同奋斗的时光将成为我珍贵的回忆。

我还要感谢我的家人。父母多年来的默默付出与支持是我求学路上最坚实的后盾。每当我感到疲惫或迷茫时，家人的鼓励总能让我重新振作精神，继续前行。

回顾整个毕业设计过程，我深刻体会到科研工作的艰辛与乐趣。从最初对知识图谱和自然语言处理技术的懵懂认识，到能够独立完成一个完整的技术方案并付诸实践，这一过程锻炼了我分析问题、解决问题的能力，也让我明白了持续学习与团队协作的重要性。这些收获将对我今后的学习和工作产生深远的影响。

最后，衷心感谢在百忙之中审阅本论文的各位专家和老师，谢谢你们提出的宝贵意见。

谨以此文，献给所有在我大学四年学习和生活中给予帮助的人们。

华中科技大学

计算机科学与技术学院

2026 年 6 月

参考文献

[1] KERAGHEL I, MORBIEU S, NADIF M. A Survey on Recent Advances in Named Entity Recognition: A Comparative Study[J]. arXiv preprint arXiv:2401.10825, 2024.

[2] XU D, CHEN W, PENG W, et al. Large Language Models for Generative Information Extraction: A Survey[J]. arXiv preprint arXiv:2312.17617, 2023.

[3] ZHU Y, WANG X, CHEN J, et al. Large Language Models for Knowledge Graph Construction and Reasoning[J]. arXiv preprint arXiv:2305.13168, 2023.

[4] WANG S, SUN X, LI X, et al. GPT-NER: Named Entity Recognition via Large Language Models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL). 2023.

[5] ZAMAI S, BOUTHORS M, MINARD A L, et al. SLIMER: Show Less, Instruct More—Entity Recognition with Definitions and Guidelines[C]//Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING). 2024.

[6] LI P, SUN T, TANG Q, et al. CodeIE: Large Code Generation Models are Better Few-Shot Information Extractors[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL). 2023.

[7] YE J, XU N, WANG Y, et al. LLM-DA: Data Augmentation via Large Language Models for Few-Shot Named Entity Recognition[J]. arXiv preprint arXiv:2402.14568, 2024.

[8] WAN Z, CHENG F, MAO Z, et al. Large Language Models are Few-Shot Relation Extractors[C]//Findings of the Association for Computational Linguistics: EMNLP 2023. 2023.

[9] ELVA R, SCHLICHTKRULL M, TITOV I. Revisiting Relation Extraction in the Era of Large Language Models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL). 2023.

[10] XUE L, ZHANG D, DONG Y, et al. AutoRE: Document-level Relation Extrac-

tion with Large Language Models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL). 2024.

[11] WANG X, ZHOU W, ZU C, et al. InstructUIE: Multi-task Instruction Tuning for Unified Information Extraction[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2023.

[12] SAINZ O, GARCÍA-FERRERO I, AGERRI R, et al. GoLLIE: Annotation Guidelines Improve Zero-Shot Information Extraction[C]//The Twelfth International Conference on Learning Representations (ICLR). 2024.

[13] LUO Y, ZHANG X, HE Y, et al. OneKE: A Dockerized Schema-Guided LLM Agent-based Knowledge Extraction System[C]//Companion Proceedings of the ACM Web Conference 2025 (WWW). 2025.

[14] AIN Q, CHOUDHARY M A, SARTOLI S. An Optimized Pipeline for Automatic Educational Knowledge Graph Construction from PDF Learning Material [J]. arXiv preprint arXiv:2509.05392, 2025.

[15] YANG R, SALA F, WU C, et al. Graphusion: Zero-shot Knowledge Graph Construction from Free Text[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2024.

[16] ISHTIAQ U, ZAFAR N, ZIA M A. Personalized Higher Education Course Modeling using Large Language Models[J]. arXiv preprint arXiv:2501.12300, 2025.

[17] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C]// Advances in Neural Information Processing Systems (NeurIPS). 2017.

[18] BROWN T, MANN B, RYDER N, et al. Language Models are Few-Shot Learners [C]//Advances in Neural Information Processing Systems (NeurIPS). 2020.

[19] ZHOU W, ZHANG S, GU Y, et al. UniversalNER: Targeted Distillation from Large Language Models for Open Named Entity Recognition[J]. arXiv preprint arXiv:2308.03279, 2023.

[20] ZARATIANA U, TOMEH N, HOLAT P, et al. GLiNER: Generalist Model for Named Entity Recognition using Bidirectional Transformer[J]. arXiv preprint arXiv:2311.08526, 2023.

[21] XIE T, LI Q, ZHANG J, et al. Self-Improving Zero-Shot Named Entity Recognition with Large Language Models[J]. arXiv preprint arXiv:2311.08921, 2023.

[22] WANG S, LI Y, DING N, et al. Unleashing Large Language Models' Potential for Zero-Shot Relation Extraction via Self-Prompting[J]. arXiv preprint arXiv:2410.01154, 2024.

[23] ABDELKADER A, NAJAR A, BOUDJELLAL N. GLiREL: Generalist Lightweight Model for Zero-Shot Relation Extraction[J]. arXiv preprint arXiv:2501.03172, 2025.

[24] GAO T, FISCH A, CHEN D. REPaL: Relation Extraction with Relation Definitions[J]. arXiv preprint arXiv:2402.11142, 2024.

[25] ZHANG C, QIU Y, LI S, et al. EDC: Extract-Define-Canonicalize—An End-to-End Framework for Knowledge Graph Construction[J]. arXiv preprint arXiv:2404.03868, 2024.

[26] BELISLE M, GONZALEZ I, BROWN T. KGGen: Extracting Knowledge Graphs from Plain Text with Large Language Models[J]. arXiv preprint arXiv:2502.09956, 2025.

[27] CHEN H, LIU X, SHAO H, et al. SAC-KG: Exploiting LLMs as Skilled Authors for Domain Knowledge Graph Construction[J]. arXiv preprint arXiv:2410.02811, 2024.